胡元楨（P77141105）

RQ1 CBOW 與 Skip-gram 有何差異？

面向	CBOW（cbow-d50-w5-m5-e10）	Skip-gram（sg-d50-w5-m5-e10）
訓練方式	視窗內周圍詞向量取**平均** → 預測中心詞；每個位置 1 個樣本，10 epochs 82.5 s	**中心詞** → 逐一預測每個周圍詞；每個位置 2b 個樣本，10 epochs 254.7 s（3 倍時間）。兩者皆在 10 epochs 內收斂
近鄰詞彙	cosine 偏高（0.85–0.95），偏**句型**相似：cancer → ischemic, neuropathy, macular（併發症）	cosine 較低（0.6–0.85），偏**主題**相似：cancer → breast, pdac, colorectal（癌症種類）
低頻詞 5–9 次，1,766 詞	同詞幹變形 hit@10 0.0%：罕見詞只分到平均梯度的 1/2b，且被同視窗高頻詞稀釋	同詞幹變形 hit@10 6.1%：每出現一次自身向量就更新 2b 次

結論　兩架構對同一詞的前 10 近鄰只有 **14%** 重疊，但差異幾乎全集中在罕見詞：200+ 次的高頻詞兩者相當，5–9 次的詞 Skip-gram 明顯較穩。Skip-gram 用 3 倍訓練時間買的就是這一段（Mikolov 等，2013）。

RQ2 詞嵌入是否具有語意意義？

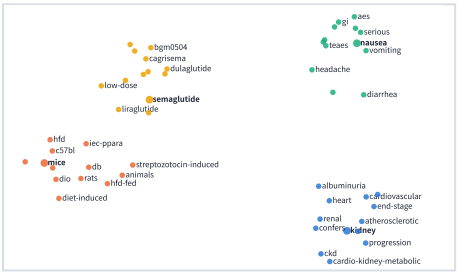
cosine（6 組 22 詞）	組內	組間	隨機對
Skip-gram	**0.680**	0.350	0.474
CBOW	**0.702**	0.348	0.633

六組中最低為血糖組（SG 0.43）。類比 v(ckd) − v(kidney) + v(liver) = **masld / mafld**（脂肪肝）只在 Skip-gram 成立。

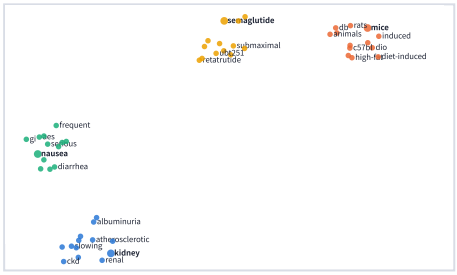
詞對	SG / CBOW	Skip-gram 近鄰
semaglutide–liraglutide	.74 / .92	dulaglutide, liraglutide, tirzepatide
nausea–vomiting	.97 / .98	vomiting, diarrhea, constipation, aes
diagnosis–diagnosed	.77 / .93	codes, residents, classified（一般詞最差）
cancer–tumor	.37 / .27	breast, pdac, colorectal, crc
diabetes–insulin	.30 / –	prediabetes, mellitus, t2dm

判斷：有，但是「主題層級」的語意。組內 0.68 ≫ 組間 0.35，組間甚至低於隨機詞對：藥名 / 副作用 / 動物模型各自成群。限制：(1) word2vec 學的是「可互換」而非「有關」，diabetes–insulin 僅 0.30；(2) 隨機詞對 cosine 達 0.47–0.63（空間各向異性，CBOW 更甚），**cosine 只能看相對排序**。

RQ3 PCA 與 t-SNE 的視覺化結果有何不同？



PCA（Skip-gram 基準）：4 個種子詞（粗體）各加 12 個最近鄰，共 52 詞。PC1 大致是「臨床 / 藥物」對「動物 / 機制」軸。



t-SNE（perplexity 15、400 iterations）：同 52 詞、同模型，被拉成 4 個緊密的島。

PCA　線性：投影到變異最大的兩個正交方向。PC1 + PC2 解釋 **53.7%** 變異；k-NN 保留率 k=5 / 10 = 50.8% / 83.1%。座標與距離有意義、可重現，但群內細節被壓扁。

t-SNE　非線性：最小化高維與低維鄰居分布的 KL 散度。k-NN 保留率 **81.5% / 89.0%**，局部鄰域忠實；但**群間距離、群的大小與方位沒有意義**，換 perplexity 或 seed 佈局就不同。

注意　四群在兩圖都分得開，主因是種子詞本來就是語料中相距最遠的主題：在未挑種子的 120 個高頻詞上，PCA 只解釋 15.4% 變異，幾乎看不出結構；t-SNE 對完全隨機的向量也會畫出「群」。**視覺上成群 ≠ 語意好**：判斷依據是 RQ2 的 cosine，圖只用來看「模型把誰當成鄰居」。

RQ4 模型參數會如何影響結果？

Skip-gram 前 10 近鄰 Jaccard 重疊	整體	5–9 次	200+
window 5 vs window 2	24.4%	14.5%	36.7%
min_count 5 vs 2	36.3%	18.1%	49.6%
50 維 vs 100 維	50.3%	44.0%	58.1%
參照：同設定、只換 seed	48.6%	41.7%	53.9%

- **視窗**（24% ≪ seed 的 49%，唯一超過雜訊的影響）：window 2 的近鄰偏「句法」緊鄰詞（weight → hair, antipsychotic-induced），window 5 偏主題（weight → loss, achieve）；藥名多在「A vs B」緊鄰位置，故 window 2 的藥名群更純。
- **min_count 2**（36%）：詞彙 4,438 → 8,544，新增皆為 1–4 次的詞，sim@10 0.967：罕見詞互抱成團並污染既有近鄰（kidney 的近鄰出現基因名 iec-ppara）。
- **維度**（50% ≈ seed，等於沒有影響）：組內 cosine 0.68 → 0.66，訓練時間加倍。16 萬 token 用 50 維已足夠；CBOW 對維度較敏感。

結論　以「只換 seed」的重疊率為尺規：**視窗**決定「相似」的定義，**min_count** 下修只會引進雜訊，**維度**在這個語料規模下無感。

RQ5 小型語料的限制為何？

穩定度：同語料、同超參數只換 seed，Skip-gram 對同一詞的前 10 近鄰只剩 **48.6%** 重疊、CBOW **36.7%**；5–9 次的詞 41.7% / 16.6%。罕見詞的「鄰居是誰」有一半以上由初始化決定；200+ 次的高頻詞 54–60%，也非完全穩定。

低頻詞：Zipf 長尾使 41% 詞型只出現一次、69% 不到 5 次；留下的 4,438 詞中仍有 40% 只出現 5–9 次，其 sim@10 高達 0.93–0.97：不是學得好，而是向量幾乎沒離開初始化。

專業術語：全語料僅 123 個詞超過 200 次，tumor 只有 19 次，落在不穩定區；藥名例外（semaglutide 759 次）只因語料本來就以 GLP-1 查得。

領域與資料量：單一主題讓「同主題」失去鑑別力（obesity–diabetes 0.66 反高於 diabetes–insulin 0.30），cancer 的近鄰因樣板句變成併發症（見 RQ1）。反面是優點：無一詞多義、句法規整，才能在 1.8×10^5 token（比 Mikolov 的 10^9 少四個數量級）上學出主題群。loss 收斂不是學完了，而是能擠出的資訊就這麼多。

結論　1,000 篇摘要足以學到**主題層級**的嵌入：查詢擴展（semaglutide → dulaglutide / liraglutide）、同義縮寫（t2dm / t2d / mellitus）、副作用詞群；不足以支撐**詞層級**的精度：類比推理、罕見術語相似度。改善方向：PubMed / PMC OA 大語料預訓練再微調、fastText 子詞、或改用上下文嵌入。