# 1,000 篇 GLP-1 摘要能學到怎樣的詞嵌入？CBOW 與 Skip-gram 的五個問題

作者 胡元楨（P77141105）· 語料：1,000 篇 PubMed 摘要（查詢 *GLP-1*）· 前處理：標題＋摘要、規則式斷句（視窗不跨句）、保留連字號、全小寫、去停用詞（30% token）、不做詞幹、min_count 5 · 實作：純 Python word2vec（negative sampling k=5、subsampling $10^{-3}$、dynamic window、10 epochs）與自寫 PCA / t-SNE · 9 個模型，基準 50 維、window ±5 · 所有數字的出處與完整分析：`REPORT_w2v.md`

| 1,000 | 11,802 | 176,332 | 14,517 | 4,438 | 9 |
|---|---|---|---|---|---|
| 文件（標題＋摘要） | 句子，平均 14.9 token | token（去停用詞後） | 詞型；41% 只出現一次 | 詞彙（≥5 次）涵蓋 90.4% token | 模型：架構 × window × dim × min_count × seed |

## RQ1 CBOW 與 Skip-gram 有何差異？

| 面向 | CBOW（基準 cbow-d50-w5-m5-e10） | Skip-gram（基準 sg-d50-w5-m5-e10） |
|---|---|---|
| **訓練方式** | 視窗內 2b 個周圍詞向量的**平均** → 預測中心詞；每個位置 1 個樣本，159,405/epoch（= token 數）；10 epochs 82.5 s | **一個中心詞** → 分別預測每個周圍詞；每個位置 2b 個配對，791,811/epoch（5 倍）；10 epochs 254.7 s（約 3 倍時間） |
| **訓練損失** | epoch 1→10：3.78 → 1.985。起點高、終點低：「平均視窗→中心詞」較容易預測 | epoch 1→10：3.17 → 2.062。第 1 epoch 就降得多（樣本 5 倍）。兩者皆於 10 epochs 內收斂（末兩 epoch 差 < 0.02），但任務不同，**loss 絕對值不可跨架構比較** |
| **近鄰詞彙** | cosine 偏高（0.85–0.95），偏**句型**相似：nausea → vomiting, hcc, thromboembolic；cancer → ischemic, neuropathy, macular（併發症） | cosine 較低（0.6–0.85），偏**主題**相似：nausea → vomiting, diarrhea, constipation, aes；cancer → breast, pdac, colorectal, crc（癌症種類） |
| **低頻詞** 5–9 次，1,766 詞 | 同詞幹變形 hit@10 0.0%、換 seed 近鄰重疊 16.6%（200+ 高頻詞：30.5%、59.8%）。罕見詞只分到平均梯度的 1/2b，且被同視窗高頻詞稀釋 | 變形 hit@10 6.1%、換 seed 重疊 41.7%（200+：28.1%、53.9%，兩者相當）。每出現一次自身向量更新 2b 次，且須獨自解釋整個視窗 |

**結論** 兩架構對同一個詞的前 10 近鄰只有 **14%** 重疊：同一語料學到不同的「相似」定義。Skip-gram 以 3 倍訓練時間換得小語料、罕見詞與專有名詞上較好的表現；CBOW 快、對高頻詞穩定，與 Mikolov 等（2013）的結論一致。

## RQ2 詞嵌入是否具有語意意義？

| 6 組 22 詞的 cosine | 組內 | 組間 | 隨機 400 對 | 藥名 | 副作用 | 體重 | 血糖 | 腎臟 | 動物 |
|---|---|---|---|---|---|---|---|---|---|
| **Skip-gram** | **0.680** | 0.350 | 0.474 | .75 | .95 | .57 | .43 | .61 | .74 |
| **CBOW** | **0.702** | 0.348 | 0.633 | .90 | .95 | .65 | .37 | .59 | .75 |

| 詞對 | SG / CBOW | Skip-gram 近鄰 |
|---|---|---|
| **semaglutide**–liraglutide | .74 / .92 | dulaglutide, liraglutide, tirzepatide |
| **nausea**–vomiting | .97 / .98 | vomiting, diarrhea, constipation, aes |
| **diagnosis**–diagnosed | .77 / .93 | codes, residents, classified（一般詞最差） |
| **treatment**–therapy | .54 / .63 | discontinuation, treatments |
| **cancer**–tumor | .37 / .27 | breast, pdac, colorectal, crc |
| **diabetes**–insulin | .30 / – | prediabetes, mellitus, t2dm |

類比 v(ckd) − v(kidney) + v(liver) = **masld / mafld**（脂肪肝）只在 Skip-gram 成立；CBOW 給 pwh、comorbidities。

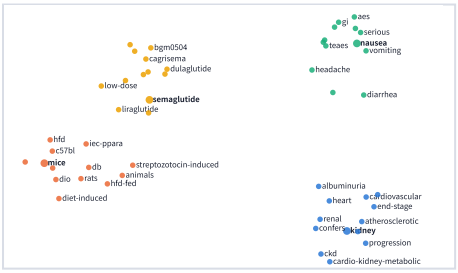
**判斷：有，但是「主題層級」的語意。**每一組的組內平均都高於組間（0.68 ≫ 0.35），組間甚至低於隨機詞對：藥名 / 副作用 / 動物模型各自成群，不是巧合。限制：(1) word2vec 學的是「可互換」而非「有關」：diabetes–insulin 僅 0.30；(2) 隨機詞對 cosine 高達 0.47–0.63，空間各向異性（CBOW 更甚），**cosine 只能看相對排序**；(3) tumor 僅 19 次，學不穩。

## RQ4 模型參數會如何影響結果？

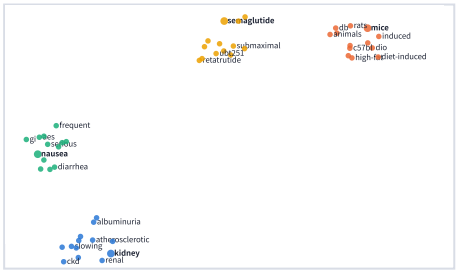
| 比較（前 10 近鄰 Jaccard 重疊） | 整體 | 5–9 次 | 200+ |
|---|---|---|---|
| SG window 5 vs window 2 | 24.4% | 14.5% | 36.7% |
| CBOW window 5 vs window 2 | 21.6% | 7.0% | 43.2% |
| SG 50 維 vs 100 維 | 50.3% | 44.0% | 58.1% |
| CBOW 50 維 vs 100 維 | 36.6% | 16.1% | 61.0% |
| SG min_count 5 vs 2 | 36.3% | 18.1% | 49.6% |
| 參照：SG 同設定、只換 seed | 48.6% | 41.7% | 53.9% |

- **視窗（影響最大）**：window 2 的近鄰更「句法」：weight → hair, antipsychotic-induced, body-weight（緊鄰詞）；window 5 → loss, achieve, attributable（主題）。semaglutide 在 window 2 得到更多藥名（survodutide, ecnoglutide），因藥名多在「A vs B」的緊鄰位置；t-SNE 中 window 2 的藥名群更純，window 5 混入 once-weekly, low-dose。window 2 的 loss 也較低（2.005 vs 2.062）：近的詞較好預測。
- **維度（影響最小）**：100 維的 sim@10 幾乎不變，5–9 次變形 hit@10 6.1% → 9.1%，組內 cosine 0.68 → 0.66，訓練時間加倍（255 → 475 s）：對 4,438 詞、16 萬 token，50 維已足夠。CBOW 對維度較敏感。
- **min_count 2**：詞彙 4,438 → 8,544，新增詞只出現 1–4 次，sim@10 0.967、近鄰頻次中位數 2：罕見詞互抱成團並污染既有近鄰（kidney 的近鄰出現 iec-ppara 之類基因名）。

## RQ3 PCA 與 t-SNE 的視覺化結果有何不同？




**PCA**（Skip-gram 基準）：4 個種子詞（粗體）各加 12 個最近鄰，共 52 詞。PC1 大致是「臨床 / 藥物」對「動物 / 機制」軸。




**t-SNE**（perplexity 15、400 iterations、KL 0.054）：同 52 詞、同模型，被拉成 4 個緊密的島。

**PCA** 線性：投影到變異最大的兩個正交方向（power iteration）。PC1 34.6% + PC2 19.1% = **53.7%** 變異；k-NN 保留率 k=5 / 10 = 50.8% / 83.1%。座標與距離有意義、可重現；但群內細節被壓扁（k=5 只留一半），在未挑種子的 120 個高頻詞上兩個主成分只解釋 15.4% 變異，圖幾乎沒有結構。

**t-SNE** 非線性：最小化高維鄰居機率 P 與低維 Q 的 KL 散度。k-NN 保留率 **81.5% / 89.0%**（高頻詞 60.3% / 53.8%），局部鄰域忠實；但**群間距離、群的大小與方位都沒有意義**，換 perplexity 5 / 30 或 seed 就得到不同佈局（76.5–81.5%），KL 隨 perplexity 單調下降，不能當品質指標。

**注意** 四群在兩張圖都分得開，主要因為種子本來就是語料中相距最遠的主題；t-SNE 對完全隨機的向量也會畫出一團團「群」。**視覺上成群 ≠ 語意好**：判斷依據是 RQ2 的 cosine 基準線與 RQ1 / RQ5 的量化指標，圖只用來看「模型把誰當成鄰居」。

## RQ5 小型語料的限制為何？

**穩定度是最直接的證據。**同語料、同超參數只換隨機 seed，Skip-gram 對同一詞的前 10 近鄰只剩 **48.6%** 重疊、CBOW **36.7%**；5–9 次的詞分別 41.7% 與 16.6%。亦即「某個罕見詞的鄰居是誰」有一半以上由初始化與抽樣順序決定；200+ 次的高頻詞 54–60%，穩定得多但仍非完全穩定。

**低頻詞**：Zipf 長尾使 41% 詞型只出現一次、69% 不到 5 次；留下的 4,438 詞中仍有 40%（1,766 個）只出現 5–9 次，其 sim@10 高達 0.93–0.97：不是學得好，而是向量幾乎沒離開初始化、彼此仍在同一方向上。

**專業術語**：tumor 19 次、nafld 10、retinopathy 18、parkinson 12，皆在不穩定區；藥名例外（semaglutide 759、tirzepatide 446）是因為語料本來就以 GLP-1 查得。一個術語要數百次出現才穩，本語料只有 123 個詞超過 200 次。

**語料領域**：單一主題讓「同主題」失去鑑別力：obesity–diabetes 0.66 反而高於 diabetes–insulin 0.30；腫瘤、神經科的詞以「GLP-1 對 X 的影響」樣板句出現，所以 cancer 的 CBOW 近鄰變成糖尿病併發症。反面是優點：無一詞多義、句法規整，才能在 16 萬 token 上學出 6 個主題群。

**資料量**：1.8 × $10^5$ token，比 Mikolov 的 $10^9$ 少四個數量級。loss 在 10 epochs 收斂不是學完了，而是能擠出的資訊就這麼多；再多 epoch 只會更貼合這 1,000 篇的措辭。

**結論** 1,000 篇摘要足以學到**主題層級**的嵌入：查詢擴展（semaglutide → dulaglutide / liraglutide）、同義縮寫（t2dm / t2d / mellitus）、副作用詞群、用 PCA / t-SNE 探索主題；不足以支撐**詞層級**的精度：類比推理、罕見術語的相似度。改善方向：在 PubMed / PMC OA 大型語料預訓練再微調、fastText 子詞（讓 glp-1ra / glp-1ras / glp-1r 共享參數）、或改用上下文嵌入。