

科學文獻語料的詞頻分布是否符合 Zipf 定律？

DOES THE WORD-FREQUENCY DISTRIBUTION OF A SCIENTIFIC DOCUMENT COLLECTION FOLLOW ZIPF'S LAW?

以 1,000 篇 PubMed 摘要（查詢詞 *GLP-1*）建立語料庫，計算 CF / DF，繪製 rank-frequency 與 log-log 圖、估計 Zipf exponent，比較四種前處理條件，並連結到 CF、DF、IDF 與 Luhn 有效詞的鑑別力。

作者 胡元楨

日期 2026-10-06

語料 PubMed abstract collection (pubmed_glp1) — 1,000 篇文件，以 PMID 為文件 ID

工具 專案的純 Python 檢索工具（Zipf 分頁）；本報告所有數字與圖表均由該工具產生

結論摘要

- **近似符合**。條件 B 下整條曲線的最小平方迴歸得到 $k = 1.419$ 、 $R^2 = 0.966$ 、 $RMSE = 0.115$ ($\log_{10}$ 單位)。log-log 圖接近直線但有彎曲：頭部比單一直線平 ($k = 0.82$)、尾部比直線陡 ($k = 1.60$)。
- **中頻段最符合** (rank 24–561: $R^2 = 0.9975$ 、 $RMSE = 0.0136$)。 R^2 本身不能證明冪次律：log-normal 或 Zipf-Mandelbrot 曲線在這類資料上會得到相近的 R^2 ，而且殘差是系統性的，不是隨機的。
- **前處理改變的是頭尾，不是定律本身**。去標點讓詞彙減半 (29,758 → 13,323) 但 token 變多；去停用詞刪掉 26% 的 token 卻只少 128 個詞；stemming 合併了 27% 的詞彙。 k 由 1.10 (A) 變為 1.48 (D)；加入 E (B + stemming、保留停用詞) 後可確認頭部變平來自停用詞、尾部變陡來自 stemming。
- **CF 與 DF 量的是不同的東西**。`glp` 的 CF = 3,325 分布在 774 篇（每篇 4.3 次），`results` 的 CF = 616 分布在 538 篇（每篇 1.1 次）。IDF 由 DF 決定：`and` → 0.0004、`retinopathy` → 2.0。
- **Luhn 的有效詞**（以 CF × IDF 衡量，半高截斷）在條件 B 落在 rank 10–155，去停用詞後移到 1–112。

目錄

- | | |
|--|---|
| 1. 語料與前處理流程 (Part I–II) | 5. 前處理的影響：條件 A–D (Part VI) |
| 2. Collection frequency 與 document frequency (Part III–IV) | 6. CF 與 DF 的比較 (Part VII) |
| 3. Zipf 分布：實驗一與實驗二 (Part V) | 7. 與 TF-IDF 的關係、Luhn 有效詞鑑別力 (Part VIII) |
| 4. 必答分析：問題 1–4 | 8. 對資訊檢索系統的意義 (Part IX) |

1. 語料與前處理流程

1.1 語料來源

語料透過 PubMed E-utilities (`esearch + efetch`) 下載查詢詞 *GLP-1* 最新的 1,000 篇英文摘要，每篇以 PMID 為唯一 Document ID，文件內容為 title + abstract。語料存成 `data/pubmed_glp1.jsonl` (一行一筆)，例如 PMID38757954, PMID39421913, PMID39724554, PMID40049721, PMID40358690。主題集中 (GLP-1 受體促效劑、肥胖、第二型糖尿病)，因此高頻的內容詞會非常明顯，這對觀察 CF 與 DF 的差異很有幫助。

1.2 前處理流程 (Part I)




圖 0 前處理流程：每個步驟的輸出就是一個條件，方框內為該條件的 token 數、term 數與 hapax 比例；方框之間是相對前一條件的變化 (上：token，下：term)。A ⊂ B ⊂ C ⊂ D 是累積的；E 由 B 分支，跳過停用詞直接 stemming (Δ 相對於 B)。

每個條件各自建立 vocabulary、CF、DF 與排名，後面所有的表與圖都標明使用的條件。停用詞處理有「保留」(A、B) 與「移除」(C、D) 兩個版本，詞幹化採用 Porter stemmer (自行實作)。

1. 語料與前處理流程（續）

1.3 建立 vocabulary (Part II)

Token 是切出來的每一次出現；**term** (unique term / type) 是去重後的字串。Total tokens 是前者的總數、Unique terms 是後者；每個 term 的 CF 就是它的 token 數，所有 CF 的總和等於 total tokens。

條件	文件數	總 token 數	不同 term 數	平均 token／篇	Token／term	只出現一次的詞 (hapax)
■ A Basic	1,000	263,453	29,758	263.5	8.9	17,397 (58.5%)
■ B Punctuation removed	1,000	286,598	13,323	286.6	21.5	4,703 (35.3%)
■ C Stop words removed	1,000	212,155	13,195	212.2	16.1	4,699 (35.6%)
■ D Stemming	1,000	212,155	9,614	212.2	22.1	3,309 (34.4%)
■ E Stemming, stop words kept	1,000	286,598	9,723	286.6	29.5	3,304 (34.0%)

- **A → B**：token 變多 (+23,145)、term 大減 (-16,435)。拆標點把 `glp-1`、`p<0.05` 切成多個 token，同時 `receptor,` / `receptor.` / (`receptor` 併成一個 term)。
- **B → C**：token 減少 26.0%，term 只少 128 個：停用詞型少，但每個出現成千上萬次。
- **C → D**：token 完全不變 (stemming 只改寫)，term 減少 3,581 (27.1%)。
- **B → E** (跳過停用詞、直接 stemming)：token 與 B 相同 (286,598)，term 由 13,323 降到 9,723； $E - D = 109$ 個 term，就是停用詞經 stemming 後剩下的詞幹數。E 讓停用詞與 stemming 的效果可以分開看：E 對 D 只差停用詞，E 對 B 只差 stemming。

2. Collection frequency 與 document frequency

對每個 term 計算 **CF(t)** = term 在整個語料出現的次數 (Part III)，以及 **DF(t)** = 含有該 term 的文件數 (Part IV)。下表是 condition B (去標點、保留停用詞) 依 CF 排序的前 50 名；最後一欄 $r \times CF$ 若 $k = 1$ 應近似常數。

依 CF 排序的前 50 個 term — 條件 B

r	詞	CF	DF	$r \times CF$	r	詞	CF	DF	$r \times CF$
1	and	11,762	999	11,762	26	peptide	1,078	720	28,028
2	of	6,613	982	13,226	27	risk	1,074	424	28,998
3	the	6,454	984	19,362	28	agonists	1,029	600	28,812
4	in	5,574	975	22,296	29	glucagon	1,014	716	29,406
5	1	4,720	955	23,600	30	associated	980	504	29,400
6	with	4,454	925	26,724	31	like	980	723	30,380
7	to	3,777	955	26,439	32	metabolic	951	384	30,432
8	a	3,580	946	28,640	33	treatment	909	448	29,997
9	glp	3,325	774	29,925	34	that	905	508	30,770
10	0	2,731	414	27,310	35	95	870	265	30,450
11	for	2,473	869	27,203	36	from	867	523	31,212
12	were	1,919	587	23,028	37	outcomes	856	409	31,672
13	was	1,701	594	22,113	38	study	803	448	30,514
14	2	1,694	627	23,716	39	semaglutide	791	237	30,849
15	receptor	1,574	799	23,610	40	clinical	785	448	31,400
16	or	1,467	575	23,472	41	effects	784	436	32,144
17	weight	1,274	421	21,658	42	p	773	237	32,466
18	obesity	1,260	478	22,680	43	type	770	437	33,110
19	on	1,240	620	23,560	44	ci	769	227	33,836
20	this	1,223	742	24,460	45	are	757	486	34,065
21	patients	1,153	404	24,213	46	we	752	467	34,592
22	as	1,139	574	25,058	47	these	728	516	34,216
23	is	1,137	610	26,151	48	use	725	323	34,800
24	diabetes	1,108	534	26,592	49	disease	722	330	35,378
25	by	1,083	586	27,075	50	evidence	706	384	35,300

前 10 名有 8 個是功能詞，加上 1 (來自 GLP-1) 與 glp； $r \times CF$ 從 11,762 一路升到 35,300，顯示頭部比 $k = 1$ 的理想曲線平。

依 CF 排序的前 50 個 term — 條件 C（已移除停用詞）

r	詞	CF	DF	r×CF	r	詞	CF	DF	r×CF
1	1	4,720	955	4,720	26	ci	769	227	19,994
2	glp	3,325	774	6,650	27	use	725	323	19,575
3	0	2,731	414	8,193	28	disease	722	330	20,216
4	2	1,694	627	6,776	29	evidence	706	384	20,474
5	receptor	1,574	799	7,870	30	3	697	320	20,910
6	weight	1,274	421	7,644	31	4	682	312	21,142
7	obesity	1,260	478	8,820	32	loss	676	285	21,632
8	patients	1,153	404	9,224	33	glucose	661	346	21,813
9	diabetes	1,108	534	9,972	34	results	616	538	20,944
10	peptide	1,078	720	10,780	35	based	590	320	20,650
11	risk	1,074	424	11,814	36	cardiovascular	588	218	21,168
12	agonists	1,029	600	12,348	37	studies	582	317	21,534
13	glucagon	1,014	716	13,182	38	5	578	260	21,964
14	associated	980	504	13,720	39	using	563	372	21,957
15	like	980	723	14,700	40	analysis	547	287	21,880
16	metabolic	951	384	15,216	41	review	538	339	22,058
17	treatment	909	448	15,453	42	therapy	537	266	22,554
18	95	870	265	15,660	43	1ra	527	146	22,661
19	outcomes	856	409	16,264	44	methods	521	498	22,924
20	study	803	448	16,060	45	adults	515	266	23,175
21	semaglutide	791	237	16,611	46	insulin	497	188	22,862
22	clinical	785	448	17,270	47	6	487	239	22,889
23	effects	784	436	18,032	48	including	483	366	23,184
24	p	773	237	18,552	49	agonist	475	329	23,275
25	type	770	437	19,250	50	tirzepatide	455	143	22,750

移除停用詞後榜首換成主題詞：glp、receptor、weight、obesity、patients、diabetes；數字 token 1、0、2 來自 GLP-1、小數與 95% CI。DF 欄顯示 glp 出現在 774 篇、receptor 799 篇，但 0 只有 414 篇——同樣的 CF 量級，分布完全不同（見第 6 節）。

3. Zipf 分布 (Part V)

實驗一 Rank 對 frequency

以 condition B 的 13,323 個 term 依 CF 排序。左圖用線性座標：曲線貼著兩軸，幾乎看不出分布；右圖把頻率軸取對數，整條長尾都看得見。這就是 Zipf 分布需要適當 scale 的原因。




圖 1a Rank-frequency，線性座標 (condition B)




圖 1b 同一資料，頻率軸取 log

實驗二 Log-log 圖與線性迴歸

對 $\log_{10}(CF)$ 與 $\log_{10}(r)$ 做最小平方迴歸 $\log(CF) = a - b \cdot \log(r)$ 。虛線為整條曲線的迴歸線，兩條垂直虛線把 log-rank 軸等分成高／中／低頻三段，各段另外單獨迴歸。




圖 2 Log-log plot (condition B) : $\log_{10}CF = 5.808 - 1.419 \cdot \log_{10}r$

斜率 (-b)	-1.4188
截距 (a)	5.8082
Zipf exponent k	1.4188
R ²	0.9662
RMSE (log ₁₀ 單位)	0.1150
資料點 (term 數)	13,323

RMSE 0.115 in $\log_{10}$ 等於實際頻率平均偏離迴歸線約 $10^{0.115} \approx 1.30$ 倍。

分段迴歸報告

範圍	Rank	斜率 -b	截距 a	Zipf k	R ²	RMSE	Token 佔比	相對整體迴歸線的平均殘差
整條曲線	1 - 13,323	-1.4188	5.8082	1.4188	0.9662	0.1150	100%	0
高頻 high (23 terms)	1 - 23	-0.8191	—	0.8191	0.9482	0.0672	25.2%	-1.038
中頻 middle (538 terms)	24 - 561	-0.8607	—	0.8607	0.9975	0.0136	42.3%	-0.189
低頻 low (12,762 terms)	562 - 13,323	-1.6025	—	1.6025	0.9798	0.0734	32.5%	+0.010

4. 必答分析

Q1 你的文件語料是否符合 Zipf 定律？

近似符合，但不是嚴格的單一幂次律。log-log 圖上 13,323 個點大致落在一條直線附近 ($R^2 = 0.966$)，長尾形狀非常明確。但曲線有系統性的彎曲：頭部 (rank 1–23) 在直線下方，平均殘差 -1.04，即最高頻的詞比直線預測少一個數量級；尾部因頻率只能是整數 1、2、3… 而呈階梯狀並向下彎。

Q2 估計出的 Zipf exponent 是多少？

整條曲線 $k = 1.419$ (condition B)。分段估計差異很大：高頻 0.82、中頻 0.86、低頻 1.60。五個條件的整體 k 為 A 1.10、B 1.42、C 1.37、D 1.48、E 1.54。整體 k 偏高 (> 1) 的原因是 12,762 個低頻詞 (佔詞彙 95.8%) 在未加權的 OLS 中佔了絕大多數的資料點，把斜率拉向尾部較陡的斜率。

Q3 R^2 足以證明分布符合 Zipf 定律嗎？

不夠。理由有三：(1) R^2 只量「相對於平均值解釋了多少變異」，在 log-log 空間裡任何單調遞減的長尾 (log-normal、stretched exponential、Zipf-Mandelbrot) 都能得到 0.95 以上的 R^2 ，它分不出這些模型。(2) 殘差不是隨機散布：三段相對整體迴歸線的平均殘差是 -1.04 / -0.19 / +0.01，而且分段斜率 0.82 / 0.86 / 1.60 彼此差異明顯——系統性的彎曲代表單一幂次律並不完全成立。(3) OLS 把每個 term 當成一個點，等權重地被數量龐大的 hapax (35.3% 的詞) 主導，所以 R^2 主要反映尾部。要「證明」需要殘差圖、分段斜率，以及 MLE 估計加 KS/likelihood-ratio 檢定與替代模型比較。

Q4 Rank-frequency 曲線的哪一段最符合 Zipf 定律？

中頻段 (rank 24–561，538 個 term、佔 42.3% 的 token)： $R^2 = 0.9975$ 、RMSE = 0.0136，是三段中最直的一段，斜率 0.86 也最接近 $k \approx 1$ 的理想值。高頻段只有 23 個點且多為功能詞，曲線較平 ($k = 0.82$)；低頻段受整數頻率與 hapax 影響呈階梯狀、斜率最陡 ($k = 1.60$)。

4. 必答分析（續）

Q2 補充 為什麼以條件 B 為準，而不是 C 或 D？

B 是 spec 必做的三個步驟（斷詞、小寫、標點）做完、尚未加入變因（停用詞、stemming）的狀態，term 仍等於「詞」、曲線頭部完整，是檢驗「語料本身符不符合定律」的對象。這也有歷史依據：Zipf（1935, 1949）的計數以書寫詞形為單位（Eldridge 的報紙詞表、Hanley 的 *Ulysses* 索引），未移除功能詞、未合併變化形——停用詞表（Luhn 1958）與 stemming（Lovins 1968、Porter 1980）都是後來為自動索引發展的——相當於本報告的條件 B。C、D 是為了檢索而做的處理，動到的正好是定律描述的兩端（E = B + stemming、保留停用詞，用來把兩個效果拆開）：

條件	整體 k	R ²	RMSE	高頻段 k	中頻段 k	低頻段 k
■ A Basic	1.098	0.958	0.100	0.89	0.89	1.10
■ B Punctuation removed	1.419	0.966	0.115	0.82	0.86	1.60
■ C Stop words removed	1.370	0.960	0.122	0.56	0.77	1.57
■ D Stemming	1.482	0.959	0.133	0.48	0.79	1.71
■ E Stemming, stop words kept	1.536	0.964	0.129	0.76	0.86	1.76

- **C（去停用詞）** 砍掉的就是曲線的頭部。rank 1–10、佔 26.0% token 的點整段消失，glp、receptor 遞補成 rank 1、2，但彼此的落差遠小於原本的頭部，高頻段 k 由 0.82 降到 0.56，頭部出現「肩膀」，離直線更遠。
- **D（stemming）** 改變了「詞」的定義。patient + patients、obesity + obese 合併後中高頻的 CF 被加總、尾巴縮短，整體 k 升到 1.48，高頻段 k 只剩 0.48，R²、RMSE 是四者中最差的；此時單位已是詞幹，不再是原本以詞為單位的問題。
- **E 把兩個效果拆開**。E 與 B 只差 stemming：頭部 k 幾乎不變（0.82 → 0.76）、尾部變陡（1.60 → 1.76）；E 與 D 只差停用詞：尾部相近（1.76 vs 1.71）、頭部由 0.76 掉到 0.48。所以「頭部變平」來自停用詞、「尾部變陡」來自 stemming。
- 若課堂慣例是「跑完整條 pipeline 再估」，可改報 D 的 k = 1.48（或 C 的 1.37），但結論要跟著改為「頭部明顯偏離、擬合較差」。本報告把 B 當基準回答 Q1–Q4，C、D 的變化留在第 5 節說明。

5. 前處理的影響 (Part VI)

五個條件各自重新建立 vocabulary 與排名後疊在同一張 log-log 圖上；表格列出各條件的規模、整體與分段的 k。E（紫）是 B 直接 stemming、不移除停用詞，頭部與 B 重合、尾部與 D 重合。




圖 3 五個條件的 rank-frequency 曲線 (log-log)

條件	Token	詞彙	Hapax	前 10 名佔比	k (整體)	R ²	RMSE	k 高／中／低頻	前 8 名
A Basic	263,453	29,758	58.5%	18.2%	1.098	0.958	0.100	0.89 / 0.89 / 1.10	and of the in with to a for
B Punctuation removed	286,598	13,323	35.3%	18.5%	1.419	0.966	0.115	0.82 / 0.86 / 1.60	and of the in 1 with to a
C Stop words removed	212,155	13,195	35.6%	9.4%	1.370	0.960	0.122	0.56 / 0.77 / 1.57	1 glp 0 2 receptor weight obesity patients
D Stemming	212,155	9,614	34.4%	10.1%	1.482	0.959	0.133	0.48 / 0.79 / 1.71	1 glp 0 2 receptor us agonist studi
E Stemming, stop words kept	286,598	9,723	34.0%	18.5%	1.536	0.964	0.129	0.76 / 0.86 / 1.76	and of the in 1 with to a

前處理如何影響 Zipf 分布？

- 詞彙大小 Vocabulary size** A→B 去除標點後 data, 、data. 、(data 合併，詞彙由 29,758 降到 13,323 (-55.2%)，token 反而增加。B→C 停用詞只有 128 個詞型，詞彙幾乎不變，但 token 少了 26.0%。C→D Porter stemming 把 13,195 個詞合併為 9,614 個詞幹 (-27.1%)。
- 高頻詞 High-frequency terms** A、B 的榜首是 the / of / and（前 10 名佔 18.5% 的 token）；C 之後換成主題詞 glp、receptor、weight、obesity，前 10 名只佔 9.4%；D 把同詞幹的變形相加（patient+patients → patient），高頻詞的 CF 再升高（前 10 名 10.1%）。

5. 前處理的影響（續）

3. **Zipf exponent** 整體 k : $A = 1.10$ 、 $B = 1.42$ 、 $C = 1.37$ 、 $D = 1.48$ 、 $E = 1.54$ 。A 最接近 1，是因為黏著標點的詞製造了大量只出現一次的詞型，拉長了尾巴；去標點後尾巴變短、斜率變陡。移除停用詞砍掉曲線最高的頭部，頭段更平（高頻段 k : $B = 0.82 \rightarrow C = 0.56$ ）。Stemming 縮短尾巴並抬高中段，整體 k 上升到 1.48。
4. **分布的形狀 Shape** 五條曲線的中段近乎平行；差異集中在頭部（停用詞移除後變平、出現「肩膀」）與尾部（詞彙越小，曲線越早觸底）。前處理改變的是截距與頭尾，不改變長尾本質。
5. **$E = B + \text{stemming}$ （不去停用詞）** E 的榜首仍是 the / of / and（前 10 名佔 18.5%，與 B 相同），但尾巴和 D 一樣被 stemming 縮短：詞彙 9,723、hapax 34.0%、整體 $k = 1.54$ （五者中最大，因為頭部保留、尾部又縮短）。

Porter stemming 合併了什麼（C → D）

gener CF 219 • 13 forms

generally 60 generating 44 generation 37 general 27
generated 23 generate 10 generalized 6 ...

activ CF 394 • 10 forms

activity 114 activation 113 active 88 activated 27
activating 16 activities 13 activates 12 ...

investig CF 197 • 10 forms

investigated 59 investigation 48 investigate 38
investigations 22 investigational 8 investigates 7
investigating 7 ...

function CF 331 • 9 forms

function 207 functional 86 functions 24
functionalized 6 functionally 3 functionality 2
functioning 1 ...

compar CF 710 • 10 forms

compared 397 comparative 83 compare 61 comparator 50
comparing 44 comparable 42 comparators 23 ...

initi CF 369 • 10 forms

initiation 161 initiated 61 initiating 50
initiators 39 initial 30 initially 15 initiative 5 ...

indic CF 180 • 10 forms

indicating 35 indicated 28 indications 28 indicate 27
indicates 22 indication 22 indices 7 ...

respons CF 323 • 9 forms

response 143 responses 133 responsiveness 20
responsive 11 responsible 6 responsibility 5
responsibly 2 ...

6. CF 與 DF 的比較 (Part VII)

選 26 個詞 (condition C)，比較 CF(t) 與 DF(t)。CF / DF 是「平均每篇出現幾次」(只計算含該詞的文件)；DF / N 是「分布在多少比例的文件」。

詞	CF	DF	CF / DF	DF / N	IDF
glp	3,325	774	4.30	77.4%	0.111
receptor	1,574	799	1.97	79.9%	0.098
weight	1,274	421	3.03	42.1%	0.376
obesity	1,260	478	2.64	47.8%	0.321
patients	1,153	404	2.85	40.4%	0.394
diabetes	1,108	534	2.07	53.4%	0.273
peptide	1,078	720	1.50	72.0%	0.143
risk	1,074	424	2.53	42.4%	0.373
treatment	909	448	2.03	44.8%	0.349
study	803	448	1.79	44.8%	0.349
semaglutide	791	237	3.34	23.7%	0.625
glucose	661	346	1.91	34.6%	0.461
results	616	538	1.14	53.8%	0.269
cardiovascular	588	218	2.70	21.8%	0.661
analysis	547	287	1.91	28.7%	0.542
methods	521	498	1.05	49.8%	0.303
insulin	497	188	2.64	18.8%	0.726
agonist	475	329	1.44	32.9%	0.483
tirzepatide	455	143	3.18	14.3%	0.845
conclusions	317	313	1.01	31.3%	0.504
dose	270	124	2.18	12.4%	0.907
kg	255	134	1.90	13.4%	0.873
placebo	251	86	2.92	8.6%	1.065
liraglutide	226	85	2.66	8.5%	1.071
hba1c	193	86	2.24	8.6%	1.065
mice	174	69	2.52	6.9%	1.161




圖 4 CF 對 DF (condition C, CF 最高的 1,500 個詞)。對角線 CF = DF 表示每篇最多出現一次；越往上代表該詞集中在少數文件裡反覆出現。

Q1 為什麼一個詞可以 CF 很高、DF 卻相對低？

因為它是少數文件的「主題詞」：只在少數文件出現，但在那些文件裡反覆出現。semaglutide CF = 791 只分布在 237 篇 (每篇 3.3 次)、placebo CF = 251 只在 86 篇 (2.9 次)、0 CF = 2,731 只在 414 篇；反之 results、methods、conclusions 每篇出現一次左右 (CF / DF $\approx$ 1.0–1.1)，CF 接近 DF。

Q2 哪個量能告訴我們一個詞是否廣泛分布在文件中？

DF (或 DF / N)。CF 只說總量，分不出「100 篇各 1 次」與「1 篇 100 次」：peptide 與 risk 的 CF 幾乎相同 (1,078 vs 1,074)，但 DF 是 720 vs 424。

Q3 為什麼 CF 與 DF 在資訊檢索中都重要？

DF 決定 IDF (詞的鑑別力) 與 posting list 的長度 (查詢成本)；CF 決定位置索引的大小與語言模型的 collection probability (平滑用)。兩者的落差 (burstiness, CF / DF 遠大於 1) 本身就是「內容詞」的訊號。

7. 與 TF-IDF 的關係 (Part VIII)

$\text{idf}(t) = \log_{10}(N / \text{df}(t))$ ， $N = 1,000$ 。下表為 condition B 的 20 個詞，從最常見到最罕見；長條是 IDF 相對於上限 $\log_{10}(1000) = 3$ 。

詞	CF	DF	DF / N	IDF
and	11,762	999	0.999	0.0004
of	6,613	982	0.982	0.0079
the	6,454	984	0.984	0.0070
in	5,574	975	0.975	0.0110
with	4,454	925	0.925	0.0339
glp	3,325	774	0.774	0.1113
were	1,919	587	0.587	0.2314
weight	1,274	421	0.421	0.3757
patients	1,153	404	0.404	0.3936
study	803	448	0.448	0.3487
semaglutide	791	237	0.237	0.6253
results	616	538	0.538	0.2692
cardiovascular	588	218	0.218	0.6615
insulin	497	188	0.188	0.7258
tirzepatide	455	143	0.143	0.8447
placebo	251	86	0.086	1.0655
liraglutide	226	85	0.085	1.0706
mice	174	69	0.069	1.1612
pancreatitis	46	15	0.015	1.8239
retinopathy	18	10	0.010	2.0000

為什麼非常常見的詞通常得到較低的 IDF？

因為 IDF 只看 DF：出現在幾乎每篇文件的詞 $\text{df} \approx N$ ， $\log(N / \text{df}) \approx 0$ 。and 在 999 篇出現，IDF = 0.0004；with 925 篇，0.034。這些詞對「這篇文件是否相關」毫無鑑別力——查詢 the 會命中每一篇。IDF 隨 DF 減少而以 log 尺度上升：semaglutide (237 篇) 0.63、mice (69 篇) 1.16、retinopathy (10 篇) 2.0。

Zipf 分布與 TF-IDF 加權的關係

Zipf 分布告訴我們頻率極度不均：排名最前的少數詞佔了大部分 token（B 的前 10 名佔 18.5%）。若只用 TF 計分，分數會被這些詞主導。IDF 正好以 log 尺度抵銷冪次律的頭部，讓落在中、低頻段的內容詞得到較高權重——TF-IDF 等於是依 Zipf 曲線上的位置重新加權。下一頁用 Luhn 的「有效詞鑑別力」把這件事畫出來。

7.1 Luhn 有效詞的鑑別力 (resolving power)

Luhn (1958) 認為排名最前的詞太常見、最後的太罕見，鑑別力最高的「有效詞」在曲線中段，用 upper/lower 兩條截斷線框出。本工具把每個詞的鑑別力量化為 $\text{power}(\mathbf{t}) = \text{CF}(\mathbf{t}) \times \text{idf}(\mathbf{t})$ （該詞在全語料累積的 TF-IDF 權重），沿 rank 軸取移動中位數，自動截斷線取曲線維持在峰值一半以上的區間。




圖 5a Condition B：CF（左軸，log）疊上鑑別力移動中位數（右軸）。著色區 rank 10–155 為有效詞。




圖 5b 同一 rank 軸上的 IDF：CF 單調下降、IDF 階梯式上升，兩者相乘在中段凸起。

區 (條件 B)	Rank	詞數	Token 佔比	CF×IDF 佔比	平均 IDF	例子
common	1 – 9	9	17.5%	0.3%	0.026	and of the in 1 with to
significant	10 – 155	146	30.2%	14.2%	0.566	0 for were was 2 receptor or
rare	156 – 13,323	13,168	52.2%	85.4%	2.562	kg which n placebo versus 1r without

Upper cut-off 以上的 9 個詞（17.5% 的 token）只貢獻 0.3% 的鑑別力，其中 7 個在停用詞表裡；lower cut-off 以下的 13,168 個詞單看都很弱（CF 太小），但加總仍佔 85.4%——所以檢索系統保留長尾、改用 IDF 加權，而不是真的切掉。

7.2 A → E：有效詞區間怎麼移動

五個條件各自用自動截斷線（曲線 $\geq$ 峰值一半）。細線是各條件的 CF（左軸，log），粗線是同一條件的鑑別力移動中位數（右軸）；圖上方的橫條是該條件的有效詞區間，圓點是峰值所在的 rank。




圖 6 五個條件的 CF（細線，左軸）與鑑別力移動中位數（粗線，右軸）；上方橫條為各條件的自動截斷區間，圓點為峰值。

條件	有效詞 rank	詞數	Token 佔比	鑑別力佔比	峰值 rank	太常見	鑑別力最高的有效詞
A Basic	7 – 209	203	31.5%	13.6%	32	6	= were weight patients semaglutide p glp-1
B Punctuation removed	10 – 155	146	30.2%	14.2%	13	9	ci semaglutide p weight patients were 1ra
C Stop words removed	1 – 112	112	32.4%	12.0%	4	0	ci semaglutide p weight patients 1ra obesity
D Stemming	1 – 132	132	40.5%	16.3%	13	0	1ra ra ci semaglutid p weight patient
E Stemming, stop words kept	10 – 231	222	41.1%	23.3%	13	9	1ra ra ci semaglutid p weight patient

E 的區間（10–231）左端與 B 相同（upper cut-off 以上同樣是 9 個停用詞），右端因 stemming 合併而比 B 長；有效詞佔總鑑別力 23.3%，比 B（14.2%）與 D（16.3%）都高。最明顯的移動在 B → C：去掉停用詞後，曲線左端被 $\text{idf} \approx 0$ 壓低的那段消失，區間整段貼到 rank 1——停用詞表等於事先套用了 upper cut-off。注意每個條件都重新排名，rank 數字不能直接跨條件比較。

8. 對資訊檢索系統的意義 (Part IX)

Why does Zipf's Law matter to an Information Retrieval system? 為什麼 Zipf 定律對資訊檢索系統很重要? (685 字)

Zipf 定律不是關於詞頻的趣聞，而是檢索系統每個元件都必須面對的統計形狀。在這份語料裡，少數幾個詞佔了大部分的文字，而大多數詞只出現一兩次；這種不均衡決定了詞要怎麼被過濾、儲存與加權。

停用詞移除。排名最前的詞幾乎沒有鑑別價值，因為它們出現在幾乎每一篇文件裡。在條件 B，upper cut-off 以上的 9 個詞 (and、of、the、in.....) 佔了全部 token 的 17.5%，卻只貢獻 0.3% 的 $CF \times IDF$ 總權重；它們的 DF 是 1,000 篇裡的 925–999 篇。含有 the 的查詢會命中每一篇文件，這個詞無法替任何文件排序，只會增加處理時間。移除 191 個停用詞讓 token 數減少 26%，詞彙卻只少 128 個——這等於事先套用了 Luhn 的 upper cut-off。但片語查詢 (例如 "to be or not to be") 需要這些詞，所以現代搜尋引擎多半把停用詞留在索引裡、用權重壓低，而不是直接丟掉。

倒排索引。字典 (dictionary) 的大小隨詞彙成長，而長尾表示字典被罕見詞主導：35% 的詞是 hapax (只出現一次)。因此字典很大但每個項目都很短，適合 front coding 與分塊儲存。Postings list 則是相反的輪廓：它的長度跟著 DF 分布走，少數幾條極長 (and 有 999 筆 posting)，絕大多數只有一兩筆。索引的總大小由那幾條長串決定，壓縮的效益也集中在那裡：長串裡相鄰文件 ID 的間距很小，用 variable-byte 或 gamma 編碼只要一兩個 byte。查詢處理同樣利用這種偏斜：先掃短串再與長串做交集，成本最低。

TF-IDF。 $IDF = \log_{10}(N / DF)$ 直接取決於一個詞在 Zipf 曲線上的位置。and 的 IDF 是 0.0004；semaglutide (DF = 237) 是 0.63；retinopathy (DF = 10) 是 2.0。這個加權把分布的頭部壓平——否則原始詞頻會主導每一個分數——並抬高 Luhn 所說有效詞所在的中段。我們的鑑別力量測證實了這一點：在條件 C，rank 1–112 的 112 個詞佔 32% 的 token，也有最高的平均 $CF \times IDF$ ；13,083 個罕見詞單獨看都很弱，但合計仍佔 88% 的權重。這就是為什麼長尾要留在索引裡、交給 IDF 處理，而不是用 lower cut-off 切掉。

總結：Zipf 定律告訴系統設計者資訊在哪裡——不在頭部 (那是雜訊)，也不在任何單一的尾部詞，而在中間那一段；停用詞表、索引壓縮與 TF-IDF 都是為了把這一段分離出來而設計的。

附錄 再現性

- 程式：專案 repo 的 `ir/zipf.py` (五個條件、 CF/DF 、OLS 迴歸、分段、鑑別力)、`ir/porter.py`、`ir/stopwords.py`；網頁介面的 **Zipf** 分頁；CLI `python3 cli.py zipf / resolving`。
- 語料：`data/pubmed_glp1.jsonl`，1,000 篇摘要，PubMed 查詢詞 *GLP-1*，以 PMID 為 ID。
- 所有圖表都是工具自己繪製的 SVG (座標軸與圖例沿用介面的英文標籤)；所有數字於 2026-10-06 讀自 `/api/zipf`、`/api/zipf/terms`、`/api/zipf/resolving`。