胡元楨（P77141105）

3,000 PubMed 摘要（GLP-1，含 MeSH）；平均 211 索引詞（24–672）

15,823 詞幹；45% 只出現在 1 篇（idf 8.01），42 個詞出現在 ≥ 1,000 篇

2×2×2 + 4 因素設計：tf raw/log × idf 有/無 × L2 有/無 = 8 種；另加 btn、atc、lpc、BM25

15 評估查詢；相關集由 MeSH / 關鍵詞規則 + 118 篇人工判讀產生（30–318 篇）

0.661 最佳 MAP：ltn（log TF × IDF）；raw TF 0.451

118 篇人工判讀，補回 37 篇漏標的相關文件；指標高 0.03–0.11，排序不變

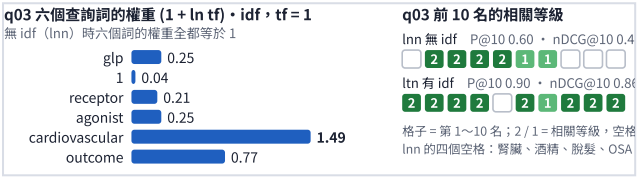
權重代號怎麼讀 SMART 三字母依位置：**l** ①tf **t** ②df **c** ③正規化 ① tf：**n** 原始次數 · **l** 1+ln tf · **a** 增強 · **b** 布林 ② df：**n** 不乘 · **t** idf · **p** 機率 idf ③ 正規化：**n** 無 · **c** cosine 例：`nnn` 原始 tf、`lnn` log tf、`ltn` log tf × idf、`ltc` 再加 cosine（完整對照表：第 2 頁附錄）

RQ1 原始 TF 與 Log TF 的差異，如何影響詞項權重？

tf	1	2	5	10	30	50
raw tf	1	2	5	10	30	50
1 + ln tf	1.00	1.69	2.61	3.30	4.40	4.91

- **例子**：FLOW 試驗摘要提到 semaglutide 7 次、cardiovascular 13 次。raw tf 說後者重要近兩倍；log 給 2.95 對 3.56、只差兩成，較接近人的判斷。
- **機制**：log 的加分逐次遞減（第 2 次 +0.69、第 30 次 +0.03），單一詞無法獨占向量：原始 tf 下（`nnn`）同篇由出現 38 次的「0」主宰、前 5 詞佔 22.5%；log tf（`lnn`）壓到 7.8%。
- **長文不公平**：文件愈長 tf 愈大，raw tf 等於替長文加分；q01 前 10 名平均長度 339 → 275（全集合 211）。
- **效果**：最有效的單一改動，MAP **0.451 → 0.574**（+27%，14/15 題提高）；壓平後 tf 與 idf 同量級，RQ2 的 idf 才量得出來。
- **結論**：詞頻增加，重要性不等比例增加。

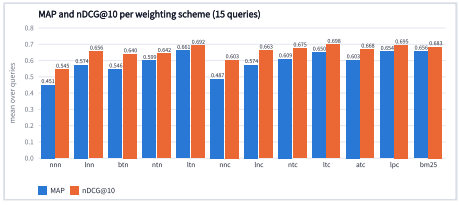
RQ2 為什麼 IDF 能降低常見詞的重要性、提高具辨識力詞項的權重？



- **變因**：固定 log tf，只在第 ② 位乘 idf：lnn → ltn、lnc → ltc。
- **機制**：idf 隨 df 遞減（df 1 → 8.01，N → 0）；出現在八成文件的 glp / receptor / agonist 每篇都加一樣，不改排名，只剩 tf 噪音。
- **效果**：q03 前 10 名相關 6 → 9 篇（左圖，nDCG@10 0.479 → 0.866）；整體 MAP **0.574 → 0.661**（+15%，15/15 題提高），lnc → ltc 0.574 → 0.650；只用 idf 的 btn 也有 0.546。
- **結論**：決定權從「常見詞重複幾次」移到「稀有詞有沒有出現」；短摘要裡有無出現幾乎與出現幾次同樣重要。

RQ3 · RQ5 TF-IDF 是否產生較好的排名？不同 weighting 對各指標的影響

scheme		P@5	P@10	R@20	MRR	MAP	nDCG@10	R-prec
`nnn`	raw TF	0.773	0.760	0.158	0.791	0.451	0.545	0.449
`lnn`	log TF	0.947	0.900	0.192	0.933	0.574	0.656	0.553
`btn`	IDF only	0.840	0.787	0.166	0.922	0.546	0.640	0.562
`ntn`	raw TF × IDF	0.907	0.880	0.195	0.933	0.599	0.642	0.574
`ltn`	log TF × IDF	0.960	**0.960**	**0.205**	0.933	**0.661**	0.692	**0.634**
`nnc`	raw TF, L2	0.880	0.827	0.180	0.883	0.487	0.603	0.477
`lnc`	log TF, L2	0.920	0.873	0.196	0.967	0.574	0.663	0.553
`ntc`	raw TF × IDF, L2	0.933	0.920	0.199	0.967	0.609	0.675	0.585
`ltc`	log TF × IDF, L2	0.960	0.940	**0.205**	0.956	0.650	**0.698**	0.622
`atc`	augmented TF × IDF, L2	0.880	0.873	0.181	**1.000**	0.603	0.668	0.588
`lpc`	log TF × prob IDF, L2	0.947	0.947	0.201	0.967	0.654	0.695	0.622
bm25（參考）		**0.973**	**0.960**	**0.205**	0.967	0.656	0.683	0.619

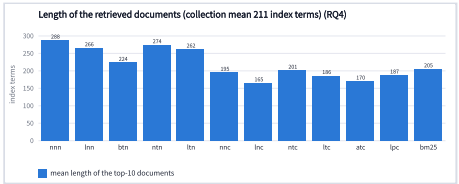


15 個查詢的平均 MAP 與 nDCG@10，含人工判讀（`cli.py vsm eval`、`vsm svg`）。

RQ3 是：MAP raw TF 0.451 → log TF 0.574 → IDF only 0.546 → TF-IDF（ltn）**0.661**；逐題 AP 上 ltn 15/15 勝 raw TF、IDF-only 與 log TF；nDCG@10 前三名 ltc / lpc / ltn 全是 TF × IDF。因素格（MAP）：log +0.06～0.12、idf +0.08～0.15、L2 −0.01～+0.04。
RQ5 raw TF 在所有指標最差；log TF × IDF（ltn / ltc / lpc）在所有指標前四；但「最佳」隨指標與查詢改變——MAP 選 ltn、nDCG@10 選 ltc（0.698）、P@5 / R@k 選 BM25、MRR 選 atc（1.000）；q04 偏好 raw TF（nDCG 0.815 vs 0.645）、q15 偏好正規化（lnc 1.000）、q09 全部都差（副作用詞幾乎每篇試驗都提到，只有「以此為主題」者算相關）。結論須結合查詢、資料集與指標。

RQ4 文件向量是否需要 L2 normalization？正規化前後的排名有何差異？

q10「polycystic ovary syndrome」	overlap@10	τ	mean len	P@10	nDCG@10
ltn log TF × IDF	1.00	1.00	230	1.00	0.775
ltc + L2	0.60	−0.17	165	1.00	0.528
nnn raw TF	0.50	0.09	215	0.70	0.609
nnc + L2	0.30	−0.32	152	0.80	0.525



各 scheme 前 10 名的平均長度（15 題平均）：未正規化 224–288，正規化 165–201，BM25 205。

未正規化的內積 = ‖d‖ · cos θ：長文件多提幾次就贏；正規化後只比方向。兩者排名差異很大（15 題平均 ltn vs ltc 前 10 名重疊 **48%**、τ ≈ 0；前 10 名平均長度 262 → 186），但本集合全是長度相近的摘要（平均 211、相關文件 217），正規化收益小且方向不一（MAP 0.661 → 0.650，僅 6/15 題變好；MRR、nDCG@10 略升；raw tf 則 0.451 → 0.487 受益），而 30 個詞的更正啟事（*Correction:* …）因為沒有其他詞稀釋，在 ltc 下竄到第一名。長度懸殊時正規化不可或缺：把 3 篇 PMC 全文（3,221–4,358 詞）混進 1,003 篇摘要，10 題前 10 名的 100 個位置中 nnn 有 15、ltn 有 9 個被長文佔走，nnc / ltc / BM25 為 0（`report/rq4_mixed_lengths.py`）。BM25 的部分正規化（b = 0.75）兩種情況都最好：問題是「正規化多少」。

方法與限制 相關性判斷

資料集沒有現成標籤，依作業指示用**主題標籤**：每個查詢定義若干概念群（正規表示式），文件的每一群至少命中一個 MeSH 標題或作者關鍵詞即相關，命中 major-topic MeSH 為 grade 2；只看標籤不看文字，故不偏向任何 weighting，並可在介面手動覆寫。為補標籤漏標，對每題把六個 scheme 的前 10 名 pooling，規則判 0 的 **118 篇**由作者讀摘要逐篇判定：37 篇補為相關（q03 心血管試驗 5、q09 副作用主題 7、q13 / q14 無標籤的 OSA 試驗與成本效益分析各 4）、81 篇確認不相關；各指標上升 0.03–0.11，結論方向不變。限制：163 篇（5.4%）無任何標籤（condensed-list 評估排序不變）；57% 有 MeSH；規則與人工判讀皆由作者一人完成，且只判讀了前 10 名；相關集偏大（30–318）、R@k 絕對值低。另一觀察：純數字 token（佔詞彙 11.5%）df 小、idf 高，會混入 ltn 向量前列；移除數字是最直接的改良。

附錄 A SMART 權重代號對照表（tf · df · norm）

每個 weighting scheme 是三個字母，**依位置讀**：第 1 字母是 tf 怎麼算、第 2 字母是 df 怎麼用、第 3 字母是正規化。三個因素獨立，權重 = ① × ② 再做 ③，查詢端全程固定為 `nnc`（原始 tf、不乘 idf、cosine）。

l **t** **c** → `ltc` = (1 + ln tf) × ln(N / df)，再除以向量長度（cosine）。同理 `nnn` = 原始 tf、不乘 idf、不正規化。

① tf　② df　③ norm

A1　三個位置各自可填的字母

位置	字	名稱	公式	直覺 / 用意	本報告用到的 scheme
① tf 詞在這篇出現幾次（局部）	n	natural	`tf`	出現幾次算幾分；高頻詞獨占向量、偏好長文件（RQ1）	`nnn ntn nnc ntc`
	l	logarithm	`1 + ln tf`	加分逐次遞減：tf 30 只得 4.4、不是 30（RQ1）	`lnn ltn lnc ltc lpc`
	a	augmented	`0.5 + 0.5 · tf / max tf`	以該篇最大 tf 為基準，另一種壓平長文件的方法	`atc`
	b	boolean	`1`	只看有沒有出現，忽略次數	`btn`
② df 詞出現在幾篇文件（全域）	n	none	`1`	不管詞多常見	`nnn lnn nnc lnc`
	t	idf	`ln(N / df)`	常見詞降權、稀有詞升權：df 1,172 → 0.94，df 29 → 4.64（RQ2）	`btn ntn ltn ntc ltc atc`
	p	prob idf	`max(0, ln((N − df) / df))`	出現超過一半文件的詞權重直接歸 0	`lpc`
③ norm 向量要不要正規化	n	none	`w`	分數 = 內積；長文件向量長、分數高（RQ4）	`nnn lnn btn ntn ltn`
	c	cosine	`w / ‖d‖`	除以向量長度，分數 = cosine 相似度，長度不再有利（RQ4）	`nnc lnc ntc ltc atc lpc`

A2　本報告的 12 個 scheme

代號	① tf	② df	③ norm	白話	公式	用在	MAP	nDCG@10
`nnn`	n 原始	n 無	n 無	raw TF	`tf`	RQ1 RQ3 RQ4	0.451	0.545
`lnn`	l 對數	n 無	n 無	log TF	`1 + ln tf`	RQ1 RQ2	0.574	0.656
`btn`	b 布林	t idf	n 無	IDF only	`idf`	RQ3	0.546	0.640
`ntn`	n 原始	t idf	n 無	raw TF × IDF	`tf · idf`	RQ1 RQ3	0.599	0.642
`ltn`	l 對數	t idf	n 無	log TF × IDF	`(1 + ln tf) · idf`	RQ1–RQ4	**0.661**	0.692
`nnc`	n 原始	n 無	c cosine	raw TF, L2	`tf / ‖d‖`	RQ4	0.487	0.603
`lnc`	l 對數	n 無	c cosine	log TF, L2	`(1 + ln tf) / ‖d‖`	RQ2	0.574	0.663
`ntc`	n 原始	t idf	c cosine	raw TF × IDF, L2	`tf · idf / ‖d‖`	因素格	0.609	0.675
`ltc`	l 對數	t idf	c cosine	log TF × IDF, L2（教科書標準）	`(1 + ln tf) · idf / ‖d‖`	RQ2 RQ4 變形	0.650	**0.698**
`atc`	a 增強	t idf	c cosine	augmented TF × IDF, L2	`(0.5 + 0.5 tf / max tf) · idf / ‖d‖`	變形	0.603	0.668
`lpc`	l 對數	p 機率 idf	c cosine	log TF × prob IDF, L2	`(1 + ln tf) · max(0, ln((N − df) / df)) / ‖d‖`	變形	0.654	0.695
`bm25`	不屬於 SMART：tf 飽和 + 長度修正 + 機率 idf			Okapi BM25（對照組）	`k1 = 1.2，b = 0.75`	變形	0.656	0.683

MAP、nDCG@10 為 15 題平均、k = 10、含 118 篇人工判讀；粗體為該欄最高。對照實驗每組只改一個字母：RQ1 nnn→lnn、ntn→ltn；RQ2 lnn→ltn、lnc→ltc；RQ3 nnn / btn / ntn / ltn；RQ4 ltn→ltc、nnn→nnc。

A3　① tf 與 ② df 的關係：都取 log，但方向與層級不同

相同：1 + ln tf 與 ln(N / df) 都是「對一個計數取對數」，背後同一個想法：計數加倍，證據不該加倍。

不同：tf 是**局部**量（這篇文件裡的次數），權重隨 tf **遞增**，回答「這篇在講它嗎」；df 是**全域**量（整個語料出現在幾篇），權重隨 df **遞減**，回答「這個詞能區分文件嗎」。兩者各自獨立，所以 SMART 放在不同位置相乘；log tf 把 tf 壓到與 idf 同一量級，idf 的效果才顯現（RQ2）。

附錄 B 評估查詢 q01–q15：怎麼定義、怎麼在網頁上重現、怎麼讀數據

定義方式　每題 = 查詢文字 + 設計意圖 + 相關規則。規則由一到兩個「概念群」組成，每群是一組 MeSH 標題 / 作者關鍵詞的正則表示式；一篇文件的標籤把**每一群**都命中才算相關，命中的是 MeSH major topic 給 grade 2、否則 grade 1。規則只看標籤、不看標題摘要正文，所以不偏向任何 weighting。再以六種 scheme（nnn、lnn、btn、ltn、ltc、bm25）各取前 10 名做 pooling，規則判 0 的 118 篇逐篇人工判讀，補回 37 篇漏標的相關文件（「人工」欄）。

id	查詢文字 / 設計意圖	相關規則（概念群；全部群都命中 → 相關）	相關 g2 / g1	MeSH / 關鍵詞 / 人工	AP nnn	AP ltn	AP bm25	P@10 ltn	R@10 ltn
q01	**semaglutide weight loss in obesity** 藥 + 病況，兩者在語料都常見	(semaglutide | wegovy | ozempic) AND (obes | overweight | weight loss …)	318 189/129	232/85/4	0.45	0.60	**0.61**	1.0	0.03
q02	**tirzepatide glycemic control in type 2 diabetes** 藥 + 病況；diabetes 是最常見詞之一（idf 低）	(tirzepatide | mounjaro | zepbound) AND (diabetes mellitus, type 2 | type 2 diabetes | t2dm? …)	131 82/49	97/32/16	0.15	**0.35**	0.34	0.8	0.06
q03	**GLP-1 receptor agonists and cardiovascular outcomes** 語料主題本身 + 結果；藥類詞幾乎沒有 idf	(glp-?1 ?r | glucagon-like peptide-?1 receptor agonist | incretin …) AND (cardiovascular | heart failure | myocardial …)	263 160/103	163/95/16	0.19	0.53	**0.55**	0.9	0.03
q04	**chronic kidney disease and diabetic nephropathy** 一個概念、多種寫法（CKD、renal insufficiency、DKD）	(renal insufficiency, chronic | chronic kidney | diabetic nephropath …)	198 91/107	109/86/6	0.50	**0.70**	0.66	1.0	0.05
q05	**gut microbiota and bile acid metabolism** 機制主題，多為動物實驗	(gastrointestinal microbiome | gut microbio | microbiota …)	132 48/84	69/61/2	0.70	**0.88**	0.86	1.0	0.08
q06	**fatty liver disease MASLD NAFLD steatohepatitis** 近年改名的主題（NAFLD → MASLD），同義詞多	(fatty liver | non-alcoholic | nonalcoholic …)	124 66/58	68/55/2	0.65	0.84	**0.85**	1.0	0.08
q07	**neuroprotection in Alzheimer's and Parkinson's disease** 神經主題；罕見、高 idf 詞	(alzheimer | parkinson | neurodegenerat …)	143 66/77	71/72/0	0.53	0.72	**0.72**	1.0	0.07
q08	**bariatric surgery versus medication for weight loss** 手術 vs 藥物的比較	(bariatric | gastric bypass | sleeve gastrectomy …)	139 66/73	81/57/5	0.37	0.82	**0.84**	1.0	0.07
q09	**gastrointestinal adverse events nausea vomiting** 安全性主題；查詢詞在摘要裡很常見，標籤只標以此為主題的文章	(nausea | vomiting | gastroparesis …)	68 26/42	32/29/19	0.18	0.31	**0.31**	0.8	0.12
q10	**polycystic ovary syndrome** 小而明確的主題（PCOS）	(polycystic ovar | pcos)	45 19/26	26/18/8	0.65	0.88	**0.91**	1.0	0.22
q11	**SGLT2 inhibitors combination therapy** 第二種藥類與 GLP-1 RA 併用	(sodium-glucose (co-?)? transporter | sglt-?2 | sglt2i …)	262 107/155	156/104/3	0.51	**0.61**	0.59	1.0	0.04
q12	**insulin secretion from pancreatic beta cells** 生理主題；insulin 常見、beta cell 專一	(insulin-secreting cells | beta[-]?cell | β[-]?cell …)	102 56/46	66/32/8	0.49	**0.57**	0.53	1.0	0.10
q13	**obstructive sleep apnea treatment** 新適應症（tirzepatide 治 OSA）	(sleep apnea | sleep apnoea | osa)	46 20/26	20/22/8	0.63	**0.92**	0.88	1.0	0.22
q14	**cost-effectiveness and health economics** 經濟研究：標籤專一、用詞通用	(cost-benefit | cost-effective | cost effective …)	30 14/16	20/6/6	0.66	**0.82**	0.78	1.0	0.33
q15	**type 1 diabetes adjunct therapy** 第 1 型 vs 常見得多的第 2 型：只差一個 token	(diabetes mellitus, type 1 | type 1 diabetes | t1dm? …)	51 34/17	36/15/15	0.11	0.36	**0.41**	0.9	0.18

AP 粗體 = 該題三者最高。R@10 受相關集大小封頂：q01 有 318 篇，前 10 名全對也只有 10/318 = 0.03；q14 只有 30 篇，10 篇對就是 0.33。R@k 只在同一題內比 scheme，跨題看 AP、nDCG。

在網頁上重現（/#vsm）

- **第 5 節 查詢表**：本表前五欄的來源。每列的「relevant set」列出該題全部相關文件、等級、命中的標籤與在所選 scheme 下的名次；「search」把查詢帶到第 3 節。
- **第 3 節 搜尋**：點 q01–q15 或自行輸入，選 Doc scheme 看前 k 名。每筆標 rel 1 / rel 2，長條是各查詢詞的貢獻 w(t,q)×w(t,d)；按 0 / 1 / 2 當場修改人工判讀。
- **第 4 節 對照實驗**：填入查詢、按 RQ1–RQ4 按鈕，一次只改一個字母；得 overlap@10、Kendall τ、平均長度、P@5 / P@10 / R@10 / AP / nDCG@10，下方並排各 scheme 的前 10 名（綠 = 相關）。
- **第 5 節 Evaluate → 第 6 節**：勾選 scheme、k、condensed，得 15 題平均表、2×2×2 因素格、逐題表；第 6 節的 RQ 結論由這些數字即時生成。

怎麼讀數據

- **P@k**：前 k 名裡相關的比例；與相關集大小無關，相關集大的題容易拿 1.0。
- **R@k**：前 k 名找回了相關集的幾分之幾，被相關集大小封頂（見上註）。
- **RR / MRR**：第一篇相關文件名次的倒數；1.0 = 第 1 名就相關。
- **AP / MAP**：每找到一篇相關文件就量一次 precision 再平均，相關文件排得愈前愈高；跨題、跨 scheme 比較的主指標。
- **nDCG@10**：分級版，grade 2 比 grade 1 值錢，名次愈後折扣愈重；grade 2 排在前面才高。
- **overlap@10 / Kendall τ**：兩個 scheme 前 10 名的交集比例與名次一致性；τ ≈ 0 表示榜單幾乎重排。
- **mean length**：前 10 名平均索引詞數（全集合 211）；偏高 = 偏好長文件（RQ4）。
- **讀表範例**：q03 AP nnn 0.19 → ltn 0.53，是 idf 把 cardiovascular 拉過 glp / receptor / agonist（RQ2）；q09 三者都只有 0.31，nausea、vomiting 幾乎每篇試驗都提到，標籤卻只標以此為主題的文章，是文字訊號與標籤分歧最大的一題；q15 ltc 0.44 > ltn 0.36，短查詢在正規化後較不被長文件淹沒；q14 是唯一 log tf 沒幫上的題（0.65 對 0.66）。