AI INFORMATION RETRIEVAL（人工智慧資訊檢索）· PROJECT #3 TERM WEIGHTING / TF-IDF

胡元楨（P77141105）· 純 Python 標準函式庫自行實作：`ir/tfidf.py`（SMART tf・df・norm 權重、向量空間、cosine 排名）、`ir/evaluation.py`（P@k、R@k、MRR、MAP、nDCG）、`ir/relevance.py`（MeSH / 關鍵詞相關性判斷）；介面分頁「TF-IDF 檢索」，CLI `cli.py vsm …`；完整報告 `REPORT_tfidf.md`

3,000 PubMed 摘要（GLP-1，含 MeSH）；平均 211 索引詞（24–672）

15,823 詞幹；45% 只出現在 1 篇（idf 8.01），42 個詞出現在 ≥ 1,000 篇

12 weighting schemes：nnn、lnn、btn、ntn、ltn、nnc、lnc、ntc、ltc、atc、lpc + BM25

15 評估查詢；相關集由 MeSH / 關鍵詞規則 + 118 篇人工判讀產生（30–318 篇）

0.661 最佳 MAP：ltn（log TF × IDF）；raw TF 0.451

0.65 ms 一次查詢（倒排權重向量）；19 個單元測試

RQ1 原始 TF 與 Log TF 的差異，如何影響詞項權重？

tf	1	2	5	10	30	50
raw tf	1	2	5	10	30	50
1 + ln tf	1.00	1.69	2.61	3.30	4.40	4.91

raw tf 讓出現 30 次的詞是出現 1 次的 30 倍，log 只給 4.4 倍。一篇 FLOW 試驗摘要（422 索引詞、max tf 38）在 `nnn` 下由小數的「0」（tf 38）主宰、前 5 詞佔向量 22.5%；`lnn` 壓到 7.8%。檢索上 raw → log 是效果最大的單一改動：MAP **0.451 → 0.574**（+27%，15 題全部提高）、nDCG@10 0.545 → 0.656、MRR 0.791 → 0.933；q01 前 10 名平均長度 339 → 275（raw tf 偏好能重複同一詞的長文件）。**詞頻增加，重要性不等比例增加。**

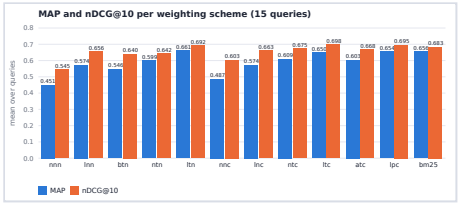
RQ2 為什麼 IDF 能降低常見詞的重要性、提高具辨識力詞項的權重？

term	df	df/N	idf
glp · receptor · agonist	2,333–2,422	78–81%	**0.21–0.25**
diabet · obes	1,617 · 1,429	54 · 48%	0.62 · 0.74
semaglutid · tirzepatid	714 · 440	24 · 15%	1.44 · 1.92
cardiovascular	679	23%	1.49
apnea · pco(s)	63 · 36	2 · 1%	**3.86 · 4.42**

idf = ln(N/df) 隨 df 單調下降（df 1 → 8.01，1,000 → 1.10，N → 0）。出現在八成文件的詞對「這篇 vs 那篇」沒有資訊：對每篇都加同樣分數不改變排名，只讓分數被它的 tf 噪音淹沒。 q03「GLP-1 receptor agonists and cardiovascular outcomes」沒有 idf 時排名由 glp/receptor/agonist 重複最多的文件決定（腎臟、酒精、脫髮…，P@10 0.60）；有 idf 後 cardiovascular 的權重是 glp 的 6 倍，前 10 名有 9 篇心血管結果（nDCG@10 0.479 → 0.866）。整體 lnn → ltn MAP **0.574 → 0.661**（+15%，15 題全部提高）；只用 idf（btn，忽略 tf）仍有 0.546：短文本裡「有無出現」幾乎與「出現幾次」同樣重要。

RQ3 · RQ5 TF-IDF 是否產生較好的排名？不同 weighting 對各指標的影響

scheme	P@5	P@10	R@20	MRR	MAP	nDCG@10	R-prec
nnn raw TF	0.773	0.760	0.158	0.791	0.451	0.545	0.449
lnn log TF	0.947	0.900	0.192	0.933	0.574	0.656	0.553
btn IDF only	0.840	0.787	0.166	0.922	0.546	0.640	0.562
ntn raw TF × IDF	0.907	0.880	0.195	0.933	0.599	0.642	0.574
ltn log TF × IDF	0.960	**0.960**	**0.205**	0.933	**0.661**	0.692	**0.634**
nnc raw TF, L2	0.880	0.827	0.180	0.883	0.487	0.603	0.477
lnc log TF, L2	0.920	0.873	0.196	0.967	0.574	0.663	0.553
ntc raw TF × IDF, L2	0.933	0.920	0.199	0.967	0.609	0.675	0.585
ltc log TF × IDF, L2	0.960	0.940	**0.205**	0.956	0.650	**0.698**	0.622
atc augmented TF × IDF, L2	0.880	0.873	0.181	**1.000**	0.603	0.668	0.588
lpc log TF × prob IDF, L2	0.947	0.947	0.201	0.967	0.654	0.695	0.622
bm25（參考）	**0.973**	**0.960**	**0.205**	0.967	0.656	0.683	0.619

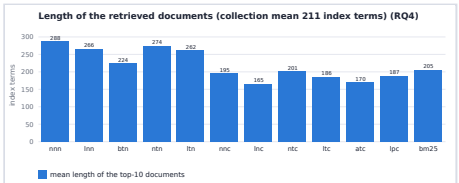


15 個查詢的平均 MAP 與 nDCG@10，含人工判讀（`cli.py vsm eval`、`vsm svg`）。

RQ3 是：MAP raw TF 0.451 → log TF 0.574 → IDF only 0.546 → TF-IDF（ltn）**0.661**；逐題 AP 上 ltn 15/15 勝 raw TF、IDF-only 與 log TF；nDCG@10 前三名 ltc / lpc / ltn 全是 TF × IDF。因素格（MAP）：log +0.06～0.12、idf +0.08～0.15、L2 −0.01～+0.04。 **RQ5** raw TF 在所有指標最差；log TF × IDF（ltn / ltc / lpc）在所有指標前四；但「最佳」隨指標與查詢改變——MAP 選 ltn、nDCG@10 選 ltc（0.698）、P@5 / R@k 選 BM25、MRR 選 atc（1.000）；q04 偏好 raw TF（nDCG 0.815 vs 0.645）、q15 偏好正規化（lnc 1.000）、q09 全部都差（副作用詞幾乎每篇試驗都提到，只有「以此為主題」者算相關）。結論須結合查詢、資料集與指標。

RQ4 文件向量是否需要 L2 normalization？正規化前後的排名有何差異？

q10「polycystic ovary syndrome」	overlap@10	τ	mean len	P@10	nDCG@10
ltn log TF × IDF	1.00	1.00	230	1.00	0.775
ltc + L2	0.60	−0.17	165	1.00	0.528
nnn raw TF	0.50	0.09	215	0.70	0.609
nnc + L2	0.30	−0.32	152	0.80	0.525



各 scheme 前 10 名的平均長度（15 題平均）：未正規化 224–288，正規化 165–201，BM25 205。

未正規化的內積 = ‖d‖ · cos θ：長文件多提幾次就贏；正規化後只比方向。兩者排名差異很大（15 題平均 ltn vs ltc 前 10 名重疊 **48%**、τ ≈ 0；前 10 名平均長度 262 → 186），但本集合全是長度相近的摘要（平均 211、相關文件 217），正規化收益小且方向不一（MAP 0.661 → 0.650，僅 6/15 題變好；MRR、nDCG@10 略升；raw tf 則 0.451 → 0.487 受益），而 30 個詞的更正啟事（*Correction: …*）因為沒有其他詞稀釋，在 ltc 下竄到第一名。 長度懸殊時正規化不可或缺：把 3 篇 PMC 全文（3,221–4,358 詞）混進 1,003 篇摘要，10 題前 10 名的 100 個位置中 nnn 有 15、ltn 有 9 個被長文佔走，nnc / ltc / BM25 為 0（`report/rq4_mixed_lengths.py`）。BM25 的部分正規化（b = 0.75）兩種情況都最好：問題是「正規化多少」。

方法與限制 相關性判斷

資料集沒有現成標籤，依作業指示用**主題標籤**：每個查詢定義若干概念群（正規表示式），文件的每一群至少命中一個 MeSH 標題或作者關鍵詞即相關，命中 major-topic MeSH 為 grade 2；只看標籤不看文字，故不偏向任何 weighting，並可在介面手動覆寫。為補標籤漏標，對每題把六個 scheme 的前 10 名 pooling，規則判 0 的 **118 篇**由作者讀摘要逐篇判定：37 篇補為相關（q03 心血管試驗 5、q09 副作用主題 7、q13 / q14 無標籤的 OSA 試驗與成本效益分析各 4）、81 篇確認不相關；各指標上升 0.03–0.11，結論方向不變。限制：163 篇（5.4%）無任何標籤（condensed-list 評估排序不變）；57% 有 MeSH；規則與人工判讀皆由作者一人完成，且只判讀了前 10 名；相關集偏大（30–318）、R@k 絕對值低。另一觀察：純數字 token（佔詞彙 11.5%）df 小、idf 高，會混入 ltn 向量前列；移除數字是最直接的 modified TF-IDF。