胡元楨（P77141105）

3,000	15,823	2×2×2 + 3	15	0.661	118
PubMed 摘要（GLP-1，含 MeSH）；平均 211 索引詞（24–672）	詞幹；45% 只出現在 1 篇（idf 8.01），42 個詞出現在 ≥ 1,000 篇	因素設計：tf raw/log × idf 有/無 × L2 有/無 = 8 種；另加 btn、atc、lpc 三個變形	評估查詢；相關集由 MeSH / 關鍵詞規則 + 118 篇人工判讀產生（30–318 篇）	最佳 MAP：ltn（log TF × IDF）；raw TF 0.451	篇 AI 助理判讀（作者未複核），補回 37 篇漏標的相關文件；指標高 0.03–0.11，排序不變

權重代號怎麼讀　SMART 三字母依位置：**l** ①tf　**t** ②df　**c** ③正規化　① tf：**n** 原始次數 · **l** 1+ln tf · **a** 增強 · **b** 布林　② df：**n** 不乘 · **t** idf · **p** 機率 idf　③ 正規化：**n** 無 · **c** cosine　例：`nnn` 原始 tf、`lnn` log tf、`ltn` log tf × idf、`ltc` 再加 cosine（完整對照表：第 2 頁附錄）

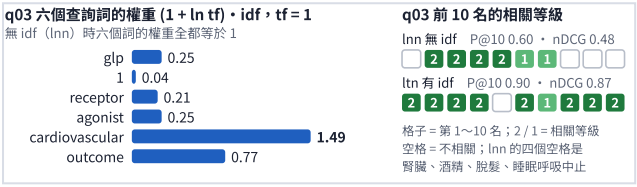
RQ1 原始 TF 與 Log TF 的差異，如何影響詞項權重？

tf	1	2	5	10	30	50
raw tf	1	2	5	10	30	50
1 + ln tf	1.00	1.69	2.61	3.30	4.40	4.91

- **例子**：FLOW 試驗摘要提到 semaglutide 7 次、cardiovascular 13 次。raw tf 說後者重要近兩倍；log 給 2.95 對 3.56、只差兩成，較接近人的判斷。
- **機制**：log 的加分逐次遞減（第 2 次 +0.69、第 30 次 +0.03），單一詞無法獨占向量：原始 tf 下（`nnn`）同篇由出現 38 次的「0」主宰、前 5 詞佔 22.5%；log tf（`lnn`）壓到 7.8%。
- **長文不公平**：文件愈長 tf 愈大，raw tf 等於替長文加分；q01 前 10 名平均長度 339 → 275（全集合 211）。
- **效果**：最有效的單一改動，MAP **0.451 → 0.574**（+27%，14/15 題提高）；壓平後 tf 與 idf 同量級，RQ2 的 idf 才量得出來。
- **結論**：詞頻增加，重要性不等比例增加。

RQ2 為什麼 IDF 能降低常見詞的重要性、提高具辨識力詞項的權重？

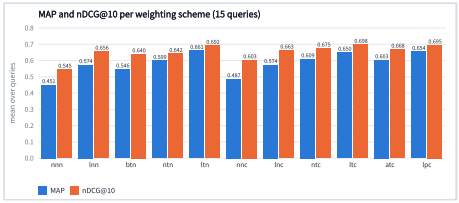
例題 q03「GLP-1 receptor agonists and cardiovascular outcomes」



- **變因**：固定 log tf，只在第 ② 位乘 idf：lnn → ltn、lnc → ltc。
- **機制**：idf 隨 df 遞減（df 1 → 8.01，N → 0）；出現在八成文件的 glp / receptor / agonist 每篇都加一樣，不改排名，只剩 tf 噪音。
- **效果**：q03 前 10 名相關 6 → 9 篇（左圖，nDCG@10 0.479 → 0.866）；整體 MAP **0.574 → 0.661**（+15%，15/15 題提高），lnc → ltc 0.574 → 0.650；只用 idf 的 btn 也有 0.546。
- **結論**：決定權從「常見詞重複幾次」移到「稀有詞有沒有出現」；短摘要裡有無出現幾乎與出現幾次同樣重要。

RQ3 · RQ5 TF-IDF 是否產生較好的排名？不同 weighting 對各指標的影響

scheme		P@5	P@10	R@20	MRR	MAP	nDCG@10	R-prec
`nnn`	raw TF	0.773	0.760	0.158	0.791	0.451	0.545	0.449
`lnn`	log TF	0.947	0.900	0.192	0.933	0.574	0.656	0.553
`btn`	IDF only	0.840	0.787	0.166	0.922	0.546	0.640	0.562
`ntn`	raw TF × IDF	0.907	0.880	0.195	0.933	0.599	0.642	0.574
`ltn`	log TF × IDF	**0.960**	**0.960**	**0.205**	0.933	**0.661**	0.692	**0.634**
`nnc`	raw TF, L2	0.880	0.827	0.180	0.883	0.487	0.603	0.477
`lnc`	log TF, L2	0.920	0.873	0.196	0.967	0.574	0.663	0.553
`ntc`	raw TF × IDF, L2	0.933	0.920	0.199	0.967	0.609	0.675	0.585
`ltc`	log TF × IDF, L2	**0.960**	0.940	**0.205**	0.956	0.650	**0.698**	0.622
`atc`	augmented TF × IDF, L2	0.880	0.873	0.181	**1.000**	0.603	0.668	0.588
`lpc`	log TF × prob IDF, L2	0.947	0.947	0.201	0.967	0.654	0.695	0.622

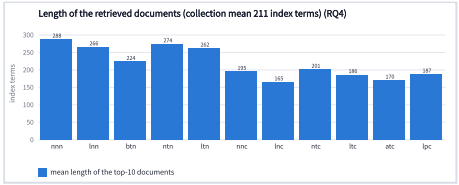


15 個查詢的平均 MAP 與 nDCG@10，含人工判讀（`cli.py vsm eval`、`vsm svg`）。

- **變因**：查詢端固定 nnc，文件端跑完 2×2×2 + 3 共 11 種 scheme，用 P@k、R@k、MRR、MAP、R-prec、nDCG@k 在 15 題上平均比較。
- **機制**：log 壓重複（RQ1）、idf 壓常見（RQ2）、L2 壓長度（RQ4）；MAP 看整條排名，P@k / MRR / nDCG@k 只看榜首，所以同一改動對不同指標的影響不同。
- **效果 RQ3**：MAP raw TF 0.451 → log TF 0.574 → IDF only 0.546 → TF-IDF（ltn）**0.661**，逐題 AP ltn 15/15 勝前三者；nDCG@10 前三名 ltc / lpc / ltn 全是 TF × IDF。
- **效果 RQ5**：**log tf 與 idf 對每個指標都是正向**，對 MAP 與 P@10 最大（log +0.12 / +0.14，idf +0.09 / +0.06）。**L2 看指標**：MRR 與 nDCG@10 上升（ltn → ltc 0.933 → 0.956、0.692 → 0.698；nnn → nnc 0.791 → 0.883、0.545 → 0.603），MAP 與 P@10 在 log × idf 上略降（0.661 → 0.650、0.960 → 0.940）。**MRR 最不敏感**：只要有 log 或 idf 就 0.92–1.00，只剩 raw TF 的 0.79。**R@k** 被相關集封頂、方向同 P@k。
- **結論**：TF-IDF 確實較好（RQ3）。RQ5：log 與 idf 全面有利，L2 只利於榜首指標，故 MAP / R-prec 選 ltn、nDCG@10 選 ltc、P@5 / R@20 ltn 與 ltc 並列、MRR 選 atc（1.000）；逐題仍有例外（q04 偏好 raw TF、q15 偏好正規化、q09 全差）。

RQ4 文件向量是否需要 L2 normalization？正規化前後的排名有何差異？

q10「polycystic ovary syndrome」	overlap@10	τ	mean len	P@10	nDCG@10
ltn log TF × IDF	1.00	1.00	230	1.00	0.775
ltc + L2	0.60	−0.17	165	1.00	0.528
nnn raw TF	0.50	0.09	215	0.70	0.609
nnc + L2	0.30	−0.32	152	0.80	0.525



各 scheme 前 10 名的平均長度（15 題平均）：未正規化 224–288，正規化 165–201。

- **變因**：固定 log tf × idf，只改第 ③ 位：ltn → ltc（raw tf 的 nnn → nnc 為對照）。
- **機制**：未正規化的內積 = ‖ d ‖ · cos θ，長文件多提幾次就贏；除以向量長度後只比方向。15 題平均 ltn 與 ltc 前 10 名只重疊 **48%**、τ ≈ 0，前 10 名平均長度 262 → 186。
- **效果**：本集合全是長度相近的摘要（平均 211、相關文件 217），收益小且方向不一：MAP 0.661 → 0.650，僅 6/15 題變好，MRR、nDCG@10 略升；raw tf 受益 0.451 → 0.487；30 個詞的更正啟事（*Correction:* …）在 ltc 下竄到第一名。混入 3 篇 PMC 全文（3,221–4,358 詞）後，10 題前 10 名的 100 個位置 nnn 被長文佔走 15 個、ltn 9 個，nnc / ltc 為 0（`report/rq4_mixed_lengths.py`）。
- **結論**：長度相近時可不正規化，長度懸殊時不可或缺；兩種情況的贏家不同，真正的問題是「正規化多少」，介於 n 與 c 之間的部分正規化是後續方向。

相關判斷的方法與限制（標籤規則、pooling 與 118 篇人工判讀、無標籤文件、數字 token）見第 5 頁附錄 D0；各題定義見附錄 B。

附錄 A SMART 權重代號對照表（tf · df · norm）

每個 weighting scheme 是三個字母，**依位置讀**：第 1 字母是 tf 怎麼算、第 2 字母是 df 怎麼用、第 3 字母是正規化。三個因素獨立，權重 = ① × ② 再做 ③，查詢端全程固定為 `nnc`（原始 tf、不乘 idf、cosine）。

l **t** **c** → `ltc` = (1 + ln tf) × ln(N / df)，再除以向量長度（cosine）。同理 `nnn` = 原始 tf、不乘 idf、不正規化。

① tf　② df　③ norm

A1　三個位置各自可填的字母

位置	字	名稱	公式	直覺 / 用意	本報告用到的 scheme
① tf 詞在這篇出現幾次（局部）	n	natural	`tf`	出現幾次算幾分；高頻詞獨占向量、偏好長文件（RQ1）	`nnn ntn nnc ntc`
	l	logarithm	`1 + ln tf`	加分逐次遞減：tf 30 只得 4.4、不是 30（RQ1）	`lnn ltn lnc ltc lpc`
	a	augmented	`0.5 + 0.5 · tf / max tf`	以該篇最大 tf 為基準，另一種壓平長文件的方法	`atc`
	b	boolean	`1`	只看有沒有出現，忽略次數	`btn`
② df 詞出現在幾篇文件（全域）	n	none	`1`	不管詞多常見	`nnn lnn nnc lnc`
	t	idf	`ln(N / df)`	常見詞降權、稀有詞升權：df 1,172 → 0.94，df 29 → 4.64（RQ2）	`btn ntn ltn ntc ltc atc`
	p	prob idf	`max(0, ln((N − df) / df))`	出現超過一半文件的詞權重直接歸 0	`lpc`
③ norm 向量要不要正規化	n	none	`w`	分數 = 內積；長文件向量長、分數高（RQ4）	`nnn lnn btn ntn ltn`
	c	cosine	`w / ‖d‖`	除以向量長度，分數 = cosine 相似度，長度不再有利（RQ4）	`nnc lnc ntc ltc atc lpc`

A2　本報告的 12 個 scheme

代號	① tf	② df	③ norm	白話	公式	用在	MAP	nDCG@10
`nnn`	n 原始	n 無	n 無	raw TF	`tf`	RQ1 RQ3 RQ4	0.451	0.545
`lnn`	l 對數	n 無	n 無	log TF	`1 + ln tf`	RQ1 RQ2	0.574	0.656
`btn`	b 布林	t idf	n 無	IDF only	`idf`	RQ3	0.546	0.640
`ntn`	n 原始	t idf	n 無	raw TF × IDF	`tf · idf`	RQ1 RQ3	0.599	0.642
`ltn`	l 對數	t idf	n 無	log TF × IDF	`(1 + ln tf) · idf`	RQ1–RQ4	**0.661**	0.692
`nnc`	n 原始	n 無	c cosine	raw TF, L2	`tf / ‖d‖`	RQ4	0.487	0.603
`lnc`	l 對數	n 無	c cosine	log TF, L2	`(1 + ln tf) / ‖d‖`	RQ2	0.574	0.663
`ntc`	n 原始	t idf	c cosine	raw TF × IDF, L2	`tf · idf / ‖d‖`	因素格	0.609	0.675
`ltc`	l 對數	t idf	c cosine	log TF × IDF, L2（教科書標準）	`(1 + ln tf) · idf / ‖d‖`	RQ2 RQ4 變形	0.650	**0.698**
`atc`	a 增強	t idf	c cosine	augmented TF × IDF, L2	`(0.5 + 0.5 tf / max tf) · idf / ‖d‖`	變形	0.603	0.668
`lpc`	l 對數	p 機率 idf	c cosine	log TF × prob IDF, L2	`(1 + ln tf) · max(0, ln((N − df) / df)) / ‖d‖`	變形	0.654	0.695
`bm25`	不屬於 SMART：tf 飽和 + 長度修正 + 機率 idf			Okapi BM25（對照組）	`k1 = 1.2，b = 0.75`	變形	0.656	0.683

MAP、nDCG@10 為 15 題平均、k = 10、含 118 篇人工判讀；粗體為該欄最高。對照實驗每組只改一個字母：RQ1 nnn→lnn、ntn→ltn；RQ2 lnn→ltn、lnc→ltc；RQ3 nnn / btn / ntn / ltn；RQ4 ltn→ltc、nnn→nnc。

A3　① tf 與 ② df 的關係：都取 log，但方向與層級不同

相同：1 + ln tf 與 ln(N / df) 都是「對一個計數取對數」，背後同一個想法：計數加倍，證據不該加倍。

不同：tf 是**局部**量（這篇文件裡的次數），權重隨 tf **遞增**，回答「這篇在講它嗎」；df 是**全域**量（整個語料出現在幾篇），權重隨 df **遞減**，回答「這個詞能區分文件嗎」。兩者各自獨立，所以 SMART 放在不同位置相乘；log tf 把 tf 壓到與 idf 同一量級，idf 的效果才顯現（RQ2）。

附錄 B 評估查詢 q01–q15：怎麼定義、怎麼在網頁上重現、怎麼讀數據

定義方式　每題 = 查詢文字 + 設計意圖 + 相關規則。規則由一到兩個「概念群」組成，每群是一組 MeSH 標題 / 作者關鍵詞的正則表示式；一篇文件的標籤把**每一群**都命中才算相關，命中的是 MeSH major topic 給 grade 2、否則 grade 1。規則只看標籤、不看標題摘要正文，所以不偏向任何 weighting。再以六種 scheme（nnn、lnn、btn、ltn、ltc、bm25）各取前 10 名做 pooling，規則判 0 的 118 篇由 AI 助理逐篇讀標題與摘要判讀（作者未逐篇複核），補回 37 篇漏標的相關文件（「人工」欄）。

id	查詢文字 / 設計意圖	相關規則（概念群；全部群都命中 → 相關）	相關 g2 / g1	MeSH / 關鍵詞 / 人工	AP nnn	AP ltn	AP bm25	P@10 ltn	R@10 ltn
q01	**semaglutide weight loss in obesity** 藥 + 病況，兩者在語料都常見	(semaglutide | wegovy | ozempic) AND (obes | overweight | weight loss …)	318 189/129	232/85/4	0.45	0.60	**0.61**	1.0	0.03
q02	**tirzepatide glycemic control in type 2 diabetes** 藥 + 病況；diabetes 是最常見詞之一（idf 低）	(tirzepatide | mounjaro | zepbound) AND (diabetes mellitus, type 2 | type 2 diabetes | t2dm? …)	131 82/49	97/32/16	0.15	**0.35**	0.34	0.8	0.06
q03	**GLP-1 receptor agonists and cardiovascular outcomes** 語料主題本身 + 結果；藥類詞幾乎沒有 idf	(glp-?1 ?r | glucagon-like peptide-?1 receptor agonist | incretin …) AND (cardiovascular | heart failure | myocardial …)	263 160/103	163/95/16	0.19	0.53	**0.55**	0.9	0.03
q04	**chronic kidney disease and diabetic nephropathy** 一個概念、多種寫法（CKD、renal insufficiency、DKD）	(renal insufficiency, chronic | chronic kidney | diabetic nephropath …)	198 91/107	109/86/6	0.50	**0.70**	0.66	1.0	0.05
q05	**gut microbiota and bile acid metabolism** 機制主題，多為動物實驗	(gastrointestinal microbiome | gut microbio | microbiota …)	132 48/84	69/61/2	0.70	**0.88**	0.86	1.0	0.08
q06	**fatty liver disease MASLD NAFLD steatohepatitis** 近年改名的主題（NAFLD → MASLD），同義詞多	(fatty liver | non-alcoholic | nonalcoholic …)	124 66/58	68/55/2	0.65	0.84	**0.85**	1.0	0.08
q07	**neuroprotection in Alzheimer's and Parkinson's disease** 神經主題；罕見、高 idf 詞	(alzheimer | parkinson | neurodegenerat …)	143 66/77	71/72/0	0.53	0.72	**0.72**	1.0	0.07
q08	**bariatric surgery versus medication for weight loss** 手術 vs 藥物的比較	(bariatric | gastric bypass | sleeve gastrectomy …)	139 66/73	81/57/5	0.37	0.82	**0.84**	1.0	0.07
q09	**gastrointestinal adverse events nausea vomiting** 安全性主題；查詢詞在摘要裡很常見，標籤只標以此為主題的文章	(nausea | vomiting | gastroparesis …)	68 26/42	32/29/19	0.18	0.31	**0.31**	0.8	0.12
q10	**polycystic ovary syndrome** 小而明確的主題（PCOS）	(polycystic ovar | pcos)	45 19/26	26/18/8	0.65	0.88	**0.91**	1.0	0.22
q11	**SGLT2 inhibitors combination therapy** 第二種藥類與 GLP-1 RA 併用	(sodium-glucose (co-?)? transporter | sglt-?2 | sglt2i …)	262 107/155	156/104/3	0.51	**0.61**	0.59	1.0	0.04
q12	**insulin secretion from pancreatic beta cells** 生理主題；insulin 常見、beta cell 專一	(insulin-secreting cells | beta[-]?cell | β[-]?cell …)	102 56/46	66/32/8	0.49	**0.57**	0.53	1.0	0.10
q13	**obstructive sleep apnea treatment** 新適應症（tirzepatide 治 OSA）	(sleep apnea | sleep apnoea | osa)	46 20/26	20/22/8	0.63	**0.92**	0.88	1.0	0.22
q14	**cost-effectiveness and health economics** 經濟研究：標籤專一、用詞通用	(cost-benefit | cost-effective | cost effective …)	30 14/16	20/6/6	0.66	**0.82**	0.78	1.0	0.33
q15	**type 1 diabetes adjunct therapy** 第 1 型 vs 常見得多的第 2 型：只差一個 token	(diabetes mellitus, type 1 | type 1 diabetes | t1dm? …)	51 34/17	36/15/15	0.11	0.36	**0.41**	0.9	0.18

AP 粗體 = 該題三者最高。R@10 受相關集大小封頂：q01 有 318 篇，前 10 名全對也只有 10/318 = 0.03；q14 只有 30 篇，10 篇對就是 0.33。R@k 只在同一題內比 scheme，跨題看 AP、nDCG。

在網頁上重現（/#vsm）

- **第 5 節 查詢表**：本表前五欄的來源。每列的「relevant set」列出該題全部相關文件、等級、命中的標籤與在所選 scheme 下的名次；「search」把查詢帶到第 3 節。
- **第 3 節 搜尋**：點 q01–q15 或自行輸入，選 Doc scheme 看前 k 名。每筆標 rel 1 / rel 2，長條是各查詢詞的貢獻 w(t,q)×w(t,d)；按 0 / 1 / 2 當場修改人工判讀。
- **第 4 節 對照實驗**：填入查詢、按 RQ1–RQ4 按鈕，一次只改一個字母；得 overlap@10、Kendall τ、平均長度、P@5 / P@10 / R@10 / AP / nDCG@10，下方並排各 scheme 的前 10 名（綠 = 相關）。
- **第 5 節 Evaluate → 第 6 節**：勾選 scheme、k、condensed，得 15 題平均表、2×2×2 因素格、逐題表；第 6 節的 RQ 結論由這些數字即時生成。

怎麼讀數據

- **P@k**：前 k 名裡相關的比例；與相關集大小無關，相關集大的題容易拿 1.0。
- **R@k**：前 k 名找回了相關集的幾分之幾，被相關集大小封頂（見上註）。
- **RR / MRR**：第一篇相關文件名次的倒數；1.0 = 第 1 名就相關。
- **AP / MAP**：每找到一篇相關文件就量一次 precision 再平均，相關文件排得愈前愈高；跨題、跨 scheme 比較的主指標。
- **nDCG@10**：分級版，grade 2 比 grade 1 值錢，名次愈後折扣愈重；grade 2 排在前面才高。
- **overlap@10 / Kendall τ**：兩個 scheme 前 10 名的交集比例與名次一致性；τ ≈ 0 表示榜單幾乎重排。
- **mean length**：前 10 名平均索引詞數（全集合 211）；偏高 = 偏好長文件（RQ4）。
- **讀表範例**：q03 AP nnn 0.19 → ltn 0.53，是 idf 把 cardiovascular 拉過 glp / receptor / agonist（RQ2）；q09 三者都只有 0.31，nausea、vomiting 幾乎每篇試驗都提到，標籤卻只標以此為主題的文章，是文字訊號與標籤分歧最大的一題；q15 ltc 0.44 > ltn 0.36，短查詢在正規化後較不被長文件淹沒；q14 是唯一 log tf 沒幫上的題（0.65 對 0.66）。

附錄 C 評估 12 種 scheme 用了哪些指標；BM25 怎麼處理資料、最接近哪一種

C1　評估指標一覽（15 題各算一次再平均；「相關」= grade ≥ 1；k 預設 10）

指標	定義	回答的問題	讀法與注意
P@5、P@10、P@20	前 k 名中相關文件的比例	榜首乾不乾淨	與相關集大小無關；相關集大的題容易 1.0。本報告 ltn / bm25 P@10 0.96
R@5、R@10、R@20	前 k 名找回了相關集的幾分之幾	找回了多少	被相關集大小封頂（q01 318 篇 → R@10 ≤ 0.03），只在同一題內比 scheme
RR → MRR	1 / 第一篇相關文件的名次，再平均	第一筆要翻多久	只看一篇；atc 1.000 代表 15 題第 1 名全相關
AP → MAP	每命中一篇相關文件就量一次 precision，加總後除以相關總數（未檢回者貢獻 0）	整條排名的品質	**主指標**：對相關文件排前排後都敏感，也看得到沒找回的。ltn 0.661 最高
R-prec	前 R 名的 precision，R = 該題相關集大小	P 與 R 的交會點	與 MAP 高度相關，做為交叉驗證（ltn 0.634）
nDCG@5 / 10 / 20	$\mathrm{DCG} = \Sigma\,(2^{\mathrm{grade}} - 1) / \log_2(\text{名次} + 1)$，除以理想排序的 DCG	分級相關 + 名次折扣	唯一用到 grade 2 / 1 的指標；grade 2 排在前面才高。ltc 0.698 最高
condensed 版	先移除沒有任何標籤的 163 篇再算上面各項	標籤缺漏的影響	各值略升、scheme 排序不變（ltn 0.661、nnn 0.453）
對照實驗專用	overlap@10（前 10 名交集比例）、Kendall τ（名次一致性）、mean length（前 10 名平均索引詞數）、mean max tf	排名變了多少、往哪邊變	不涉及相關性，純粹比兩個 scheme 的榜單；τ ≈ 0 = 幾乎重排，mean length 對照全集合 211

怎麼選主指標：P@k 只看頭、R@k 被相關集封頂、MRR 只看一篇；MAP 同時反映排序與找回，所以 RQ3 / RQ5 以 MAP 為主、nDCG@10 為輔，其餘供交叉檢查。

C2　BM25 怎麼處理資料

$$\mathrm{score}(q,d) = \Sigma_{t \in q}\ \mathrm{qtf}_t \cdot \mathrm{idf}(t) \cdot \frac{\mathrm{tf} \cdot (k_1 + 1)}{\mathrm{tf} + k_1 \cdot (1 - b + b \cdot |d| / \mathrm{avgdl})}$$

$k_1 = 1.2$，$b = 0.75$，avgdl = 211；$\mathrm{idf}(t) = \ln(1 + (N - \mathrm{df} + 0.5) / (\mathrm{df} + 0.5))$；查詢端用原始 qtf、不正規化

- **tf 飽和**（取代 SMART 第 ① 位）：權重有上限 $k_1 + 1 = 2.2$，壓得比 1 + ln tf 更兇。tf = 1 → 1.00、5 → 1.77、30 → 2.12（log 給 2.61、4.40）；「出現幾次」幾乎退化成「有沒有出現」，接近 b（布林）與 l 之間。
- **長度正規化**（取代第 ③ 位）：分母的 k_1 項乘上 $(1 - b + b \cdot |d|/\mathrm{avgdl})$。b = 0 完全不管長度（= n），b = 1 完全按長度打折；0.75 是「部分正規化」。兩倍長的文件 tf = 5 只剩 1.55，一半長的升到 1.91。它懲罰長度的方式是「同樣的 tf 在長文件裡算少一點」，不是 cosine 的「整支向量除以長度」。
- **機率型 idf**（取代第 ② 位）：$\ln(1 + (N - \mathrm{df} + 0.5)/(\mathrm{df} + 0.5))$ 與 $\ln(N/\mathrm{df})$ 幾乎重合（df 1 → 7.60 vs 8.01，df 100 以上完全相同），且不像 p（prob idf）會把過半文件出現的詞歸 0。

C3　BM25 與哪一種 SMART scheme 最接近

scheme		overlap@10 vs bm25	Kendall τ	前 10 名平均長度	MAP
bm25	**（自身）**	1.00	+1.00	205	0.656
ltn	**log TF × IDF**	**0.63**	**+0.23**	262	0.661
ltc	**log TF × IDF, L2**	0.58	+0.19	186	0.650
lpc	**log TF × prob IDF, L2**	0.56	+0.17	187	0.654
lnc	**log TF, L2**	0.56	+0.14	165	0.574
lnn	**log TF**	0.55	+0.10	266	0.574
atc	**augmented TF × IDF, L2**	0.52	−0.02	170	0.603
ntc	**raw TF × IDF, L2**	0.50	+0.05	201	0.609
ntn	**raw TF × IDF**	0.43	−0.05	274	0.599
nnc	**raw TF, L2**	0.43	−0.01	195	0.487
btn	**IDF only**	0.40	−0.14	224	0.546
nnn	**raw TF**	0.32	−0.19	288	0.451

overlap@10 與 τ 為 15 題平均，以 bm25 的前 10 名為基準。

- **結構上**：BM25 = 飽和 tf × 機率 idf × 部分長度正規化，三個位置分別介於 l 與 b、等於 t、介於 n 與 c 之間，所以它落在 **ltn 與 ltc 之間**。
- **實測上**：排名最像 ltn（overlap 0.63、τ +0.23），其次 ltc；前 10 名平均長度 205 正好夾在 ltn 262 與 ltc 186 之間，MAP 0.656 也夾在 0.661 與 0.650 之間。
- **離它最遠**的是 nnn（overlap 0.32、τ −0.19）：BM25 把 tf 飽和得最徹底，而 nnn 完全不壓 tf。
- **意義**：BM25 在此沒有贏過調好的 TF-IDF，價值在用一組參數同時處理飽和、idf、長度三件事；b = 0.75 在摘要與全文混合時最穩。

附錄 D NLM 的 MeSH 索引現在怎麼做、可靠嗎、對本報告的相關判斷有什麼影響

D0　本報告的相關判斷：方法與限制

資料集沒有現成標籤，依作業指示用**主題標籤**：每個查詢定義若干概念群（正規表示式），文件的每一群至少命中一個 MeSH 標題或作者關鍵詞即相關，命中 major-topic MeSH 為 grade 2；只看標籤不看文字，故不偏向任何 weighting，並可在介面手動覆寫。為補標籤漏標，對每題把六個 scheme 的前 10 名 pooling，規則判 0 的 **118 篇**由 AI 助理（Claude）讀標題與摘要逐篇判定：37 篇補為相關、81 篇確認不相關（逐題見附錄 B；清單在 `docs/manual_judgements_review.md`，作者尚未逐篇複核）；各指標上升 0.03–0.11，結論方向不變。限制：163 篇（5.4%）無任何標籤；57% 有 MeSH；規則由作者與 AI 助理共同撰寫，判讀由 AI 助理完成、作者未逐篇複核、只判讀前 10 名；相關集偏大（30–318）、R@k 絕對值低。另一觀察：純數字 token（佔詞彙 11.5%）df 小、idf 高，會混入 ltn 向量前列，移除數字可改善。

D1　現行做法

- **人工時代**：MEDLINE 自 1960 年代起由 NLM 的專業索引員閱讀全文，從 MeSH 詞彙表挑 10–15 個標題，並以星號標出文章的主要主題（major topic）；作者關鍵詞則由作者自填，不受詞彙表控制。
- **2002–2021**：NLM 的 Medical Text Indexer（MTI）先以規則與機器學習推薦標題，索引員再審核，MTI 的推薦品質逐年提升。
- **2022 起全面自動化**：所有 MEDLINE 文獻改由演算法（MTIA）直接索引，人工只做「curation」覆核；**2024 年 4 月**改用神經網路模型 **MTIX**（以 2007–2022 的文獻訓練，輸入是標題、摘要與期刊資訊），覆核集中在高影響與常被檢索的領域。
- **時間差**：新文獻先以「in process」狀態進 PubMed，索引完成才有 MeSH；本集合 2026 年的文獻中 163 篇（5.4%）因此沒有任何標籤。

D2　可靠嗎

- **人與人之間本來就不一致**：Funk 與 Reid（1983）比較 760 篇被兩位索引員各自索引過的文章，主標題的一致性約 48%，核心概念約 61%，checktag（人類、年齡層等）約 75%；文章長度、語言與期刊優先級都不影響一致性。相關判斷的「標準答案」本身就有相當雜訊，這在資訊檢索評估裡是常態。
- **自動索引接近但未等同人工**：2026 年的系統性回顧（Giustini 等，JMLA）指出 MTIX 的索引速度大幅提升，但仍未達到與人工索引完全等價，約三分之一的紀錄仍需人工修正。
- **星號也是預測出來的**：major topic 旗標在自動索引下同樣由模型決定，所以本報告的 grade 2 / grade 1 之分也帶有模型誤差。

D3　對本報告的影響

- 正文說相關判斷「只看標籤不看正文，故不偏向任何 weighting」要加一個但書：MTIX 的輸入正是標題與摘要，標籤與檢索用的文字並非完全獨立，只是多了一層受控詞彙的分類，不直接等於詞頻，也不會因為某個詞重複出現就多給標籤。
- 漏標是真實存在的：pooling 後人工判讀的 118 篇中有 37 篇（31%）其實相關，比例與「約三分之一的紀錄需人工修正」一致；這是本報告加入人工判讀的理由。q13、q14 的漏標多半是 2026 年「in process」尚未索引的文獻。
- 因此結論只宣稱 scheme 之間的**相對**排序（加人工判讀前後排序不變），不宣稱任何絕對的 MAP 值。

D4　在網頁上怎麼看

- 第 5 節查詢表的「via MeSH / keywords only / manual」三欄顯示每題相關集各來自哪種標籤；點「relevant set」可看每篇命中的標籤，帶 * 的是 major topic。
- 第 3 節每筆結果展開「abstract ・ MeSH ・ keywords」即可對照 MTIX 給的標籤與摘要內容，判斷它漏了什麼。

資料來源：NLM Technical Bulletin 2024 年 3–4 月號「MTIX」；Giustini 等，Automated indexing in MEDLINE and the Medical Text Indexer (MTI), 2000–2025: a scoping review，*J Med Libr Assoc*（2026）；Funk ME, Reid CA. Indexing consistency in MEDLINE. *Bull Med Libr Assoc* 1983;71(2):176–183；NLM「Introduction to MeSH Indexing」。

附錄 E 課堂 demo 講稿：六個步驟展示向量空間檢索系統（約 15 分鐘）

每個 demo 同一節奏： ① **問** 「你猜會怎樣？」 ② **按** 只按一個按鈕 ③ **驗** 用畫面上的數字驗證　　共 6 個 demo，約 15 分鐘

Demo 1 一篇文件變成向量　第 2 節 · 2 分鐘

操作　PMID 留空按 Show vectors，勾 nnn、lnn、ltn 三張卡並排。

看什麼　nnn 的榜首是數字「0」，出現 38 次、佔向量 9%；lnn 把它壓到 4.6；ltn 的榜首換成 ascvd，因為它只出現在 29 篇。

向量空間模型的第一步不是算相似度，而是決定「哪些詞代表這篇文件」。

Demo 2 查詢也是向量，分數就是內積　第 3 節 · 3 分鐘

操作　點 q01 連結，Doc scheme 先選 nnn 按 Search，再改 ltc 按一次。

看什麼　每筆結果下方的貢獻長條：nnn 下 weight、loss 這種常見詞吃掉大半分數；ltc 下 semaglutide 一個詞佔最大塊。右側 rel 1 / rel 2 標籤讓觀眾直接數相關數。

分數 = Σ 查詢詞權重 × 文件詞權重，換權重就是換「誰說了算」。

Demo 3 改一個字母，整張榜單重排　第 4 節 · 3 分鐘

操作　填 q03「GLP-1 receptor agonists and cardiovascular outcomes」，按「RQ2 有無 IDF」。先請觀眾猜 lnn 的前 10 名會出現什麼。

看什麼　lnn 欄跑出腎臟、酒精、脫髮、睡眠呼吸中止；ltn 欄 9 篇綠色。表格 overlap 0.40、τ 0.05，兩張榜單幾乎無關。

glp、receptor、agonist 出現在八成文件，沒有 idf 時分數分給每一篇，剩下的只有雜訊。

Demo 4 長文件的優勢與正規化的代價　第 4 節 · 2 分鐘

操作　填 q10「polycystic ovary syndrome」，按「RQ4 L2 正規化」。

看什麼　ltn 前 10 名平均長度 230，ltc 降到 165，但 ltc 把一篇只有 30 個詞的更正啟事推到第一名；nDCG@10 從 0.775 掉到 0.528。

正規化不是免費的：它懲罰長文件，也獎勵「短到沒有別的詞稀釋」的文件。

Demo 5 長尾 idf 的陷阱（現場輸入）　第 3 節 · 2 分鐘

操作　輸入「semaglutide hepatocyte」，Doc scheme 選 ltc。

看什麼　第 3 名只命中 hepatocyte 兩次（分數 0.150），贏過第 6 名命中 semaglutide 十三次的文章（0.099）；hepatocyte 的 idf 5.6 是 semaglutide 1.44 的 4 倍。

idf 只看稀有、不看意義：一個罕見詞的一次出現可以壓過主題詞的十幾次。這是已知限制，也是討論題。

Demo 6 怎麼證明哪種比較好　第 5、6 節 · 3 分鐘

操作　先看查詢表的 relevant / via MeSH / manual 欄，點一題的「relevant set」；再勾全部 scheme、k = 10 按 Evaluate；最後勾 condensed 重跑。

看什麼　ltn MAP 0.661、ltc nDCG@10 0.698、bm25 P@5 0.973 各自粗體；condensed 後數字幾乎不動；第 6 節的結論文字跟著即時生成。

相關判斷來自標籤規則加 118 篇 AI 助理判讀（附錄 D0），不碰檢索用的權重，所以結果不偏向任何 scheme。

現場技巧

- 網址 `http://172.27.156.215:8090/#vsm`（WSL 的 IP 以 `hostname -I` 確認）；投影前把六節都先按過一次，結果載好才不會等。
- Demo 3 與 5 最有戲劇性，放在中段；Demo 6 收尾，直接接到第 1 頁的結論表。
- 第 3 節的 0 / 1 / 2 按鈕可順手示範人工判讀，示範完按 × 還原，否則評估數字會變。
- 報告第 1 頁的 RQ2 圖與 RQ4 表就是 Demo 3、4 的靜態版本，demo 後翻回報告對照，讓觀眾知道數字從哪裡來。
- 備援：網頁若出問題，終端機下列指令得到一模一樣的數字（服務以 `python3 app.py --host 0.0.0.0` 啟動，預設埠 8090）。

```
python3 cli.py vsm search  "semaglutide hepatocyte" --scheme ltc
python3 cli.py vsm compare "GLP-1 receptor agonists and cardiovascular outcomes" --schemes lnn,ltn
python3 cli.py vsm compare "polycystic ovary syndrome" --schemes ltn,ltc
python3 cli.py vsm eval --k 10
```