AI INFORMATION RETRIEVAL（人工智慧資訊檢索）· PROJECT #3 TERM WEIGHTING / TF-IDF

胡元楨（P77141105）· 純 Python 標準函式庫自行實作：`ir/tfidf.py`（SMART tf・df・norm 權重、向量空間、cosine 排名）、`ir/evaluation.py`（P@k、R@k、MRR、MAP、nDCG）、`ir/relevance.py`（MeSH / 關鍵詞相關性判斷）；介面分頁「TF-IDF 檢索」，CLI `cli.py vsm …`；完整報告 `REPORT_tfidf.md`

3,000 PubMed 摘要（GLP-1，含 MeSH）；平均 211 索引詞（24–672）

15,823 詞幹；45% 只出現在 1 篇（idf 8.01），42 個詞出現在 ≥ 1,000 篇

12 weighting schemes：nnn、lnn、btn、ntn、ltn、nnc、lnc、ntc、ltc、atc、lpc + BM25

15 評估查詢；相關集由 MeSH major-topic / 關鍵詞規則產生（26–317 篇）

0.615 最佳 MAP：ltn（log TF × IDF）；raw TF 0.421

0.65 ms 一次查詢（倒排權重向量）；19 個單元測試

RQ1 原始 TF 與 Log TF 的差異，如何影響詞項權重？

tf	1	2	5	10	30	50
raw tf	1	2	5	10	30	50
1 + ln tf	1.00	1.69	2.61	3.30	4.40	4.91

raw tf 讓出現 30 次的詞是出現 1 次的 30 倍，log 只給 4.4 倍。一篇 FLOW 試驗摘要（422 索引詞、max tf 38）在 `nnn` 下由小數的「0」（tf 38）主宰、前 5 詞佔向量 22.5%；`lnn` 壓到 7.8%。檢索上 raw → log 是效果最大的單一改動：MAP **0.421 → 0.533**（+27%）、nDCG@10 0.484 → 0.605、MRR 0.778 → 0.917；q01 前 10 名平均長度 378 → 253（raw tf 偏好能重複同一詞的長文件）。**詞頻增加，重要性不等比例增加。**

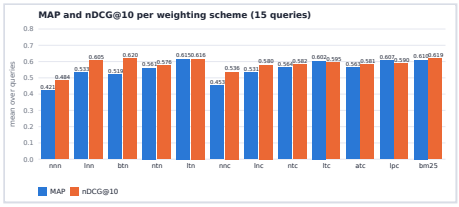
RQ2 為什麼 IDF 能降低常見詞的重要性、提高具辨識力詞項的權重？

term	df	df/N	idf
glp・receptor・agonist	2,333–2,422	78–81%	**0.21–0.25**
diabet・obes	1,617・1,429	54・48%	0.62・0.74
semaglutid・tirzepatid	714・440	24・15%	1.44・1.92
cardiovascular	679	23%	1.49
apnea・pco(s)	63・36	2・1%	**3.86・4.42**

idf = ln(N/df) 隨 df 單調下降（df 1 → 8.01，1,000 → 1.10，N → 0）。出現在八成文件的詞對「這篇 vs 那篇」沒有資訊：對每篇都加同樣分數不改變排名，只讓分數被它的 tf 噪音淹沒。q03「GLP-1 receptor agonists and cardiovascular outcomes」沒有 idf 時前五名由 glp/receptor/agonist 重複最多的文件決定（腎臟、酒精、脫髮…無一相關）；有 idf 後 cardiovascular 的權重是 glp 的 6 倍，排名才轉向心血管。整體 lnn → ltn MAP **0.533 → 0.615**（+15%）；只用 idf（btn）就有 0.519，nDCG@10 甚至最高（0.620）：短文本裡「有無出現」比「出現幾次」更重要。

RQ3 · RQ5 TF-IDF 是否產生較好的排名？不同 weighting 對各指標的影響

scheme	P@5	P@10	R@20	MRR	MAP	nDCG@10	R-prec
nnn raw TF	0.653	0.667	0.152	0.778	0.421	0.484	0.430
lnn log TF	0.853	0.827	0.177	0.917	0.533	0.605	0.531
btn IDF only	0.800	0.747	0.156	0.883	0.519	**0.620**	0.538
ntn raw TF × IDF	0.787	0.793	0.183	0.883	0.561	0.576	0.549
ltn log TF × IDF	**0.893**	**0.847**	**0.194**	0.900	**0.615**	0.616	**0.613**
nnc raw TF, L2	0.787	0.733	0.170	0.848	0.453	0.536	0.461
lnc log TF, L2	0.813	0.767	0.184	0.902	0.531	0.580	0.532
ntc raw TF × IDF, L2	0.827	0.807	0.185	0.847	0.564	0.582	0.567
ltc log TF × IDF, L2	0.827	0.820	0.190	0.817	0.602	0.595	0.602
atc augmented TF × IDF, L2	0.733	0.773	0.167	0.832	0.563	0.581	0.565
lpc log TF × prob IDF, L2	0.813	0.827	0.187	0.783	0.607	0.590	0.605
bm25（參考）	**0.893**	**0.847**	0.190	**0.967**	0.610	0.619	0.595

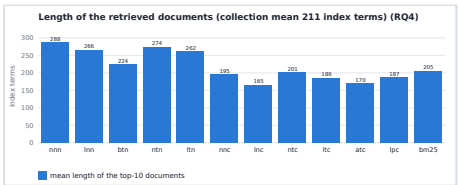


15 個查詢的平均 MAP 與 nDCG@10（`cli.py vsm eval`、`vsm svg`）。

RQ3 是：MAP raw TF 0.421 → log TF 0.533 → IDF only 0.519 → TF-IDF（ltn）**0.615**；逐題 AP 上 ltn 15/15 勝 raw TF、15/15 勝 IDF-only、14/15 勝 log TF。2×2×2 因素格（MAP）：log +0.07、idf +0.10、L2 −0.01～+0.03。**RQ5** raw TF 在所有指標最差；log TF × IDF 在所有指標前三；但「最佳」隨指標與查詢改變——nDCG@10 偏好 btn / BM25（重視 major-topic 的 grade-2 文件）、MRR 偏好 BM25（0.967）、q04 偏好 raw TF（nDCG 0.815 vs 0.587）、q15 偏好正規化（lnc 1.000）、q09 全部都差（副作用詞幾乎每篇試驗都提到，標籤卻只標「以此為主題」者）。結論須結合查詢、資料集與指標。

RQ4 文件向量是否需要 L2 normalization？正規化前後的排名有何差異？

q10「polycystic ovary syndrome」	overlap@10	τ	mean len	P@10	nDCG@10
ltn log TF × IDF	1.00	1.00	237	1.00	0.775
ltc + L2	0.40	−0.36	153	0.90	0.464
nnn raw TF	0.40	−0.36	213	0.70	0.609
nnc + L2	0.20	−0.39	118	0.70	0.459



各 scheme 前 10 名的平均長度（15 題平均）：未正規化 224–288，正規化 165–201，BM25 205。

未正規化的內積 = ‖d‖ · cos θ：長文件多提幾次就贏；正規化後只比方向。兩者排名差異很大（15 題平均 ltn vs ltc 前 10 名重疊 **48%**、τ ≈ 0；前 10 名平均長度 262 → 186），但本集合全是長度相近的摘要（平均 211、相關文件 217），正規化收益小（MAP 0.615 → 0.602，僅 5/15 題變好），而 30 個詞的更正啟事（*Correction: …*）因為沒有其他詞稀釋，在 ltc 下竄到第一名。長度懸殊時正規化不可或缺：把 3 篇 PMC 全文（3,221–4,358 詞）混進 1,003 篇摘要，10 題前 10 名的 100 個位置中 nnn 有 15、ltn 有 9 個被長文佔走，nnc / ltc / BM25 為 0（`report/rq4_mixed_lengths.py`）。BM25 的部分正規化（b = 0.75）兩種情況都最好：問題不是「要不要」而是「正規化多少」。

方法與限制 相關性判斷

資料集沒有現成標籤，依作業指示用**主題標籤**：每個查詢定義若干概念群（正規表示式），文件的每一群至少命中一個 MeSH 標題或作者關鍵詞即相關，命中 major-topic MeSH 為 grade 2；只看標籤不看文字，故不偏向任何 weighting，並可在介面手動覆寫。限制：163 篇（5.4%）無任何標籤（另提供 condensed-list 評估，各值 +0.01～0.03、排序不變）；最新記錄 MeSH 尚未完成（57% 有 MeSH）；規則由作者撰寫而非獨立評審；標籤層級的相關比人工判讀寬鬆，相關集偏大、R@k 絕對值低。另一觀察：純數字 token（佔詞彙 11.5%）df 小、idf 高，會混入 ltn 向量前列；移除數字是最直接的 modified TF-IDF。

`python3 cli.py vsm info | terms | doc | search | compare | eval | queries | relevant | judge | svg · /#vsm`

`tests/test_project3.py` (19)· 全部 72 個測試通過 · 2026-10-27