胡元楨（P77141105）

| 3,000 | 15,823 | 2×2×2 + 4 | 15 | 0.661 | 118 |
|---|---|---|---|---|---|
| PubMed 摘要（GLP-1，含 MeSH）；平均 211 索引詞（24–672） | 詞幹；45% 只出現在 1 篇（idf 8.01），42 個詞出現在 ≥ 1,000 篇 | 因素設計：tf raw/log × idf 有/無 × L2 有/無 = 8 種；另加 btn、atc、lpc、BM25 | 評估查詢；相關集由 MeSH / 關鍵詞規則 + 118 篇人工判讀產生（30–318 篇） | 最佳 MAP：ltn（log TF × IDF）；raw TF 0.451 | 篇人工判讀，補回 37 篇漏標的相關文件；指標高 0.03–0.11，排序不變 |

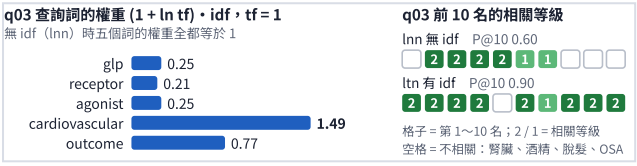
**權重代號怎麼讀**　SMART 三字母依位置：**l** ①tf　**t** ②df　**c** ③正規化　① tf：**n** 原始次數 · **l** 1+ln tf · **a** 增強 · **b** 布林　② df：**n** 不乘 · **t** idf · **p** 機率 idf　③ 正規化：**n** 無 · **c** cosine　例：`nnn` 原始 tf、`lnn` log tf、`ltn` log tf × idf、`ltc` 再加 cosine（完整對照表：第 2 頁附錄）

## RQ1 原始 TF 與 Log TF 的差異，如何影響詞項權重？

| tf | 1 | 2 | 5 | 10 | 30 | 50 |
|---|---|---|---|---|---|---|
| raw tf | 1 | 2 | 5 | 10 | 30 | 50 |
| 1 + ln tf | 1.00 | 1.69 | 2.61 | 3.30 | 4.40 | 4.91 |

- **例子**：FLOW 試驗摘要提到 semaglutide 7 次、cardiovascular 13 次。raw tf 說後者重要近兩倍；log 給 2.95 對 3.56、只差兩成，較接近人的判斷。
- **機制**：log 的加分逐次遞減（第 2 次 +0.69、第 30 次 +0.03），單一詞無法獨占向量：原始 tf 下（`nnn`）同篇由出現 38 次的「0」主宰、前 5 詞佔 22.5%；log tf（`lnn`）壓到 7.8%。
- **長文不公平**：文件愈長 tf 愈大，raw tf 等於替長文加分；q01 前 10 名平均長度 339 → 275（全集合 211）。
- **效果**：最有效的單一改動，MAP **0.451 → 0.574**（+27%，14/15 題提高）；壓平後 tf 與 idf 同量級，RQ2 的 idf 才量得出來。
- **結論**：詞頻增加，重要性不等比例增加。

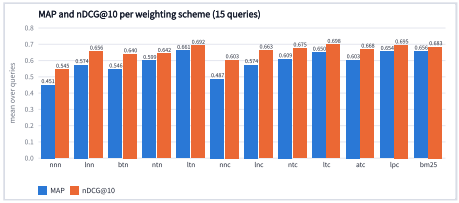
## RQ2 為什麼 IDF 能降低常見詞的重要性、提高具辨識力詞項的權重？




- **變因**：固定 log tf，只在第 ② 位乘 idf：lnn → ltn、lnc → ltc。
- **機制**：idf 隨 df 遞減（df 1 → 8.01，N → 0）；出現在八成文件的 glp / receptor / agonist 每篇都加一樣，不改排名，只剩 tf 噪音。
- **效果**：q03 前 10 名相關 6 → 9 篇（左圖，nDCG@10 0.479 → 0.866）；整體 MAP **0.574 → 0.661**（+15%，15/15 題提高），lnc → ltc 0.574 → 0.650；只用 idf 的 btn 也有 0.546。
- **結論**：決定權從「常見詞重複幾次」移到「稀有詞有沒有出現」；短摘要裡有無出現幾乎與出現幾次同樣重要。

## RQ3 · RQ5 TF-IDF 是否產生較好的排名？不同 weighting 對各指標的影響

| scheme | | P@5 | P@10 | R@20 | MRR | MAP | nDCG@10 | R-prec |
|---|---|---|---|---|---|---|---|---|
| `nnn` | raw TF | 0.773 | 0.760 | 0.158 | 0.791 | 0.451 | 0.545 | 0.449 |
| `lnn` | log TF | 0.947 | 0.900 | 0.192 | 0.933 | 0.574 | 0.656 | 0.553 |
| `btn` | IDF only | 0.840 | 0.787 | 0.166 | 0.922 | 0.546 | 0.640 | 0.562 |
| `ntn` | raw TF × IDF | 0.907 | 0.880 | 0.195 | 0.933 | 0.599 | 0.642 | 0.574 |
| `ltn` | log TF × IDF | 0.960 | **0.960** | **0.205** | 0.933 | **0.661** | 0.692 | **0.634** |
| `nnc` | raw TF, L2 | 0.880 | 0.827 | 0.180 | 0.883 | 0.487 | 0.603 | 0.477 |
| `lnc` | log TF, L2 | 0.920 | 0.873 | 0.196 | 0.967 | 0.574 | 0.663 | 0.553 |
| `ntc` | raw TF × IDF, L2 | 0.933 | 0.920 | 0.199 | 0.967 | 0.609 | 0.675 | 0.585 |
| `ltc` | log TF × IDF, L2 | 0.960 | 0.940 | **0.205** | 0.956 | 0.650 | **0.698** | 0.622 |
| `atc` | augmented TF × IDF, L2 | 0.880 | 0.873 | 0.181 | **1.000** | 0.603 | 0.668 | 0.588 |
| `lpc` | log TF × prob IDF, L2 | 0.947 | 0.947 | 0.201 | 0.967 | 0.654 | 0.695 | 0.622 |
| **bm25（參考）** | | **0.973** | **0.960** | **0.205** | 0.967 | 0.656 | 0.683 | 0.619 |

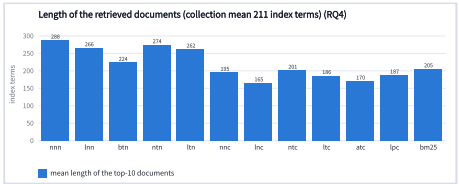


15 個查詢的平均 MAP 與 nDCG@10，含人工判讀（`cli.py vsm eval`、`vsm svg`）。

**RQ3**　是：MAP raw TF 0.451 → log TF 0.574 → IDF only 0.546 → TF-IDF（ltn）**0.661**；逐題 AP 上 ltn 15/15 勝 raw TF、IDF-only 與 log TF；nDCG@10 前三名 ltc / lpc / ltn 全是 TF × IDF。因素格（MAP）：log +0.06～0.12、idf +0.08～0.15、L2 −0.01～+0.04。
**RQ5**　raw TF 在所有指標最差；log TF × IDF（ltn / ltc / lpc）在所有指標前四；但「最佳」隨指標與查詢改變——MAP 選 ltn、nDCG@10 選 ltc（0.698）、P@5 / R@k 選 BM25、MRR 選 atc（1.000）；q04 偏好 raw TF（nDCG 0.815 vs 0.645）、q15 偏好正規化（lnc 1.000）、q09 全部都差（副作用詞幾乎每篇試驗都提到，只有「以此為主題」者算相關）。結論須結合查詢、資料集與指標。

## RQ4 文件向量是否需要 L2 normalization？正規化前後的排名有何差異？

| q10「polycystic ovary syndrome」 | overlap@10 | τ | mean len | P@10 | nDCG@10 |
|---|---|---|---|---|---|
| ltn log TF × IDF | 1.00 | 1.00 | 230 | 1.00 | 0.775 |
| ltc + L2 | 0.60 | −0.17 | 165 | 1.00 | 0.528 |
| nnn raw TF | 0.50 | 0.09 | 215 | 0.70 | 0.609 |
| nnc + L2 | 0.30 | −0.32 | 152 | 0.80 | 0.525 |



各 scheme 前 10 名的平均長度（15 題平均）：未正規化 224–288，正規化 165–201，BM25 205。

未正規化的內積 = ‖d‖ · cos θ：長文件多提幾次就贏；正規化後只比方向。兩者排名差異很大（15 題平均 ltn vs ltc 前 10 名重疊 **48%**、τ ≈ 0；前 10 名平均長度 262 → 186），但本集合全是長度相近的摘要（平均 211、相關文件 217），正規化收益小且方向不一（MAP 0.661 → 0.650，僅 6/15 題變好；MRR、nDCG@10 略升；raw tf 則 0.451 → 0.487 受益），而 30 個詞的更正啟事（*Correction:* …）因為沒有其他詞稀釋，在 ltc 下竄到第一名。長度懸殊時正規化不可或缺：把 3 篇 PMC 全文（3,221–4,358 詞）混進 1,003 篇摘要，10 題前 10 名的 100 個位置中 nnn 有 15、ltn 有 9 個被長文佔走，nnc / ltc / BM25 為 0（`report/rq4_mixed_lengths.py`）。BM25 的部分正規化（b = 0.75）兩種情況都最好：問題是「正規化多少」。

## 方法與限制 相關性判斷

資料集沒有現成標籤，依作業指示用**主題標籤**：每個查詢定義若干概念群（正規表示式），文件的每一群至少命中一個 MeSH 標題或作者關鍵詞即相關，命中 major-topic MeSH 為 grade 2；只看標籤不看文字，故不偏向任何 weighting，並可在介面手動覆寫。為補標籤漏標，對每題把六個 scheme 的前 10 名 pooling，規則判 0 的 **118 篇**由作者讀摘要逐篇判定：37 篇補為相關（q03 心血管試驗 5、q09 副作用主題 7、q13 / q14 無標籤的 OSA 試驗與成本效益分析各 4）、81 篇確認不相關；各指標上升 0.03–0.11，結論方向不變。限制：163 篇（5.4%）無任何標籤（condensed-list 評估排序不變）；57% 有 MeSH；規則與人工判讀皆由作者一人完成，且只判讀了前 10 名；相關集偏大（30–318）、R@k 絕對值低。另一觀察：純數字 token（佔詞彙 11.5%）df 小、idf 高，會混入 ltn 向量前列；移除數字是最直接的改良。

## 附錄 A SMART 權重代號對照表（tf · df · norm）

每個 weighting scheme 是三個字母，**依位置讀**：第 1 字母是 tf 怎麼算、第 2 字母是 df 怎麼用、第 3 字母是正規化。三個因素獨立，權重 = ① × ② 再做 ③，查詢端全程固定為 `nnc`（原始 tf、不乘 idf、cosine）。

**l** **t** **c** → `ltc` = (1 + ln tf) × ln(N / df)，再除以向量長度（cosine）。同理 `nnn` = 原始 tf、不乘 idf、不正規化。

① tf　② df　③ norm

### A1　三個位置各自可填的字母

| 位置 | 字 | 名稱 | 公式 | 直覺 / 用意 | 本報告用到的 scheme |
|---|---|---|---|---|---|
| **① tf**<br>詞在這篇出現幾次（局部） | n | natural | `tf` | 出現幾次算幾分；高頻詞獨占向量、偏好長文件（RQ1） | `nnn ntn nnc ntc` |
| | l | logarithm | `1 + ln tf` | 加分逐次遞減：tf 30 只得 4.4、不是 30（RQ1） | `lnn ltn lnc ltc lpc` |
| | a | augmented | `0.5 + 0.5 · tf / max tf` | 以該篇最大 tf 為基準，另一種壓平長文件的方法 | `atc` |
| | b | boolean | `1` | 只看有沒有出現，忽略次數 | `btn` |
| **② df**<br>詞出現在幾篇文件（全域） | n | none | `1` | 不管詞多常見 | `nnn lnn nnc lnc` |
| | t | idf | `ln(N / df)` | 常見詞降權、稀有詞升權：df 1,172 → 0.94，df 29 → 4.64（RQ2） | `btn ntn ltn ntc ltc atc` |
| | p | prob idf | `max(0, ln((N − df) / df))` | 出現超過一半文件的詞權重直接歸 0 | `lpc` |
| **③ norm**<br>向量要不要正規化 | n | none | `w` | 分數 = 內積；長文件向量長、分數高（RQ4） | `nnn lnn btn ntn ltn` |
| | c | cosine | `w / ‖d‖` | 除以向量長度，分數 = cosine 相似度，長度不再有利（RQ4） | `nnc lnc ntc ltc atc lpc` |

### A2　本報告的 12 個 scheme

| 代號 | ① tf | ② df | ③ norm | 白話 | 公式 | 用在 | MAP | nDCG@10 |
|---|---|---|---|---|---|---|---|---|
| `nnn` | n 原始 | n 無 | n 無 | raw TF | `tf` | RQ1 RQ3 RQ4 | 0.451 | 0.545 |
| `lnn` | l 對數 | n 無 | n 無 | log TF | `1 + ln tf` | RQ1 RQ2 | 0.574 | 0.656 |
| `btn` | b 布林 | t idf | n 無 | IDF only | `idf` | RQ3 | 0.546 | 0.640 |
| `ntn` | n 原始 | t idf | n 無 | raw TF × IDF | `tf · idf` | RQ1 RQ3 | 0.599 | 0.642 |
| `ltn` | l 對數 | t idf | n 無 | log TF × IDF | `(1 + ln tf) · idf` | RQ1–RQ4 | **0.661** | 0.692 |
| `nnc` | n 原始 | n 無 | c cosine | raw TF, L2 | `tf / ‖d‖` | RQ4 | 0.487 | 0.603 |
| `lnc` | l 對數 | n 無 | c cosine | log TF, L2 | `(1 + ln tf) / ‖d‖` | RQ2 | 0.574 | 0.663 |
| `ntc` | n 原始 | t idf | c cosine | raw TF × IDF, L2 | `tf · idf / ‖d‖` | 因素格 | 0.609 | 0.675 |
| `ltc` | l 對數 | t idf | c cosine | log TF × IDF, L2（教科書標準） | `(1 + ln tf) · idf / ‖d‖` | RQ2 RQ4 變形 | 0.650 | **0.698** |
| `atc` | a 增強 | t idf | c cosine | augmented TF × IDF, L2 | `(0.5 + 0.5 tf / max tf) · idf / ‖d‖` | 變形 | 0.603 | 0.668 |
| `lpc` | l 對數 | p 機率 idf | c cosine | log TF × prob IDF, L2 | `(1 + ln tf) · max(0, ln((N − df) / df)) / ‖d‖` | 變形 | 0.654 | 0.695 |
| `bm25` | 不屬於 SMART：tf 飽和 + 長度修正 + 機率 idf | | | Okapi BM25（對照組） | `k1 = 1.2，b = 0.75` | 變形 | 0.656 | 0.683 |

MAP、nDCG@10 為 15 題平均、k = 10、含 118 篇人工判讀；粗體為該欄最高。對照實驗每組只改一個字母：RQ1 nnn→lnn、ntn→ltn；RQ2 lnn→ltn、lnc→ltc；RQ3 nnn / btn / ntn / ltn；RQ4 ltn→ltc、nnn→nnc。

### A3　① tf 與 ② df 的關係：都取 log，但方向與層級不同

**相同**：1 + ln tf 與 ln(N / df) 都是「對一個計數取對數」，背後同一個想法：計數加倍，證據不該加倍。

**不同**：tf 是**局部**量（這篇文件裡的次數），權重隨 tf **遞增**，回答「這篇在講它嗎」；df 是**全域**量（整個語料出現在幾篇），權重隨 df **遞減**，回答「這個詞能區分文件嗎」。兩者各自獨立，所以 SMART 放在不同位置相乘；log tf 把 tf 壓到與 idf 同一量級，idf 的效果才顯現（RQ2）。

# 附錄 B 評估查詢 q01–q15：怎麼定義、怎麼在網頁上重現、怎麼讀數據

**定義方式**　每題 = 查詢文字 + 設計意圖 + 相關規則。規則由一到兩個「概念群」組成，每群是一組 MeSH 標題 / 作者關鍵詞的正則表示式；一篇文件的標籤把**每一群**都命中才算相關，命中的是 MeSH major topic 給 grade 2、否則 grade 1。規則只看標籤、不看標題摘要正文，所以不偏向任何 weighting。再以六種 scheme（nnn、lnn、btn、ltn、ltc、bm25）各取前 10 名做 pooling，規則判 0 的 118 篇逐篇人工判讀，補回 37 篇漏標的相關文件（「人工」欄）。

| id | 查詢文字 / 設計意圖 | 相關規則（概念群；全部群都命中 → 相關） | 相關 g2 / g1 | MeSH / 關鍵詞 / 人工 | AP nnn | AP ltn | AP bm25 | P@10 ltn | R@10 ltn |
|---|---|---|---|---|---|---|---|---|---|
| q01 | **semaglutide weight loss in obesity**<br>藥 + 病況，兩者在語料都常見 | (semaglutide \| wegovy \| ozempic) AND (obes \| overweight \| weight loss …) | 318<br>189/129 | 232/85/4 | 0.45 | 0.60 | **0.61** | 1.0 | 0.03 |
| q02 | **tirzepatide glycemic control in type 2 diabetes**<br>藥 + 病況；diabetes 是最常見詞之一（idf 低） | (tirzepatide \| mounjaro \| zepbound) AND (diabetes mellitus, type 2 \| type 2 diabetes \| t2dm? …) | 131<br>82/49 | 97/32/16 | 0.15 | **0.35** | 0.34 | 0.8 | 0.06 |
| q03 | **GLP-1 receptor agonists and cardiovascular outcomes**<br>語料主題本身 + 結果；藥類詞幾乎沒有 idf | (glp-?1 ?r \| glucagon-like peptide-?1 receptor agonist \| incretin …) AND (cardiovascular \| heart failure \| myocardial …) | 263<br>160/103 | 163/95/16 | 0.19 | 0.53 | **0.55** | 0.9 | 0.03 |
| q04 | **chronic kidney disease and diabetic nephropathy**<br>一個概念、多種寫法（CKD、renal insufficiency、DKD） | (renal insufficiency, chronic \| chronic kidney \| diabetic nephropath …) | 198<br>91/107 | 109/86/6 | 0.50 | **0.70** | 0.66 | 1.0 | 0.05 |
| q05 | **gut microbiota and bile acid metabolism**<br>機制主題，多為動物實驗 | (gastrointestinal microbiome \| gut microbio \| microbiota …) | 132<br>48/84 | 69/61/2 | 0.70 | **0.88** | 0.86 | 1.0 | 0.08 |
| q06 | **fatty liver disease MASLD NAFLD steatohepatitis**<br>近年改名的主題（NAFLD → MASLD），同義詞多 | (fatty liver \| non-alcoholic \| nonalcoholic …) | 124<br>66/58 | 68/55/2 | 0.65 | 0.84 | **0.85** | 1.0 | 0.08 |
| q07 | **neuroprotection in Alzheimer's and Parkinson's disease**<br>神經主題；罕見、高 idf 詞 | (alzheimer \| parkinson \| neurodegenerat …) | 143<br>66/77 | 71/72/0 | 0.53 | 0.72 | **0.72** | 1.0 | 0.07 |
| q08 | **bariatric surgery versus medication for weight loss**<br>手術 vs 藥物的比較 | (bariatric \| gastric bypass \| sleeve gastrectomy …) | 139<br>66/73 | 81/57/5 | 0.37 | 0.82 | **0.84** | 1.0 | 0.07 |
| q09 | **gastrointestinal adverse events nausea vomiting**<br>安全性主題；查詢詞在摘要裡很常見，標籤只標以此為主題的文章 | (nausea \| vomiting \| gastroparesis …) | 68<br>26/42 | 32/29/19 | 0.18 | 0.31 | **0.31** | 0.8 | 0.12 |
| q10 | **polycystic ovary syndrome**<br>小而明確的主題（PCOS） | (polycystic ovar \| pcos) | 45<br>19/26 | 26/18/8 | 0.65 | 0.88 | **0.91** | 1.0 | 0.22 |
| q11 | **SGLT2 inhibitors combination therapy**<br>第二種藥類與 GLP-1 RA 併用 | (sodium-glucose (co-?)? transporter \| sglt-?2 \| sglt2i …) | 262<br>107/155 | 156/104/3 | 0.51 | **0.61** | 0.59 | 1.0 | 0.04 |
| q12 | **insulin secretion from pancreatic beta cells**<br>生理主題；insulin 常見、beta cell 專一 | (insulin-secreting cells \| beta[- ]?cell \| β[- ]?cell …) | 102<br>56/46 | 66/32/8 | 0.49 | **0.57** | 0.53 | 1.0 | 0.10 |
| q13 | **obstructive sleep apnea treatment**<br>新適應症（tirzepatide 治 OSA） | (sleep apnea \| sleep apnoea \| osa) | 46<br>20/26 | 20/22/8 | 0.63 | **0.92** | 0.88 | 1.0 | 0.22 |
| q14 | **cost-effectiveness and health economics**<br>經濟研究：標籤專一、用詞通用 | (cost-benefit \| cost-effective \| cost effective …) | 30<br>14/16 | 20/6/6 | 0.66 | **0.82** | 0.78 | 1.0 | 0.33 |
| q15 | **type 1 diabetes adjunct therapy**<br>第 1 型 vs 常見得多的第 2 型：只差一個 token | (diabetes mellitus, type 1 \| type 1 diabetes \| t1dm? …) | 51<br>34/17 | 36/15/15 | 0.11 | 0.36 | **0.41** | 0.9 | 0.18 |

AP 粗體 = 該題三者最高。R@10 受相關集大小封頂：q01 有 318 篇，前 10 名全對也只有 10/318 = 0.03；q14 只有 30 篇，10 篇對就是 0.33。R@k 只在同一題內比 scheme，跨題看 AP、nDCG。

## 在網頁上重現（/#vsm）

- **第 5 節 查詢表**：本表前五欄的來源。每列的「relevant set」列出該題全部相關文件、等級、命中的標籤與在所選 scheme 下的名次；「search」把查詢帶到第 3 節。
- **第 3 節 搜尋**：點 q01–q15 或自行輸入，選 Doc scheme 看前 k 名。每筆標 rel 1 / rel 2，長條是各查詢詞的貢獻 w(t,q)×w(t,d)；按 0 / 1 / 2 當場修改人工判讀。
- **第 4 節 對照實驗**：填入查詢、按 RQ1–RQ4 按鈕，一次只改一個字母；得 overlap@10、Kendall τ、平均長度、P@5 / P@10 / R@10 / AP / nDCG@10，下方並排各 scheme 的前 10 名（綠 = 相關）。
- **第 5 節 Evaluate → 第 6 節**：勾選 scheme、k、condensed，得 15 題平均表、2×2×2 因素格、逐題表；第 6 節的 RQ 結論由這些數字即時生成。

## 怎麼讀數據

- **P@k**：前 k 名裡相關的比例；與相關集大小無關，相關集大的題容易拿 1.0。
- **R@k**：前 k 名找回了相關集的幾分之幾，被相關集大小封頂（見上註）。
- **RR / MRR**：第一篇相關文件名次的倒數；1.0 = 第 1 名就相關。
- **AP / MAP**：每找到一篇相關文件就量一次 precision 再平均，相關文件排得愈前愈高；跨題、跨 scheme 比較的主指標。
- **nDCG@10**：分級版，grade 2 比 grade 1 值錢，名次愈後折扣愈重；grade 2 排在前面才高。
- **overlap@10 / Kendall τ**：兩個 scheme 前 10 名的交集比例與名次一致性；τ ≈ 0 表示榜單幾乎重排。
- **mean length**：前 10 名平均索引詞數（全集合 211）；偏高 = 偏好長文件（RQ4）。
- **讀表範例**：q03 AP nnn 0.19 → ltn 0.53，是 idf 把 cardiovascular 拉過 glp / receptor / agonist（RQ2）；q09 三者都只有 0.31，nausea、vomiting 幾乎每篇試驗都提到，標籤卻只標以此為主題的文章，是文字訊號與標籤分歧最大的一題；q15 ltc 0.44 > ltn 0.36，短查詢在正規化後較不被長文件淹沒；q14 是唯一 log tf 沒幫上的題（0.65 對 0.66）。