胡元楨（P77141105）

3,000	15,823	2×2×2 + 3	15	0.661	118
PubMed 摘要（GLP-1，含 MeSH）；平均 211 索引詞（24–672）	詞幹；45% 只出現在 1 篇（idf 8.01），42 個詞出現在 ≥ 1,000 篇	因素設計：tf raw/log × idf 有/無 × L2 有/無 = 8 種；另加 btn、atc、lpc 三個變形	評估查詢；相關集由 MeSH / 關鍵詞規則 + 118 篇人工判讀產生（30–318 篇）	最佳 MAP：ltn（log TF × IDF）；raw TF 0.451	篇 AI 助理判讀（作者未複核），補回 37 篇漏標的相關文件；指標高 0.03–0.11，排序不變

權重代號怎麼讀　SMART 三字母依位置：**l** ①tf　**t** ②df　**c** ③正規化　① tf：**n** 原始次數 · **l** 1+ln tf · **a** 增強 · **b** 布林　② df：**n** 不乘 · **t** idf · **p** 機率 idf　③ 正規化：**n** 無 · **c** cosine　例：`nnn` 原始 tf、`lnn` log tf、`ltn` log tf × idf、`ltc` 再加 cosine（完整對照表：第 2 頁附錄）

RQ1 原始 TF 與 Log TF 的差異，如何影響詞項權重？

tf	1	2	5	10	30	50
raw tf	1	2	5	10	30	50
1 + ln tf	1.00	1.69	2.61	3.30	4.40	4.91

- **例子**：FLOW 試驗摘要提到 semaglutide 7 次、cardiovascular 13 次。raw tf 說後者重要近兩倍；log 給 2.95 對 3.56、只差兩成，較接近人的判斷。
- **機制**：log 的加分逐次遞減（第 2 次 +0.69、第 30 次 +0.03），單一詞無法獨占向量：原始 tf 下（`nnn`）同篇由出現 38 次的「0」主宰、前 5 詞佔 22.5%；log tf（`lnn`）壓到 7.8%。
- **長文不公平**：文件愈長 tf 愈大，raw tf 等於替長文加分；q01 前 10 名平均長度 339 → 275（全集合 211）。
- **效果**：最有效的單一改動，MAP **0.451 → 0.574**（+27%，14/15 題提高）；壓平後 tf 與 idf 同量級，RQ2 的 idf 才量得出來。
- **結論**：詞頻增加，重要性不等比例增加。

RQ2 為什麼 IDF 能降低常見詞的重要性、提高具辨識力詞項的權重？

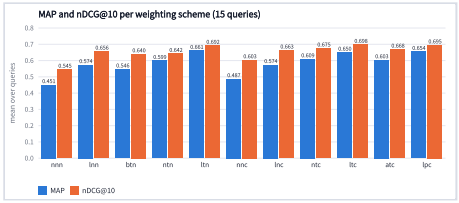
例題 q03「GLP-1 receptor agonists and cardiovascular outcomes」 · rel 2 / 1 / 0 = 相關且為主要主題 / 相關但非主要 / 不相關（附錄 D0）



- **變因**：固定 log tf，只在第 ② 位乘 idf：lnn → ltn、lnc → ltc。
- **機制**：idf 隨 df 遞減（df 1 → 8.01，N → 0）；出現在八成文件的 glp / receptor / agonist 每篇都加一樣，不改排名，只剩 tf 噪音。
- **效果**：q03 前 10 名相關 6 → 9 篇（左圖，nDCG@10 0.479 → 0.866）；整體 MAP **0.574 → 0.661**（+15%，15/15 題提高），lnc → ltc 0.574 → 0.650；只用 idf 的 btn 也有 0.546。
- **結論**：決定權從「常見詞重複幾次」移到「稀有詞有沒有出現」；短摘要裡有無出現幾乎與出現幾次同樣重要。

RQ3 · RQ5 TF-IDF 是否產生較好的排名？不同 weighting 對各指標的影響

scheme		P@5	P@10	R@20	MRR	MAP	nDCG@10	R-prec
nnn	raw TF	0.773	0.760	0.158	0.791	0.451	0.545	0.449
lnn	log TF	0.947	0.900	0.192	0.933	0.574	0.656	0.553
btn	IDF only	0.840	0.787	0.166	0.922	0.546	0.640	0.562
ntn	raw TF × IDF	0.907	0.880	0.195	0.933	0.599	0.642	0.574
ltn	log TF × IDF	**0.960**	**0.960**	**0.205**	0.933	**0.661**	0.692	**0.634**
nnc	raw TF, L2	0.880	0.827	0.180	0.883	0.487	0.603	0.477
lnc	log TF, L2	0.920	0.873	0.196	0.967	0.574	0.663	0.553
ntc	raw TF × IDF, L2	0.933	0.920	0.199	0.967	0.609	0.675	0.585
ltc	log TF × IDF, L2	**0.960**	0.940	**0.205**	0.956	0.650	**0.698**	0.622
atc	augmented TF × IDF, L2	0.880	0.873	0.181	**1.000**	0.603	0.668	0.588
lpc	log TF × prob IDF, L2	0.947	0.947	0.201	0.967	0.654	0.695	0.622

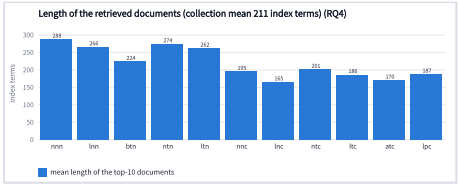


15 個查詢的平均 MAP 與 nDCG@10，含人工判讀（`cli.py vsm eval`、`vsm svg`）。

- **變因**：查詢端固定 nnc，文件端跑完 2×2×2 + 3 共 11 種 scheme，用 P@k、R@k、MRR、MAP、R-prec、nDCG@k 在 15 題上平均比較。
- **機制**：log 壓重複（RQ1）、idf 壓常見（RQ2）、L2 壓長度（RQ4）；MAP 看整條排名，P@k / MRR / nDCG@k 只看榜首，所以同一改動對不同指標的影響不同。
- **效果 RQ3**：MAP raw TF 0.451 → log TF 0.574 → IDF only 0.546 → TF-IDF（ltn）**0.661**，逐題 AP ltn 15/15 勝前三者；nDCG@10 前三名 ltc / lpc / ltn 全是 TF × IDF。
- **效果 RQ5**：**log tf 與 idf 對每個指標都是正向**，對 MAP 與 P@10 最大（log +0.12 / +0.14，idf +0.09 / +0.06）。**L2 看指標**：MRR 與 nDCG@10 上升（ltn → ltc 0.933 → 0.956、0.692 → 0.698；nnn → nnc 0.791 → 0.883、0.545 → 0.603），MAP 與 P@10 在 log × idf 上略降（0.661 → 0.650、0.960 → 0.940）。**MRR 最不敏感**：只要有 log 或 idf 就 0.92–1.00，只剩 raw TF 的 0.79。**R@k** 被相關集封頂、方向同 P@k。
- **結論**：TF-IDF 確實較好（RQ3）。RQ5：log 與 idf 全面有利，L2 只利於榜首指標，故 MAP / R-prec 選 ltn、nDCG@10 選 ltc、P@5 / R@20 ltn 與 ltc 並列、MRR 選 atc（1.000）；逐題仍有例外（q04 偏好 raw TF、q15 偏好正規化、q09 全差）。

RQ4 文件向量是否需要 L2 normalization？正規化前後的排名有何差異？

q10「polycystic ovary syndrome」	overlap@10	τ	mean len	P@10	nDCG@10
ltn log TF × IDF	1.00	1.00	230	1.00	0.775
ltc + L2	0.60	−0.17	165	1.00	0.528
nnn raw TF	0.50	0.09	215	0.70	0.609
nnc + L2	0.30	−0.32	152	0.80	0.525



各 scheme 前 10 名的平均長度（15 題平均）：未正規化 224–288，正規化 165–201。

- **變因**：固定 log tf × idf，只改第 ③ 位：ltn → ltc（raw tf 的 nnn → nnc 為對照）。
- **機制**：未正規化的內積 = ‖ d ‖ · cos θ，長文件多提幾次就贏；除以向量長度後只比方向。15 題平均 ltn 與 ltc 前 10 名只重疊 **48%**、τ ≈ 0，前 10 名平均長度 262 → 186。
- **效果**：本集合全是長度相近的摘要（平均 211、相關文件 217），收益小且方向不一：MAP 0.661 → 0.650，僅 6/15 題變好，MRR、nDCG@10 略升；raw tf 受益 0.451 → 0.487；30 個詞的更正啟事（*Correction:* …）在 ltc 下竄到第一名。混入 3 篇 PMC 全文（3,221–4,358 詞）後，10 題前 10 名的 100 個位置 nnn 被長文佔走 15 個、ltn 9 個，nnc / ltc 為 0（`report/rq4_mixed_lengths.py`）。
- **結論**：長度相近時可不正規化，長度懸殊時不可或缺；兩種情況的贏家不同，真正的問題是「正規化多少」，介於 n 與 c 之間的部分正規化是後續方向。

相關判斷的方法與限制（標籤規則、pooling 與 118 篇人工判讀、無標籤文件、數字 token）見第 5 頁附錄 D0；各題定義見附錄 B。

附錄 A SMART 權重代號對照表（tf · df · norm）

每個 weighting scheme 是三個字母，**依位置讀**：第 1 字母是 tf 怎麼算、第 2 字母是 df 怎麼用、第 3 字母是正規化。三個因素獨立，權重 = ① × ② 再做 ③，查詢端全程固定為 `nnc`（原始 tf、不乘 idf、cosine）。

l **t** **c** → `ltc` = (1 + ln tf) × ln(N / df)，再除以向量長度（cosine）。同理 `nnn` = 原始 tf、不乘 idf、不正規化。

① tf　② df　③ norm

A1　三個位置各自可填的字母

位置	字	名稱	公式	直覺 / 用意	本報告用到的 scheme
① tf 詞在這篇出現幾次（局部）	n	natural	`tf`	出現幾次算幾分；高頻詞獨占向量、偏好長文件（RQ1）	`nnn ntn nnc ntc`
	l	logarithm	`1 + ln tf`	加分逐次遞減：tf 30 只得 4.4、不是 30（RQ1）	`lnn ltn lnc ltc lpc`
	a	augmented	`0.5 + 0.5 · tf / max tf`	以該篇最大 tf 為基準，另一種壓平長文件的方法	`atc`
	b	boolean	`1`	只看有沒有出現，忽略次數	`btn`
② df 詞出現在幾篇文件（全域）	n	none	`1`	不管詞多常見	`nnn lnn nnc lnc`
	t	idf	`ln(N / df)`	常見詞降權、稀有詞升權：df 1,172 → 0.94，df 29 → 4.64（RQ2）	`btn ntn ltn ntc ltc atc`
	p	prob idf	`max(0, ln((N − df) / df))`	出現超過一半文件的詞權重直接歸 0	`lpc`
③ norm 向量要不要正規化	n	none	`w`	分數 = 內積；長文件向量長、分數高（RQ4）	`nnn lnn btn ntn ltn`
	c	cosine	`w / ‖d‖`	除以向量長度，分數 = cosine 相似度，長度不再有利（RQ4）	`nnc lnc ntc ltc atc lpc`

A2　本報告的 12 個 scheme

代號	① tf	② df	③ norm	白話	公式	用在	MAP	nDCG@10
`nnn`	n 原始	n 無	n 無	raw TF	`tf`	RQ1 RQ3 RQ4	0.451	0.545
`lnn`	l 對數	n 無	n 無	log TF	`1 + ln tf`	RQ1 RQ2	0.574	0.656
`btn`	b 布林	t idf	n 無	IDF only	`idf`	RQ3	0.546	0.640
`ntn`	n 原始	t idf	n 無	raw TF × IDF	`tf · idf`	RQ1 RQ3	0.599	0.642
`ltn`	l 對數	t idf	n 無	log TF × IDF	`(1 + ln tf) · idf`	RQ1–RQ4	**0.661**	0.692
`nnc`	n 原始	n 無	c cosine	raw TF, L2	`tf / ‖d‖`	RQ4	0.487	0.603
`lnc`	l 對數	n 無	c cosine	log TF, L2	`(1 + ln tf) / ‖d‖`	RQ2	0.574	0.663
`ntc`	n 原始	t idf	c cosine	raw TF × IDF, L2	`tf · idf / ‖d‖`	因素格	0.609	0.675
`ltc`	l 對數	t idf	c cosine	log TF × IDF, L2（教科書標準）	`(1 + ln tf) · idf / ‖d‖`	RQ2 RQ4 變形	0.650	**0.698**
`atc`	a 增強	t idf	c cosine	augmented TF × IDF, L2	`(0.5 + 0.5 tf / max tf) · idf / ‖d‖`	變形	0.603	0.668
`lpc`	l 對數	p 機率 idf	c cosine	log TF × prob IDF, L2	`(1 + ln tf) · max(0, ln((N − df) / df)) / ‖d‖`	變形	0.654	0.695
`bm25`	不屬於 SMART：tf 飽和 + 長度修正 + 機率 idf			Okapi BM25（對照組）	`k1 = 1.2，b = 0.75`	變形	0.656	0.683

MAP、nDCG@10 為 15 題平均、k = 10、含 118 篇人工判讀；粗體為該欄最高。對照實驗每組只改一個字母：RQ1 nnn→lnn、ntn→ltn；RQ2 lnn→ltn、lnc→ltc；RQ3 nnn / btn / ntn / ltn；RQ4 ltn→ltc、nnn→nnc。

A3　① tf 與 ② df 的關係：都取 log，但方向與層級不同

相同：1 + ln tf 與 ln(N / df) 都是「對一個計數取對數」，背後同一個想法：計數加倍，證據不該加倍。

不同：tf 是**局部**量（這篇文件裡的次數），權重隨 tf **遞增**，回答「這篇在講它嗎」；df 是**全域**量（整個語料出現在幾篇），權重隨 df **遞減**，回答「這個詞能區分文件嗎」。兩者各自獨立，所以 SMART 放在不同位置相乘；log tf 把 tf 壓到與 idf 同一量級，idf 的效果才顯現（RQ2）。

附錄 B 評估查詢 q01–q15：怎麼定義、怎麼在網頁上重現、怎麼讀數據

定義方式　每題 = 查詢文字 + 設計意圖 + 相關規則。規則由一到兩個「概念群」組成，每群是一組 MeSH 標題 / 作者關鍵詞的正則表示式；一篇文件的標籤把**每一群**都命中才算相關，命中的是 MeSH major topic 給 grade 2、否則 grade 1（標準表見附錄 D0）。規則只看標籤、不看標題摘要正文，所以不偏向任何 weighting。再以六種 scheme（nnn、lnn、btn、ltn、ltc、bm25）各取前 10 名做 pooling，規則判 0 的 118 篇由 AI 助理逐篇讀標題與摘要判讀（作者未逐篇複核），補回 37 篇漏標的相關文件（「人工」欄）。

id	查詢文字 / 設計意圖	相關規則（概念群；全部群都命中 → 相關）	相關 g2 / g1	MeSH / 關鍵詞 / 人工	AP nnn	AP ltn	AP bm25	P@10 ltn	R@10 ltn
q01	**semaglutide weight loss in obesity** 藥 + 病況，兩者在語料都常見	(semaglutide | wegovy | ozempic) AND (obes | overweight | weight loss …)	318 189/129	232/85/4	0.45	0.60	**0.61**	1.0	0.03
q02	**tirzepatide glycemic control in type 2 diabetes** 藥 + 病況；diabetes 是最常見詞之一（idf 低）	(tirzepatide | mounjaro | zepbound) AND (diabetes mellitus, type 2 | type 2 diabetes | t2dm? …)	131 82/49	97/32/16	0.15	**0.35**	0.34	0.8	0.06
q03	**GLP-1 receptor agonists and cardiovascular outcomes** 語料主題本身 + 結果；藥類詞幾乎沒有 idf	(glp-?1 ?r | glucagon-like peptide-?1 receptor agonist | incretin …) AND (cardiovascular | heart failure | myocardial …)	263 160/103	163/95/16	0.19	0.53	**0.55**	0.9	0.03
q04	**chronic kidney disease and diabetic nephropathy** 一個概念、多種寫法（CKD、renal insufficiency、DKD）	(renal insufficiency, chronic | chronic kidney | diabetic nephropath …)	198 91/107	109/86/6	0.50	**0.70**	0.66	1.0	0.05
q05	**gut microbiota and bile acid metabolism** 機制主題，多為動物實驗	(gastrointestinal microbiome | gut microbio | microbiota …)	132 48/84	69/61/2	0.70	**0.88**	0.86	1.0	0.08
q06	**fatty liver disease MASLD NAFLD steatohepatitis** 近年改名的主題（NAFLD → MASLD），同義詞多	(fatty liver | non-alcoholic | nonalcoholic …)	124 66/58	68/55/2	0.65	0.84	**0.85**	1.0	0.08
q07	**neuroprotection in Alzheimer's and Parkinson's disease** 神經主題；罕見、高 idf 詞	(alzheimer | parkinson | neurodegenerat …)	143 66/77	71/72/0	0.53	0.72	**0.72**	1.0	0.07
q08	**bariatric surgery versus medication for weight loss** 手術 vs 藥物的比較	(bariatric | gastric bypass | sleeve gastrectomy …)	139 66/73	81/57/5	0.37	0.82	**0.84**	1.0	0.07
q09	**gastrointestinal adverse events nausea vomiting** 安全性主題；查詢詞在摘要裡很常見，標籤只標以此為主題的文章	(nausea | vomiting | gastroparesis …)	68 26/42	32/29/19	0.18	0.31	**0.31**	0.8	0.12
q10	**polycystic ovary syndrome** 小而明確的主題（PCOS）	(polycystic ovar | pcos)	45 19/26	26/18/8	0.65	0.88	**0.91**	1.0	0.22
q11	**SGLT2 inhibitors combination therapy** 第二種藥類與 GLP-1 RA 併用	(sodium-glucose (co-?)? transporter | sglt-?2 | sglt2i …)	262 107/155	156/104/3	0.51	**0.61**	0.59	1.0	0.04
q12	**insulin secretion from pancreatic beta cells** 生理主題；insulin 常見、beta cell 專一	(insulin-secreting cells | beta[-]?cell | β[-]?cell …)	102 56/46	66/32/8	0.49	**0.57**	0.53	1.0	0.10
q13	**obstructive sleep apnea treatment** 新適應症（tirzepatide 治 OSA）	(sleep apnea | sleep apnoea | osa)	46 20/26	20/22/8	0.63	**0.92**	0.88	1.0	0.22
q14	**cost-effectiveness and health economics** 經濟研究：標籤專一、用詞通用	(cost-benefit | cost-effective | cost effective …)	30 14/16	20/6/6	0.66	**0.82**	0.78	1.0	0.33
q15	**type 1 diabetes adjunct therapy** 第 1 型 vs 常見得多的第 2 型：只差一個 token	(diabetes mellitus, type 1 | type 1 diabetes | t1dm? …)	51 34/17	36/15/15	0.11	0.36	**0.41**	0.9	0.18

AP 粗體 = 該題三者最高。R@10 受相關集大小封頂：q01 有 318 篇，前 10 名全對也只有 10/318 = 0.03；q14 只有 30 篇，10 篇對就是 0.33。R@k 只在同一題內比 scheme，跨題看 AP、nDCG。

在網頁上重現（/#vsm）

- **第 5 節 查詢表**：本表前五欄的來源。每列的「relevant set」列出該題全部相關文件、等級、命中的標籤與在所選 scheme 下的名次；「search」把查詢帶到第 3 節。
- **第 3 節 搜尋**：點 q01–q15 或自行輸入，選 Doc scheme 看前 k 名。每筆標 rel 1 / rel 2，長條是各查詢詞的貢獻 w(t,q)×w(t,d)；按 0 / 1 / 2 當場修改人工判讀。
- **第 4 節 對照實驗**：填入查詢、按 RQ1–RQ4 按鈕，一次只改一個字母；得 overlap@10、Kendall τ、平均長度、P@5 / P@10 / R@10 / AP / nDCG@10，下方並排各 scheme 的前 10 名（綠 = 相關）。
- **第 5 節 Evaluate → 第 6 節**：勾選 scheme、k、condensed，得 15 題平均表、2×2×2 因素格、逐題表；第 6 節的 RQ 結論由這些數字即時生成。

怎麼讀數據

- **P@k**：前 k 名裡相關的比例；與相關集大小無關，相關集大的題容易拿 1.0。
- **R@k**：前 k 名找回了相關集的幾分之幾，被相關集大小封頂（見上註）。
- **RR / MRR**：第一篇相關文件名次的倒數；1.0 = 第 1 名就相關。
- **AP / MAP**：每找到一篇相關文件就量一次 precision 再平均，相關文件排得愈前愈高；跨題、跨 scheme 比較的主指標。
- **nDCG@10**：分級版，grade 2 比 grade 1 值錢，名次愈後折扣愈重；grade 2 排在前面才高。
- **overlap@10 / Kendall τ**：兩個 scheme 前 10 名的交集比例與名次一致性；τ ≈ 0 表示榜單幾乎重排。
- **mean length**：前 10 名平均索引詞數（全集合 211）；偏高 = 偏好長文件（RQ4）。
- **讀表範例**：q03 AP nnn 0.19 → ltn 0.53，是 idf 把 cardiovascular 拉過 glp / receptor / agonist（RQ2）；q09 三者都只有 0.31，nausea、vomiting 幾乎每篇試驗都提到，標籤卻只標以此為主題的文章，是文字訊號與標籤分歧最大的一題；q15 ltc 0.44 > ltn 0.36，短查詢在正規化後較不被長文件淹沒；q14 是唯一 log tf 沒幫上的題（0.65 對 0.66）。

附錄 C 評估 12 種 scheme 用了哪些指標；BM25 怎麼處理資料、最接近哪一種

C1　評估指標一覽（15 題各算一次再平均；「相關」= grade ≥ 1；k 預設 10）

指標	定義	回答的問題	讀法與注意
P@5、P@10、P@20	前 k 名中相關文件的比例	榜首乾不乾淨	與相關集大小無關；相關集大的題容易 1.0。本報告 ltn / bm25 P@10 0.96
R@5、R@10、R@20	前 k 名找回了相關集的幾分之幾	找回了多少	被相關集大小封頂（q01 318 篇 → R@10 ≤ 0.03），只在同一題內比 scheme
RR → MRR	1 / 第一篇相關文件的名次，再平均	第一筆要翻多久	只看一篇；atc 1.000 代表 15 題第 1 名全相關
AP → MAP	每命中一篇相關文件就量一次 precision，加總後除以相關總數（未檢回者貢獻 0）	整條排名的品質	**主指標**：對相關文件排前排後都敏感，也看得到沒找回的。ltn 0.661 最高
R-prec	前 R 名的 precision，R = 該題相關集大小	P 與 R 的交會點	與 MAP 高度相關，做為交叉驗證（ltn 0.634）
nDCG@5 / 10 / 20	$\mathrm{DCG} = \Sigma\,(2^{\mathrm{grade}} - 1) / \log_2(\text{名次} + 1)$，除以理想排序的 DCG	分級相關 + 名次折扣	唯一用到 grade 2 / 1 的指標；grade 2 排在前面才高。ltc 0.698 最高
condensed 版	先移除沒有任何標籤的 163 篇再算上面各項	標籤缺漏的影響	各值略升、scheme 排序不變（ltn 0.661、nnn 0.453）
對照實驗專用	overlap@10（前 10 名交集比例）、Kendall τ（名次一致性）、mean length（前 10 名平均索引詞數）、mean max tf	排名變了多少、往哪邊變	不涉及相關性，純粹比兩個 scheme 的榜單；τ ≈ 0 = 幾乎重排，mean length 對照全集合 211

怎麼選主指標：P@k 只看頭、R@k 被相關集封頂、MRR 只看一篇；MAP 同時反映排序與找回，所以 RQ3 / RQ5 以 MAP 為主、nDCG@10 為輔，其餘供交叉檢查。

C2　BM25 怎麼處理資料

$$\mathrm{score}(q,d) = \Sigma_{t \in q}\ \mathrm{qtf}_t \cdot \mathrm{idf}(t) \cdot \frac{\mathrm{tf} \cdot (k_1 + 1)}{\mathrm{tf} + k_1 \cdot (1 - b + b \cdot |d| / \mathrm{avgdl})}$$

$k_1 = 1.2$，$b = 0.75$，avgdl = 211；$\mathrm{idf}(t) = \ln(1 + (N - \mathrm{df} + 0.5) / (\mathrm{df} + 0.5))$；查詢端用原始 qtf、不正規化

- **tf 飽和**（取代 SMART 第 ① 位）：權重有上限 $k_1 + 1 = 2.2$，壓得比 1 + ln tf 更兇。tf = 1 → 1.00、5 → 1.77、30 → 2.12（log 給 2.61、4.40）；「出現幾次」幾乎退化成「有沒有出現」，接近 b（布林）與 l 之間。
- **長度正規化**（取代第 ③ 位）：分母的 k_1 項乘上 $(1 - b + b \cdot |d|/\mathrm{avgdl})$。b = 0 完全不管長度（= n），b = 1 完全按長度打折；0.75 是「部分正規化」。兩倍長的文件 tf = 5 只剩 1.55，一半長的升到 1.91。它懲罰長度的方式是「同樣的 tf 在長文件裡算少一點」，不是 cosine 的「整支向量除以長度」。
- **機率型 idf**（取代第 ② 位）：$\ln(1 + (N - \mathrm{df} + 0.5)/(\mathrm{df} + 0.5))$ 與 $\ln(N/\mathrm{df})$ 幾乎重合（df 1 → 7.60 vs 8.01，df 100 以上完全相同），且不像 p（prob idf）會把過半文件出現的詞歸 0。

C3　BM25 與哪一種 SMART scheme 最接近

scheme		overlap@10 vs bm25	Kendall τ	前 10 名平均長度	MAP
bm25	**（自身）**	1.00	+1.00	205	0.656
ltn	**log TF × IDF**	**0.63**	**+0.23**	262	0.661
ltc	**log TF × IDF, L2**	0.58	+0.19	186	0.650
lpc	**log TF × prob IDF, L2**	0.56	+0.17	187	0.654
lnc	**log TF, L2**	0.56	+0.14	165	0.574
lnn	**log TF**	0.55	+0.10	266	0.574
atc	**augmented TF × IDF, L2**	0.52	−0.02	170	0.603
ntc	**raw TF × IDF, L2**	0.50	+0.05	201	0.609
ntn	**raw TF × IDF**	0.43	−0.05	274	0.599
nnc	**raw TF, L2**	0.43	−0.01	195	0.487
btn	**IDF only**	0.40	−0.14	224	0.546
nnn	**raw TF**	0.32	−0.19	288	0.451

overlap@10 與 τ 為 15 題平均，以 bm25 的前 10 名為基準。

- **結構上**：BM25 = 飽和 tf × 機率 idf × 部分長度正規化，三個位置分別介於 l 與 b、等於 t、介於 n 與 c 之間，所以它落在 **ltn 與 ltc 之間**。
- **實測上**：排名最像 ltn（overlap 0.63、τ +0.23），其次 ltc；前 10 名平均長度 205 正好夾在 ltn 262 與 ltc 186 之間，MAP 0.656 也夾在 0.661 與 0.650 之間。
- **離它最遠**的是 nnn（overlap 0.32、τ −0.19）：BM25 把 tf 飽和得最徹底，而 nnn 完全不壓 tf。
- **意義**：BM25 在此沒有贏過調好的 TF-IDF，價值在用一組參數同時處理飽和、idf、長度三件事；b = 0.75 在摘要與全文混合時最穩。

附錄 D NLM 的 MeSH 索引現在怎麼做、可靠嗎、對本報告的相關判斷有什麼影響

D0　本報告的相關判斷：方法與限制

資料集沒有現成標籤，依作業指示用**主題標籤**：每個查詢定義若干概念群（正規表示式），文件的每一群至少命中一個 MeSH 標題或作者關鍵詞即相關，命中 major-topic MeSH 為 grade 2；只看標籤不看文字，故不偏向任何 weighting，並可在介面手動覆寫。為補標籤漏標，對每題把六個 scheme 的前 10 名 pooling，規則判 0 的 **118 篇**由 AI 助理（Claude）讀標題與摘要逐篇判定：37 篇補為相關、81 篇確認不相關（逐題見附錄 B；清單在 `docs/manual_judgements_review.md`，作者尚未逐篇複核）；各指標上升 0.03–0.11，結論方向不變。限制：163 篇（5.4%）無任何標籤；57% 有 MeSH；規則由作者與 AI 助理共同撰寫，判讀由 AI 助理完成、作者未逐篇複核、只判讀前 10 名；相關集偏大（30–318）、R@k 絕對值低。另一觀察：純數字 token（佔詞彙 11.5%）df 小、idf 高，會混入 ltn 向量前列，移除數字可改善。

等級	標籤規則（自動）	人工判讀（AI 助理）採用的標準	在指標中的用法
rel 2	每個概念群都命中 ≥ 1 個標籤，且命中的 MeSH 標題至少一個帶 major-topic 星號（★）	查詢主題是摘要的主要對象，例如主要結果就是該病況的試驗	P@k、R@k、MRR、MAP 視為相關；nDCG 增益 $2^2 - 1 = 3$
rel 1	每個概念群都命中，但沒有 major-topic MeSH：只靠一般 MeSH 標題或作者關鍵詞	主題有實質討論但屬次要，例如副作用段落、次要結果	同樣視為相關；nDCG 增益 1
rel 0	任一概念群沒命中，或文件沒有任何標籤（163 篇）	只是順帶提及或無關	不相關；增益 0

人工判讀（`manual`）優先於規則；118 筆中 37 筆升為 rel 1 / 2、81 筆確認 rel 0。網頁第 3 節每筆結果的 rel 標籤滑鼠停留可看命中的標籤，帶 * 的是 major topic；第 5 節「relevant set」列出整題的相關集與等級。

D1　現行做法

- **人工時代**：MEDLINE 自 1960 年代起由 NLM 的專業索引員閱讀全文，從 MeSH 詞彙表挑 10–15 個標題，並以星號標出文章的主要主題（major topic）；作者關鍵詞則由作者自填，不受詞彙表控制。
- **2002–2021**：NLM 的 Medical Text Indexer（MTI）先以規則與機器學習推薦標題，索引員再審核，MTI 的推薦品質逐年提升。
- **2022 起全面自動化**：所有 MEDLINE 文獻改由演算法（MTIA）直接索引，人工只做「curation」覆核；**2024 年 4 月**改用神經網路模型 **MTIX**（以 2007–2022 的文獻訓練，輸入是標題、摘要與期刊資訊），覆核集中在高影響與常被檢索的領域。
- **時間差**：新文獻先以「in process」狀態進 PubMed，索引完成才有 MeSH；本集合 2026 年的文獻中 163 篇（5.4%）因此沒有任何標籤。

D2　可靠嗎

- **人與人之間本來就不一致**：Funk 與 Reid（1983）比較 760 篇被兩位索引員各自索引過的文章，主標題的一致性約 48%，核心概念約 61%，checktag（人類、年齡層等）約 75%；文章長度、語言與期刊優先級都不影響一致性。相關判斷的「標準答案」本身就有相當雜訊，這在資訊檢索評估裡是常態。
- **自動索引接近但未等同人工**：2026 年的系統性回顧（Giustini 等，JMLA）指出 MTIX 的索引速度大幅提升，但仍未達到與人工索引完全等價，約三分之一的紀錄仍需人工修正。
- **星號也是預測出來的**：major topic 旗標在自動索引下同樣由模型決定，所以本報告的 grade 2 / grade 1 之分也帶有模型誤差。

D3　對本報告的影響

- 正文說相關判斷「只看標籤不看正文，故不偏向任何 weighting」要加一個但書：MTIX 的輸入正是標題與摘要，標籤與檢索用的文字並非完全獨立，只是多了一層受控詞彙的分類，不直接等於詞頻，也不會因為某個詞重複出現就多給標籤。
- 漏標是真實存在的：pooling 後人工判讀的 118 篇中有 37 篇（31%）其實相關，比例與「約三分之一的紀錄需人工修正」一致；這是本報告加入人工判讀的理由。q13、q14 的漏標多半是 2026 年「in process」尚未索引的文獻。
- 因此結論只宣稱 scheme 之間的**相對**排序（加人工判讀前後排序不變），不宣稱任何絕對的 MAP 值。

D4　在網頁上怎麼看

- 第 5 節查詢表的「via MeSH / keywords only / manual」三欄顯示每題相關集各來自哪種標籤；點「relevant set」可看每篇命中的標籤，帶 * 的是 major topic。
- 第 3 節每筆結果展開「abstract ・ MeSH ・ keywords」即可對照 MTIX 給的標籤與摘要內容，判斷它漏了什麼。

資料來源：NLM Technical Bulletin 2024 年 3–4 月號「MTIX」；Giustini 等，Automated indexing in MEDLINE and the Medical Text Indexer (MTI), 2000–2025: a scoping review，*J Med Libr Assoc*（2026）；Funk ME, Reid CA. Indexing consistency in MEDLINE. *Bull Med Libr Assoc* 1983;71(2):176–183；NLM「Introduction to MeSH Indexing」。

附錄 E 課堂 demo 講稿：六個步驟展示向量空間檢索系統（約 15 分鐘）

每個 demo 同一節奏： ① **問** 「你猜會怎樣？」 ② **按** 只按一個按鈕 ③ **驗** 用畫面上的數字驗證　　共 6 個 demo，約 15 分鐘

Demo 1 一篇文件變成向量　第 2 節 · 2 分鐘

操作　PMID 留空按 Show vectors，勾 nnn、lnn、ltn 三張卡並排。

看什麼　nnn 的榜首是數字「0」，出現 38 次、佔向量 9%；lnn 把它壓到 4.6；ltn 的榜首換成 ascvd，因為它只出現在 29 篇。

向量空間模型的第一步不是算相似度，而是決定「哪些詞代表這篇文件」。

Demo 2 查詢也是向量，分數就是內積　第 3 節 · 3 分鐘

操作　點 q01 連結，Doc scheme 先選 nnn 按 Search，再改 ltc 按一次。

看什麼　每筆結果下方的貢獻長條：nnn 下 weight、loss 這種常見詞吃掉大半分數；ltc 下 semaglutide 一個詞佔最大塊。右側 rel 1 / rel 2 標籤讓觀眾直接數相關數。

分數 = Σ 查詢詞權重 × 文件詞權重，換權重就是換「誰說了算」。

Demo 3 改一個字母，整張榜單重排　第 4 節 · 3 分鐘

操作　填 q03「GLP-1 receptor agonists and cardiovascular outcomes」，按「RQ2 有無 IDF」。先請觀眾猜 lnn 的前 10 名會出現什麼。

看什麼　lnn 欄跑出腎臟、酒精、脫髮、睡眠呼吸中止；ltn 欄 9 篇綠色。表格 overlap 0.40、τ 0.05，兩張榜單幾乎無關。

glp、receptor、agonist 出現在八成文件，沒有 idf 時分數分給每一篇，剩下的只有雜訊。

Demo 4 長文件的優勢與正規化的代價　第 4 節 · 2 分鐘

操作　填 q10「polycystic ovary syndrome」，按「RQ4 L2 正規化」。

看什麼　ltn 前 10 名平均長度 230，ltc 降到 165，但 ltc 把一篇只有 30 個詞的更正啟事推到第一名；nDCG@10 從 0.775 掉到 0.528。

正規化不是免費的：它懲罰長文件，也獎勵「短到沒有別的詞稀釋」的文件。

Demo 5 長尾 idf 的陷阱（現場輸入）　第 3 節 · 2 分鐘

操作　輸入「semaglutide hepatocyte」，Doc scheme 選 ltc。

看什麼　第 3 名只命中 hepatocyte 兩次（分數 0.150），贏過第 6 名命中 semaglutide 十三次的文章（0.099）；hepatocyte 的 idf 5.6 是 semaglutide 1.44 的 4 倍。

idf 只看稀有、不看意義：一個罕見詞的一次出現可以壓過主題詞的十幾次。這是已知限制，也是討論題。

Demo 6 怎麼證明哪種比較好　第 5、6 節 · 3 分鐘

操作　先看查詢表的 relevant / via MeSH / manual 欄，點一題的「relevant set」；再勾全部 scheme、k = 10 按 Evaluate；最後勾 condensed 重跑。

看什麼　ltn MAP 0.661、ltc nDCG@10 0.698、bm25 P@5 0.973 各自粗體；condensed 後數字幾乎不動；第 6 節的結論文字跟著即時生成。

相關判斷來自標籤規則加 118 篇 AI 助理判讀（附錄 D0），不碰檢索用的權重，所以結果不偏向任何 scheme。

現場技巧

- 網址 `http://172.27.156.215:8090/#vsm`（WSL 的 IP 以 `hostname -I` 確認）；投影前把六節都先按過一次，結果載好才不會等。
- Demo 3 與 5 最有戲劇性，放在中段；Demo 6 收尾，直接接到第 1 頁的結論表。
- 第 3 節的 0 / 1 / 2 按鈕可順手示範人工判讀，示範完按 × 還原，否則評估數字會變。
- 報告第 1 頁的 RQ2 圖與 RQ4 表就是 Demo 3、4 的靜態版本，demo 後翻回報告對照，讓觀眾知道數字從哪裡來。
- 備援：網頁若出問題，終端機下列指令得到一模一樣的數字（服務以 `python3 app.py --host 0.0.0.0` 啟動，預設埠 8090）。

```
python3 cli.py vsm search  "semaglutide hepatocyte" --scheme ltc
python3 cli.py vsm compare "GLP-1 receptor agonists and cardiovascular outcomes" --schemes lnn,ltn
python3 cli.py vsm compare "polycystic ovary syndrome" --schemes ltn,ltc
python3 cli.py vsm eval --k 10
```