胡元楨（P77141105）

| 3,000 | 15,823 | 2×2×2 + 3 | 15 | 0.661 | 118 |
|---|---|---|---|---|---|
| PubMed 摘要（GLP-1，含 MeSH）；平均 211 索引詞（24–672） | 詞幹；45% 只出現在 1 篇（idf 8.01），42 個詞出現在 ≥ 1,000 篇 | 因素設計：tf raw/log × idf 有/無 × L2 有/無 = 8 種；另加 btn、atc、lpc 三個變形 | 評估查詢；相關集由 MeSH / 關鍵詞規則 + 118 篇人工判讀產生（30–318 篇） | 最佳 MAP：ltn（log TF × IDF）；raw TF 0.451 | 篇 AI 助理判讀（作者未複核），補回 37 篇漏標的相關文件；指標高 0.03–0.11，排序不變 |

**權重代號怎麼讀**　SMART 三字母依位置：**l**（①tf）　**t**（②df）　**c**（③正規化）　① tf：**n** 原始次數 · **l** 1+ln tf · **a** 增強 · **b** 布林　② df：**n** 不乘 · **t** idf · **p** 機率 idf　③ 正規化：**n** 無 · **c** cosine　例：`nnn` 原始 tf、`lnn` log tf、`ltn` log tf × idf、`ltc` 再加 cosine（完整對照表：第 2 頁附錄）

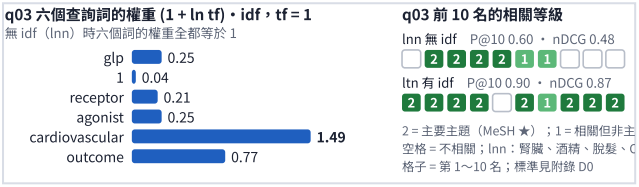
## RQ1 原始 TF 與 Log TF 的差異，如何影響詞項權重？

| tf | 1 | 2 | 5 | 10 | 30 | 50 |
|---|---|---|---|---|---|---|
| raw tf | 1 | 2 | 5 | 10 | 30 | 50 |
| 1 + ln tf | 1.00 | 1.69 | 2.61 | 3.30 | 4.40 | 4.91 |

- **例子**：FLOW 試驗摘要提到 semaglutide 7 次、cardiovascular 13 次。raw tf 說後者重要近兩倍；log 給 2.95 對 3.56、只差兩成，較接近人的判斷。
- **機制**：log 的加分逐次遞減（第 2 次 +0.69、第 30 次 +0.03），單一詞無法獨占向量：原始 tf 下（`nnn`）同篇由出現 38 次的「0」主宰、前 5 詞佔 22.5%；log tf（`lnn`）壓到 7.8%。
- **長文不公平**：文件愈長 tf 愈大，raw tf 等於替長文加分；q01 前 10 名平均長度 339 → 275（全集合 211）。
- **效果**：最有效的單一改動，MAP **0.451 → 0.574**（+27%，14/15 題提高）；壓平後 tf 與 idf 同量級，RQ2 的 idf 才量得出來。
- **結論**：詞頻增加，重要性不等比例增加。

## RQ2 為什麼 IDF 能降低常見詞的重要性、提高具辨識力詞項的權重？

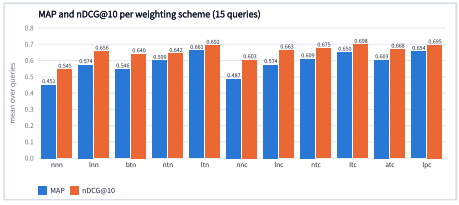
例題 q03「GLP-1 receptor agonists and cardiovascular outcomes」 · rel 2 / 1 / 0 = 相關且為主要主題 / 相關但非主要 / 不相關（附錄 D0）




- **變因**：固定 log tf，只在第 ② 位乘 idf：lnn → ltn、lnc → ltc。
- **機制**：idf 隨 df 遞減（df 1 → 8.01，N → 0）；出現在八成文件的 glp / receptor / agonist 每篇都加一樣，不改排名，只剩 tf 噪音。
- **效果**：q03 前 10 名相關 6 → 9 篇（左圖，nDCG@10 0.479 → 0.866）；整體 MAP **0.574 → 0.661**（+15%，15/15 題提高），lnc → ltc 0.574 → 0.650；只用 idf 的 btn 也有 0.546。
- **結論**：決定權從「常見詞重複幾次」移到「稀有詞有沒有出現」；短摘要裡有無出現幾乎與出現幾次同樣重要。

## RQ3 · RQ5 TF-IDF 是否產生較好的排名？不同 weighting 對各指標的影響

| scheme | | P@5 | P@10 | R@20 | MRR | MAP | nDCG@10 | R-prec |
|---|---|---|---|---|---|---|---|---|
| nnn | raw TF | 0.773 | 0.760 | 0.158 | 0.791 | 0.451 | 0.545 | 0.449 |
| lnn | log TF | 0.947 | 0.900 | 0.192 | 0.933 | 0.574 | 0.656 | 0.553 |
| btn | IDF only | 0.840 | 0.787 | 0.166 | 0.922 | 0.546 | 0.640 | 0.562 |
| ntn | raw TF × IDF | 0.907 | 0.880 | 0.195 | 0.933 | 0.599 | 0.642 | 0.574 |
| ltn | log TF × IDF | **0.960** | **0.960** | **0.205** | 0.933 | **0.661** | 0.692 | **0.634** |
| nnc | raw TF, L2 | 0.880 | 0.827 | 0.180 | 0.883 | 0.487 | 0.603 | 0.477 |
| lnc | log TF, L2 | 0.920 | 0.873 | 0.196 | 0.967 | 0.574 | 0.663 | 0.553 |
| ntc | raw TF × IDF, L2 | 0.933 | 0.920 | 0.199 | 0.967 | 0.609 | 0.675 | 0.585 |
| ltc | log TF × IDF, L2 | **0.960** | 0.940 | **0.205** | 0.956 | 0.650 | **0.698** | 0.622 |
| atc | augmented TF × IDF, L2 | 0.880 | 0.873 | 0.181 | **1.000** | 0.603 | 0.668 | 0.588 |
| lpc | log TF × prob IDF, L2 | 0.947 | 0.947 | 0.201 | 0.967 | 0.654 | 0.695 | 0.622 |

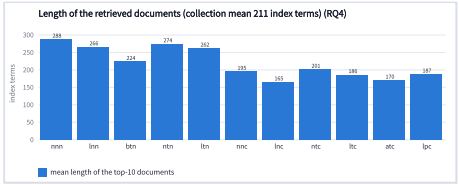



15 個查詢的平均 MAP 與 nDCG@10，含人工判讀（`cli.py vsm eval`、`vsm svg`）。

- **變因**：查詢端固定 nnc，文件端跑完 2×2×2 + 3 共 11 種 scheme，用 P@k、R@k、MRR、MAP、R-prec、nDCG@k 在 15 題上平均比較。
- **機制**：log 壓重複（RQ1）、idf 壓常見（RQ2）、L2 壓長度（RQ4）；MAP 看整條排名，P@k / MRR / nDCG@k 只看榜首，所以同一改動對不同指標的影響不同。
- **效果 RQ3**：MAP raw TF 0.451 → log TF 0.574 → IDF only 0.546 → TF-IDF（ltn）**0.661**，逐題 AP ltn 15/15 勝前三者；nDCG@10 前三名 ltc / lpc / ltn 全是 TF × IDF。
- **效果 RQ5**：**log tf 與 idf 對每個指標都是正向**，對 MAP 與 P@10 最大（log +0.12 / +0.14，idf +0.09 / +0.06）。**L2 看指標**：MRR 與 nDCG@10 上升（ltn → ltc 0.933 → 0.956、0.692 → 0.698；nnn → nnc 0.791 → 0.883、0.545 → 0.603），MAP 與 P@10 在 log × idf 上略降（0.661 → 0.650、0.960 → 0.940）。**MRR 最不敏感**：只要有 log 或 idf 就 0.92–1.00，只剩 raw TF 的 0.79。**R@k** 被相關集封頂、方向同 P@k。
- **結論**：TF-IDF 確實較好（RQ3）。RQ5：log 與 idf 全面有利，L2 只利於榜首指標，故 MAP / R-prec 選 ltn、nDCG@10 選 ltc、P@5 / R@20 ltn 與 ltc 並列、MRR 選 atc（1.000）；逐題仍有例外（q04 偏好 raw TF、q15 偏好正規化、q09 全差）。

## RQ4 文件向量是否需要 L2 normalization？正規化前後的排名有何差異？

| q10「polycystic ovary syndrome」 | overlap@10 | τ | mean len | P@10 | nDCG@10 |
|---|---|---|---|---|---|
| ltn log TF × IDF | 1.00 | 1.00 | 230 | 1.00 | 0.775 |
| ltc + L2 | 0.60 | −0.17 | 165 | 1.00 | 0.528 |
| nnn raw TF | 0.50 | 0.09 | 215 | 0.70 | 0.609 |
| nnc + L2 | 0.30 | −0.32 | 152 | 0.80 | 0.525 |




各 scheme 前 10 名的平均長度（15 題平均）：未正規化 224–288，正規化 165–201。

- **變因**：固定 log tf × idf，只改第 ③ 位：ltn → ltc（raw tf 的 nnn → nnc 為對照）。
- **機制**：未正規化的內積 = ‖ d ‖ · cos θ，長文件多提幾次就贏；除以向量長度後只比方向。15 題平均 ltn 與 ltc 前 10 名只重疊 **48%**、τ ≈ 0，前 10 名平均長度 262 → 186。
- **效果**：本集合全是長度相近的摘要（平均 211、相關文件 217），收益小且方向不一：MAP 0.661 → 0.650，僅 6/15 題變好，MRR、nDCG@10 略升；raw tf 受益 0.451 → 0.487；30 個詞的更正啟事（*Correction:* …）在 ltc 下竄到第一名。混入 3 篇 PMC 全文（3,221–4,358 詞）後，10 題前 10 名的 100 個位置 nnn 被長文佔走 15 個、ltn 9 個，nnc / ltc 為 0（`report/rq4_mixed_lengths.py`）。
- **結論**：長度相近時可不正規化，長度懸殊時不可或缺；兩種情況的贏家不同，真正的問題是「正規化多少」，介於 n 與 c 之間的部分正規化是後續方向。

相關判斷的方法與限制（標籤規則、pooling 與 118 篇人工判讀、無標籤文件、數字 token）見第 5 頁附錄 D0；各題定義見附錄 B。

## 附錄 A SMART 權重代號對照表（tf · df · norm）

每個 weighting scheme 是三個字母，**依位置讀**：第 1 字母是 tf 怎麼算、第 2 字母是 df 怎麼用、第 3 字母是正規化。三個因素獨立，權重 = ① × ② 再做 ③，查詢端全程固定為 `nnc`（原始 tf、不乘 idf、cosine）。

**l** **t** **c** → `ltc` = (1 + ln tf) × ln(N / df)，再除以向量長度（cosine）。同理 `nnn` = 原始 tf、不乘 idf、不正規化。

① tf　② df　③ norm

### A1　三個位置各自可填的字母

| 位置 | 字 | 名稱 | 公式 | 直覺 / 用意 | 本報告用到的 scheme |
|---|---|---|---|---|---|
| **① tf**<br>詞在這篇出現幾次（局部） | n | natural | `tf` | 出現幾次算幾分；高頻詞獨占向量、偏好長文件（RQ1） | `nnn ntn nnc ntc` |
| | l | logarithm | `1 + ln tf` | 加分逐次遞減：tf 30 只得 4.4、不是 30（RQ1） | `lnn ltn lnc ltc lpc` |
| | a | augmented | `0.5 + 0.5 · tf / max tf` | 以該篇最大 tf 為基準，另一種壓平長文件的方法 | `atc` |
| | b | boolean | `1` | 只看有沒有出現，忽略次數 | `btn` |
| **② df**<br>詞出現在幾篇文件（全域） | n | none | `1` | 不管詞多常見 | `nnn lnn nnc lnc` |
| | t | idf | `ln(N / df)` | 常見詞降權、稀有詞升權：df 1,172 → 0.94，df 29 → 4.64（RQ2） | `btn ntn ltn ntc ltc atc` |
| | p | prob idf | `max(0, ln((N − df) / df))` | 出現超過一半文件的詞權重直接歸 0 | `lpc` |
| **③ norm**<br>向量要不要正規化 | n | none | `w` | 分數 = 內積；長文件向量長、分數高（RQ4） | `nnn lnn btn ntn ltn` |
| | c | cosine | `w / ‖d‖` | 除以向量長度，分數 = cosine 相似度，長度不再有利（RQ4） | `nnc lnc ntc ltc atc lpc` |

### A2　本報告的 12 個 scheme

| 代號 | ① tf | ② df | ③ norm | 白話 | 公式 | 用在 | MAP | nDCG@10 |
|---|---|---|---|---|---|---|---|---|
| `nnn` | n 原始 | n 無 | n 無 | raw TF | `tf` | RQ1 RQ3 RQ4 | 0.451 | 0.545 |
| `lnn` | l 對數 | n 無 | n 無 | log TF | `1 + ln tf` | RQ1 RQ2 | 0.574 | 0.656 |
| `btn` | b 布林 | t idf | n 無 | IDF only | `idf` | RQ3 | 0.546 | 0.640 |
| `ntn` | n 原始 | t idf | n 無 | raw TF × IDF | `tf · idf` | RQ1 RQ3 | 0.599 | 0.642 |
| `ltn` | l 對數 | t idf | n 無 | log TF × IDF | `(1 + ln tf) · idf` | RQ1–RQ4 | **0.661** | 0.692 |
| `nnc` | n 原始 | n 無 | c cosine | raw TF, L2 | `tf / ‖d‖` | RQ4 | 0.487 | 0.603 |
| `lnc` | l 對數 | n 無 | c cosine | log TF, L2 | `(1 + ln tf) / ‖d‖` | RQ2 | 0.574 | 0.663 |
| `ntc` | n 原始 | t idf | c cosine | raw TF × IDF, L2 | `tf · idf / ‖d‖` | 因素格 | 0.609 | 0.675 |
| `ltc` | l 對數 | t idf | c cosine | log TF × IDF, L2（教科書標準） | `(1 + ln tf) · idf / ‖d‖` | RQ2 RQ4 變形 | 0.650 | **0.698** |
| `atc` | a 增強 | t idf | c cosine | augmented TF × IDF, L2 | `(0.5 + 0.5 tf / max tf) · idf / ‖d‖` | 變形 | 0.603 | 0.668 |
| `lpc` | l 對數 | p 機率 idf | c cosine | log TF × prob IDF, L2 | `(1 + ln tf) · max(0, ln((N − df) / df)) / ‖d‖` | 變形 | 0.654 | 0.695 |
| `bm25` | 不屬於 SMART：tf 飽和 + 長度修正 + 機率 idf | | | Okapi BM25（對照組） | `k1 = 1.2，b = 0.75` | 變形 | 0.656 | 0.683 |

MAP、nDCG@10 為 15 題平均、k = 10、含 118 篇人工判讀；粗體為該欄最高。對照實驗每組只改一個字母：RQ1 nnn→lnn、ntn→ltn；RQ2 lnn→ltn、lnc→ltc；RQ3 nnn / btn / ntn / ltn；RQ4 ltn→ltc、nnn→nnc。

### A3　① tf 與 ② df 的關係：都取 log，但方向與層級不同

**相同**：1 + ln tf 與 ln(N / df) 都是「對一個計數取對數」，背後同一個想法：計數加倍，證據不該加倍。

**不同**：tf 是**局部**量（這篇文件裡的次數），權重隨 tf **遞增**，回答「這篇在講它嗎」；df 是**全域**量（整個語料出現在幾篇），權重隨 df **遞減**，回答「這個詞能區分文件嗎」。兩者各自獨立，所以 SMART 放在不同位置相乘；log tf 把 tf 壓到與 idf 同一量級，idf 的效果才顯現（RQ2）。

# 附錄 B 評估查詢 q01–q15：怎麼定義、怎麼在網頁上重現、怎麼讀數據

**定義方式**　每題 = 查詢文字 + 設計意圖 + 相關規則。規則由一到兩個「概念群」組成，每群是一組 MeSH 標題 / 作者關鍵詞的正則表示式；一篇文件的標籤把**每一群**都命中才算相關，命中的是 MeSH major topic 給 grade 2、否則 grade 1（標準表見附錄 D0）。規則只看標籤、不看標題摘要正文，所以不偏向任何 weighting。再以六種 scheme（nnn、lnn、btn、ltn、ltc、bm25）各取前 10 名做 pooling，規則判 0 的 118 篇由 AI 助理逐篇讀標題與摘要判讀（作者未逐篇複核），補回 37 篇漏標的相關文件（「人工」欄）。

| id | 查詢文字 / 設計意圖 | 相關規則（概念群；全部群都命中 → 相關） | 相關 g2 / g1 | MeSH / 關鍵詞 / 人工 | AP nnn | AP ltn | AP bm25 | P@10 ltn | R@10 ltn |
|---|---|---|---|---|---|---|---|---|---|
| q01 | **semaglutide weight loss in obesity**<br>藥 + 病況，兩者在語料都常見 | (semaglutide \| wegovy \| ozempic) AND (obes \| overweight \| weight loss …) | 318<br>189/129 | 232/85/4 | 0.45 | 0.60 | **0.61** | 1.0 | 0.03 |
| q02 | **tirzepatide glycemic control in type 2 diabetes**<br>藥 + 病況；diabetes 是最常見詞之一（idf 低） | (tirzepatide \| mounjaro \| zepbound) AND (diabetes mellitus, type 2 \| type 2 diabetes \| t2dm? …) | 131<br>82/49 | 97/32/16 | 0.15 | **0.35** | 0.34 | 0.8 | 0.06 |
| q03 | **GLP-1 receptor agonists and cardiovascular outcomes**<br>語料主題本身 + 結果；藥類詞幾乎沒有 idf | (glp-?1 ?r \| glucagon-like peptide-?1 receptor agonist \| incretin …) AND (cardiovascular \| heart failure \| myocardial …) | 263<br>160/103 | 163/95/16 | 0.19 | 0.53 | **0.55** | 0.9 | 0.03 |
| q04 | **chronic kidney disease and diabetic nephropathy**<br>一個概念、多種寫法（CKD、renal insufficiency、DKD） | (renal insufficiency, chronic \| chronic kidney \| diabetic nephropath …) | 198<br>91/107 | 109/86/6 | 0.50 | **0.70** | 0.66 | 1.0 | 0.05 |
| q05 | **gut microbiota and bile acid metabolism**<br>機制主題，多為動物實驗 | (gastrointestinal microbiome \| gut microbio \| microbiota …) | 132<br>48/84 | 69/61/2 | 0.70 | **0.88** | 0.86 | 1.0 | 0.08 |
| q06 | **fatty liver disease MASLD NAFLD steatohepatitis**<br>近年改名的主題（NAFLD → MASLD），同義詞多 | (fatty liver \| non-alcoholic \| nonalcoholic …) | 124<br>66/58 | 68/55/2 | 0.65 | 0.84 | **0.85** | 1.0 | 0.08 |
| q07 | **neuroprotection in Alzheimer's and Parkinson's disease**<br>神經主題；罕見、高 idf 詞 | (alzheimer \| parkinson \| neurodegenerat …) | 143<br>66/77 | 71/72/0 | 0.53 | 0.72 | **0.72** | 1.0 | 0.07 |
| q08 | **bariatric surgery versus medication for weight loss**<br>手術 vs 藥物的比較 | (bariatric \| gastric bypass \| sleeve gastrectomy …) | 139<br>66/73 | 81/57/5 | 0.37 | 0.82 | **0.84** | 1.0 | 0.07 |
| q09 | **gastrointestinal adverse events nausea vomiting**<br>安全性主題；查詢詞在摘要裡很常見，標籤只標以此為主題的文章 | (nausea \| vomiting \| gastroparesis …) | 68<br>26/42 | 32/29/19 | 0.18 | 0.31 | **0.31** | 0.8 | 0.12 |
| q10 | **polycystic ovary syndrome**<br>小而明確的主題（PCOS） | (polycystic ovar \| pcos) | 45<br>19/26 | 26/18/8 | 0.65 | 0.88 | **0.91** | 1.0 | 0.22 |
| q11 | **SGLT2 inhibitors combination therapy**<br>第二種藥類與 GLP-1 RA 併用 | (sodium-glucose (co-?)? transporter \| sglt-?2 \| sglt2i …) | 262<br>107/155 | 156/104/3 | 0.51 | **0.61** | 0.59 | 1.0 | 0.04 |
| q12 | **insulin secretion from pancreatic beta cells**<br>生理主題；insulin 常見、beta cell 專一 | (insulin-secreting cells \| beta[- ]?cell \| β[- ]?cell …) | 102<br>56/46 | 66/32/8 | 0.49 | **0.57** | 0.53 | 1.0 | 0.10 |
| q13 | **obstructive sleep apnea treatment**<br>新適應症（tirzepatide 治 OSA） | (sleep apnea \| sleep apnoea \| osa) | 46<br>20/26 | 20/22/8 | 0.63 | **0.92** | 0.88 | 1.0 | 0.22 |
| q14 | **cost-effectiveness and health economics**<br>經濟研究：標籤專一、用詞通用 | (cost-benefit \| cost-effective \| cost effective …) | 30<br>14/16 | 20/6/6 | 0.66 | **0.82** | 0.78 | 1.0 | 0.33 |
| q15 | **type 1 diabetes adjunct therapy**<br>第 1 型 vs 常見得多的第 2 型：只差一個 token | (diabetes mellitus, type 1 \| type 1 diabetes \| t1dm? …) | 51<br>34/17 | 36/15/15 | 0.11 | 0.36 | **0.41** | 0.9 | 0.18 |

AP 粗體 = 該題三者最高。R@10 受相關集大小封頂：q01 有 318 篇，前 10 名全對也只有 10/318 = 0.03；q14 只有 30 篇，10 篇對就是 0.33。R@k 只在同一題內比 scheme，跨題看 AP、nDCG。

## 在網頁上重現（/#vsm）

- **第 5 節 查詢表**：本表前五欄的來源。每列的「relevant set」列出該題全部相關文件、等級、命中的標籤與在所選 scheme 下的名次；「search」把查詢帶到第 3 節。
- **第 3 節 搜尋**：點 q01–q15 或自行輸入，選 Doc scheme 看前 k 名。每筆標 rel 1 / rel 2，長條是各查詢詞的貢獻 w(t,q)×w(t,d)；按 0 / 1 / 2 當場修改人工判讀。
- **第 4 節 對照實驗**：填入查詢、按 RQ1–RQ4 按鈕，一次只改一個字母；得 overlap@10、Kendall τ、平均長度、P@5 / P@10 / R@10 / AP / nDCG@10，下方並排各 scheme 的前 10 名（綠 = 相關）。
- **第 5 節 Evaluate → 第 6 節**：勾選 scheme、k、condensed，得 15 題平均表、2×2×2 因素格、逐題表；第 6 節的 RQ 結論由這些數字即時生成。

## 怎麼讀數據

- **P@k**：前 k 名裡相關的比例；與相關集大小無關，相關集大的題容易拿 1.0。
- **R@k**：前 k 名找回了相關集的幾分之幾，被相關集大小封頂（見上註）。
- **RR / MRR**：第一篇相關文件名次的倒數；1.0 = 第 1 名就相關。
- **AP / MAP**：每找到一篇相關文件就量一次 precision 再平均，相關文件排得愈前愈高；跨題、跨 scheme 比較的主指標。
- **nDCG@10**：分級版，grade 2 比 grade 1 值錢，名次愈後折扣愈重；grade 2 排在前面才高。
- **overlap@10 / Kendall τ**：兩個 scheme 前 10 名的交集比例與名次一致性；τ ≈ 0 表示榜單幾乎重排。
- **mean length**：前 10 名平均索引詞數（全集合 211）；偏高 = 偏好長文件（RQ4）。
- **讀表範例**：q03 AP nnn 0.19 → ltn 0.53，是 idf 把 cardiovascular 拉過 glp / receptor / agonist（RQ2）；q09 三者都只有 0.31，nausea、vomiting 幾乎每篇試驗都提到，標籤卻只標以此為主題的文章，是文字訊號與標籤分歧最大的一題；q15 ltc 0.44 > ltn 0.36，短查詢在正規化後較不被長文件淹沒；q14 是唯一 log tf 沒幫上的題（0.65 對 0.66）。

# 附錄 C 評估 12 種 scheme 用了哪些指標；BM25 怎麼處理資料、最接近哪一種

## C1　評估指標一覽（15 題各算一次再平均；「相關」= grade ≥ 1；k 預設 10）

| 指標 | 定義 | 回答的問題 | 讀法與注意 |
|---|---|---|---|
| **P@5、P@10、P@20** | 前 k 名中相關文件的比例 | 榜首乾不乾淨 | 與相關集大小無關；相關集大的題容易 1.0。本報告 ltn / bm25 P@10 0.96 |
| **R@5、R@10、R@20** | 前 k 名找回了相關集的幾分之幾 | 找回了多少 | 被相關集大小封頂（q01 318 篇 → R@10 ≤ 0.03），只在同一題內比 scheme |
| **RR → MRR** | 1 / 第一篇相關文件的名次，再平均 | 第一筆要翻多久 | 只看一篇；atc 1.000 代表 15 題第 1 名全相關 |
| **AP → MAP** | 每命中一篇相關文件就量一次 precision，加總後除以相關總數（未檢回者貢獻 0） | 整條排名的品質 | **主指標**：對相關文件排前排後都敏感，也看得到沒找回的。ltn 0.661 最高 |
| **R-prec** | 前 R 名的 precision，R = 該題相關集大小 | P 與 R 的交會點 | 與 MAP 高度相關，做為交叉驗證（ltn 0.634） |
| **nDCG@5 / 10 / 20** | $\mathrm{DCG} = \Sigma\,(2^{\mathrm{grade}} - 1) / \log_2(\text{名次} + 1)$，除以理想排序的 DCG | 分級相關 + 名次折扣 | 唯一用到 grade 2 / 1 的指標；grade 2 排在前面才高。ltc 0.698 最高 |
| **condensed 版** | 先移除沒有任何標籤的 163 篇再算上面各項 | 標籤缺漏的影響 | 各值略升、scheme 排序不變（ltn 0.661、nnn 0.453） |
| **對照實驗專用** | overlap@10（前 10 名交集比例）、Kendall τ（名次一致性）、mean length（前 10 名平均索引詞數）、mean max tf | 排名變了多少、往哪邊變 | 不涉及相關性，純粹比兩個 scheme 的榜單；τ ≈ 0 = 幾乎重排，mean length 對照全集合 211 |

怎麼選主指標：P@k 只看頭、R@k 被相關集封頂、MRR 只看一篇；MAP 同時反映排序與找回，所以 RQ3 / RQ5 以 MAP 為主、nDCG@10 為輔，其餘供交叉檢查。

## C2　BM25 怎麼處理資料

$$\mathrm{score}(q,d) = \Sigma_{t \in q}\ \mathrm{qtf}_t \cdot \mathrm{idf}(t) \cdot \frac{\mathrm{tf} \cdot (k_1 + 1)}{\mathrm{tf} + k_1 \cdot (1 - b + b \cdot |d| / \mathrm{avgdl})}$$

$k_1 = 1.2$，$b = 0.75$，avgdl = 211；$\mathrm{idf}(t) = \ln(1 + (N - \mathrm{df} + 0.5) / (\mathrm{df} + 0.5))$；查詢端用原始 qtf、不正規化

- **tf 飽和**（取代 SMART 第 ① 位）：權重有上限 $k_1 + 1 = 2.2$，壓得比 1 + ln tf 更兇。tf = 1 → 1.00、5 → 1.77、30 → 2.12（log 給 2.61、4.40）；「出現幾次」幾乎退化成「有沒有出現」，接近 b（布林）與 l 之間。
- **長度正規化**（取代第 ③ 位）：分母的 $k_1$ 項乘上 $(1 - b + b \cdot |d|/\mathrm{avgdl})$。b = 0 完全不管長度（= n），b = 1 完全按長度打折；0.75 是「部分正規化」。兩倍長的文件 tf = 5 只剩 1.55，一半長的升到 1.91。它懲罰長度的方式是「同樣的 tf 在長文件裡算少一點」，不是 cosine 的「整支向量除以長度」。
- **機率型 idf**（取代第 ② 位）：$\ln(1 + (N - \mathrm{df} + 0.5)/(\mathrm{df} + 0.5))$ 與 $\ln(N/\mathrm{df})$ 幾乎重合（df 1 → 7.60 vs 8.01，df 100 以上完全相同），且不像 p（prob idf）會把過半文件出現的詞歸 0。

## C3　BM25 與哪一種 SMART scheme 最接近

| scheme | | overlap@10 vs bm25 | Kendall τ | 前 10 名平均長度 | MAP |
|---|---|---|---|---|---|
| bm25 | **（自身）** | 1.00 | +1.00 | 205 | 0.656 |
| ltn | **log TF × IDF** | **0.63** | **+0.23** | 262 | 0.661 |
| ltc | **log TF × IDF, L2** | 0.58 | +0.19 | 186 | 0.650 |
| lpc | **log TF × prob IDF, L2** | 0.56 | +0.17 | 187 | 0.654 |
| lnc | **log TF, L2** | 0.56 | +0.14 | 165 | 0.574 |
| lnn | **log TF** | 0.55 | +0.10 | 266 | 0.574 |
| atc | **augmented TF × IDF, L2** | 0.52 | −0.02 | 170 | 0.603 |
| ntc | **raw TF × IDF, L2** | 0.50 | +0.05 | 201 | 0.609 |
| ntn | **raw TF × IDF** | 0.43 | −0.05 | 274 | 0.599 |
| nnc | **raw TF, L2** | 0.43 | −0.01 | 195 | 0.487 |
| btn | **IDF only** | 0.40 | −0.14 | 224 | 0.546 |
| nnn | **raw TF** | 0.32 | −0.19 | 288 | 0.451 |

overlap@10 與 τ 為 15 題平均，以 bm25 的前 10 名為基準。

- **結構上**：BM25 = 飽和 tf × 機率 idf × 部分長度正規化，三個位置分別介於 l 與 b、等於 t、介於 n 與 c 之間，所以它落在 **ltn 與 ltc 之間**。
- **實測上**：排名最像 ltn（overlap 0.63、τ +0.23），其次 ltc；前 10 名平均長度 205 正好夾在 ltn 262 與 ltc 186 之間，MAP 0.656 也夾在 0.661 與 0.650 之間。
- **離它最遠**的是 nnn（overlap 0.32、τ −0.19）：BM25 把 tf 飽和得最徹底，而 nnn 完全不壓 tf。
- **意義**：BM25 在此沒有贏過調好的 TF-IDF，價值在用一組參數同時處理飽和、idf、長度三件事；b = 0.75 在摘要與全文混合時最穩。

# 附錄 D NLM 的 MeSH 索引現在怎麼做、可靠嗎、對本報告的相關判斷有什麼影響

## D0　本報告的相關判斷：方法與限制

資料集沒有現成標籤，依作業指示用**主題標籤**：每個查詢定義若干概念群（正規表示式），文件的每一群至少命中一個 MeSH 標題或作者關鍵詞即相關，命中 major-topic MeSH 為 grade 2；只看標籤不看文字，故不偏向任何 weighting，並可在介面手動覆寫。為補標籤漏標，對每題把六個 scheme 的前 10 名 pooling，規則判 0 的 **118 篇**由 AI 助理（Claude）讀標題與摘要逐篇判定：37 篇補為相關、81 篇確認不相關（逐題見附錄 B；清單在 `docs/manual_judgements_review.md`，作者尚未逐篇複核）；各指標上升 0.03–0.11，結論方向不變。限制：163 篇（5.4%）無任何標籤；57% 有 MeSH；規則由作者與 AI 助理共同撰寫，判讀由 AI 助理完成、作者未逐篇複核、只判讀前 10 名；相關集偏大（30–318）、R@k 絕對值低。另一觀察：純數字 token（佔詞彙 11.5%）df 小、idf 高，會混入 ltn 向量前列，移除數字可改善。

| 等級 | 標籤規則（自動） | 人工判讀（AI 助理）採用的標準 | 在指標中的用法 |
|---|---|---|---|
| **rel 2** | 每個概念群都命中 ≥ 1 個標籤，且命中的 MeSH 標題至少一個帶 major-topic 星號（★） | 查詢主題是摘要的主要對象，例如主要結果就是該病況的試驗 | P@k、R@k、MRR、MAP 視為相關；nDCG 增益 $2^2 - 1 = 3$ |
| **rel 1** | 每個概念群都命中，但沒有 major-topic MeSH：只靠一般 MeSH 標題或作者關鍵詞 | 主題有實質討論但屬次要，例如副作用段落、次要結果 | 同樣視為相關；nDCG 增益 1 |
| **rel 0** | 任一概念群沒命中，或文件沒有任何標籤（163 篇） | 只是順帶提及或無關 | 不相關；增益 0 |

人工判讀（`manual`）優先於規則；118 筆中 37 筆升為 rel 1 / 2、81 筆確認 rel 0。網頁第 3 節每筆結果的 rel 標籤滑鼠停留可看命中的標籤，帶 * 的是 major topic；第 5 節「relevant set」列出整題的相關集與等級。

## D1　現行做法

- **人工時代**：MEDLINE 自 1960 年代起由 NLM 的專業索引員閱讀全文，從 MeSH 詞彙表挑 10–15 個標題，並以星號標出文章的主要主題（major topic）；作者關鍵詞則由作者自填，不受詞彙表控制。
- **2002–2021**：NLM 的 Medical Text Indexer（MTI）先以規則與機器學習推薦標題，索引員再審核，MTI 的推薦品質逐年提升。
- **2022 起全面自動化**：所有 MEDLINE 文獻改由演算法（MTIA）直接索引，人工只做「curation」覆核；**2024 年 4 月**改用神經網路模型 **MTIX**（以 2007–2022 的文獻訓練，輸入是標題、摘要與期刊資訊），覆核集中在高影響與常被檢索的領域。
- **時間差**：新文獻先以「in process」狀態進 PubMed，索引完成才有 MeSH；本集合 2026 年的文獻中 163 篇（5.4%）因此沒有任何標籤。

## D2　可靠嗎

- **人與人之間本來就不一致**：Funk 與 Reid（1983）比較 760 篇被兩位索引員各自索引過的文章，主標題的一致性約 48%，核心概念約 61%，checktag（人類、年齡層等）約 75%；文章長度、語言與期刊優先級都不影響一致性。相關判斷的「標準答案」本身就有相當雜訊，這在資訊檢索評估裡是常態。
- **自動索引接近但未等同人工**：2026 年的系統性回顧（Giustini 等，JMLA）指出 MTIX 的索引速度大幅提升，但仍未達到與人工索引完全等價，約三分之一的紀錄仍需人工修正。
- **星號也是預測出來的**：major topic 旗標在自動索引下同樣由模型決定，所以本報告的 grade 2 / grade 1 之分也帶有模型誤差。

## D3　對本報告的影響

- 正文說相關判斷「只看標籤不看正文，故不偏向任何 weighting」要加一個但書：MTIX 的輸入正是標題與摘要，標籤與檢索用的文字並非完全獨立，只是多了一層受控詞彙的分類，不直接等於詞頻，也不會因為某個詞重複出現就多給標籤。
- 漏標是真實存在的：pooling 後人工判讀的 118 篇中有 37 篇（31%）其實相關，比例與「約三分之一的紀錄需人工修正」一致；這是本報告加入人工判讀的理由。q13、q14 的漏標多半是 2026 年「in process」尚未索引的文獻。
- 因此結論只宣稱 scheme 之間的**相對**排序（加人工判讀前後排序不變），不宣稱任何絕對的 MAP 值。

## D4　在網頁上怎麼看

- 第 5 節查詢表的「via MeSH / keywords only / manual」三欄顯示每題相關集各來自哪種標籤；點「relevant set」可看每篇命中的標籤，帶 * 的是 major topic。
- 第 3 節每筆結果展開「abstract ・ MeSH ・ keywords」即可對照 MTIX 給的標籤與摘要內容，判斷它漏了什麼。

資料來源：NLM Technical Bulletin 2024 年 3–4 月號「MTIX」；Giustini 等，Automated indexing in MEDLINE and the Medical Text Indexer (MTI), 2000–2025: a scoping review，*J Med Libr Assoc*（2026）；Funk ME, Reid CA. Indexing consistency in MEDLINE. *Bull Med Libr Assoc* 1983;71(2):176–183；NLM「Introduction to MeSH Indexing」。

# 附錄 E 課堂 demo 講稿：六個步驟展示向量空間檢索系統（約 15 分鐘）

每個 demo 同一節奏： ① **問** 「你猜會怎樣？」 ② **按** 只按一個按鈕 ③ **驗** 用畫面上的數字驗證　　共 6 個 demo，約 15 分鐘

### Demo 1 一篇文件變成向量　第 2 節 · 2 分鐘

**操作**　PMID 留空按 Show vectors，勾 nnn、lnn、ltn 三張卡並排。

**看什麼**　nnn 的榜首是數字「0」，出現 38 次、佔向量 9%；lnn 把它壓到 4.6；ltn 的榜首換成 ascvd，因為它只出現在 29 篇。

**向量空間模型的第一步不是算相似度，而是決定「哪些詞代表這篇文件」。**

### Demo 2 查詢也是向量，分數就是內積　第 3 節 · 3 分鐘

**操作**　點 q01 連結，Doc scheme 先選 nnn 按 Search，再改 ltc 按一次。

**看什麼**　每筆結果下方的貢獻長條：nnn 下 weight、loss 這種常見詞吃掉大半分數；ltc 下 semaglutide 一個詞佔最大塊。右側 rel 1 / rel 2 標籤讓觀眾直接數相關數。

**分數 = Σ 查詢詞權重 × 文件詞權重，換權重就是換「誰說了算」。**

### Demo 3 改一個字母，整張榜單重排　第 4 節 · 3 分鐘

**操作**　填 q03「GLP-1 receptor agonists and cardiovascular outcomes」，按「RQ2 有無 IDF」。先請觀眾猜 lnn 的前 10 名會出現什麼。

**看什麼**　lnn 欄跑出腎臟、酒精、脫髮、睡眠呼吸中止；ltn 欄 9 篇綠色。表格 overlap 0.40、τ 0.05，兩張榜單幾乎無關。

**glp、receptor、agonist 出現在八成文件，沒有 idf 時分數分給每一篇，剩下的只有雜訊。**

### Demo 4 長文件的優勢與正規化的代價　第 4 節 · 2 分鐘

**操作**　填 q10「polycystic ovary syndrome」，按「RQ4 L2 正規化」。

**看什麼**　ltn 前 10 名平均長度 230，ltc 降到 165，但 ltc 把一篇只有 30 個詞的更正啟事推到第一名；nDCG@10 從 0.775 掉到 0.528。

**正規化不是免費的：它懲罰長文件，也獎勵「短到沒有別的詞稀釋」的文件。**

### Demo 5 長尾 idf 的陷阱（現場輸入）　第 3 節 · 2 分鐘

**操作**　輸入「semaglutide hepatocyte」，Doc scheme 選 ltc。

**看什麼**　第 3 名只命中 hepatocyte 兩次（分數 0.150），贏過第 6 名命中 semaglutide 十三次的文章（0.099）；hepatocyte 的 idf 5.6 是 semaglutide 1.44 的 4 倍。

**idf 只看稀有、不看意義：一個罕見詞的一次出現可以壓過主題詞的十幾次。這是已知限制，也是討論題。**

### Demo 6 怎麼證明哪種比較好　第 5、6 節 · 3 分鐘

**操作**　先看查詢表的 relevant / via MeSH / manual 欄，點一題的「relevant set」；再勾全部 scheme、k = 10 按 Evaluate；最後勾 condensed 重跑。

**看什麼**　ltn MAP 0.661、ltc nDCG@10 0.698、bm25 P@5 0.973 各自粗體；condensed 後數字幾乎不動；第 6 節的結論文字跟著即時生成。

**相關判斷來自標籤規則加 118 篇 AI 助理判讀（附錄 D0），不碰檢索用的權重，所以結果不偏向任何 scheme。**

## 現場技巧

- 網址 `http://172.27.156.215:8090/#vsm`（WSL 的 IP 以 `hostname -I` 確認）；投影前把六節都先按過一次，結果載好才不會等。
- Demo 3 與 5 最有戲劇性，放在中段；Demo 6 收尾，直接接到第 1 頁的結論表。
- 第 3 節的 0 / 1 / 2 按鈕可順手示範人工判讀，示範完按 × 還原，否則評估數字會變。
- 報告第 1 頁的 RQ2 圖與 RQ4 表就是 Demo 3、4 的靜態版本，demo 後翻回報告對照，讓觀眾知道數字從哪裡來。
- 備援：網頁若出問題，終端機下列指令得到一模一樣的數字（服務以 `python3 app.py --host 0.0.0.0` 啟動，預設埠 8090）。

```
python3 cli.py vsm search  "semaglutide hepatocyte" --scheme ltc
python3 cli.py vsm compare "GLP-1 receptor agonists and cardiovascular outcomes" --schemes lnn,ltn
python3 cli.py vsm compare "polycystic ovary syndrome" --schemes ltn,ltc
python3 cli.py vsm eval --k 10
```