9,603 / 3,299
ModApte train（word2vec 訓練）/ test（檢索集合）；相關性 = TOPICS 標籤

9,996
詞向量詞彙（min_count 5）；覆蓋 test 詞元 93%、詞型 46%；6 個模型（sg / CBOW × d50 / d100…）

A · B · C · D
TF-IDF · TF-IDF 加權詞向量 · 詞向量平均 · 融合；同一組詞、同一 cosine 排序

20
查詢 = 5 主題 × 4 種用字（主題詞／路透慣用詞／同義改寫／情境描述）

0.730 → 0.865
P@10：A → B（skip-gram d100）；MRR 0.824 → 0.942；nDCG@10 0.605 → 0.735

0.64 → 0.80
同義改寫查詢的 P@10；主題詞查詢 0.92 = 0.92：收益全來自用字不同的查詢

1 資料、模型與四種文件表示

Reuters-21578（22 個 SGML 檔、21,578 則 1987 年新聞）自行解析：實體解碼、移除控制字元與 "Reuter" 署名、硬換行段落接回句子。**ModApte** = `TOPICS="YES"` 且 LEWISSPLIT TRAIN／TEST。train 9,603 篇（68K 句、763K 詞元）訓練 word2vec（negative sampling、dynamic window；skip-gram d100 5 epochs 21 分鐘、CBOW 6.7 分鐘）；test 3,299 篇是檢索集合（平均 74.5 詞、詞彙 17,295）。

所有方法用**同一組詞**（小寫、去停用詞、不 stemming）與 cosine：**A** TF-IDF `ltc`；**C** 詞向量平均 Σ tf · v；**B** TF-IDF 加權平均 Σ (1+ln tf) · idf · v；**D** $\alpha \cdot \cos_A + (1-\alpha) \cdot \cos_B$；$A_0$ = Project #3 的 Porter-stemmed TF-IDF（對照）。

相關性：查詢針對一個主題，test 文件帶該主題即相關（grade 2 = 唯一主題）。TOPICS 由路透編目員指派，與檢索方法無關。

topic	train	test	test 唯一主題	查詢例（同義改寫）
earn 獲利	2,877	1,087	1,083	corporate financial performance for the
acq 併購	1,650	719	696	merger agreement between two firms
crude 原油	389	189	121	**petroleum** production and output
grain 穀物	433	149	10	**cereal** crop production forecast
trade 貿易	369	117	75	import tariffs and export restrictions

每主題另有主題詞（crude oil prices）、路透慣用詞（OPEC barrel output quota）、情境描述（energy exploration and drilling）三個查詢；全部 20 個見附錄。

2 Word-level：Top-5 最近鄰（skip-gram d100 ／ CBOW d100）

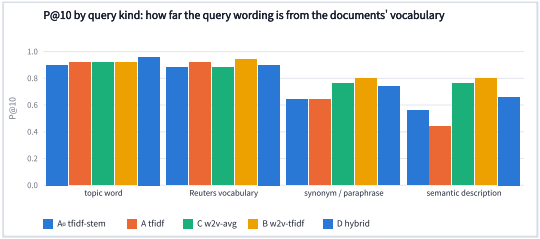
詞	skip-gram	CBOW
`oil`	crude .74 · gas .69 · petroleum .64 · pipeline .62 · natural .61	crude .80 · natural .80 · fuel .76 · pipeline .76 · postings .76
`petroleum`	king .70 · xon .69 · esso .69 · gas .68 · inland .68	mines .92 · columbia .86 · mining .84 · pty .84 · pacific .83
`opec`	bpd .78 · lukman .77 · nazer .77 · arabia .77 · ceiling .76	producer .90 · colombia .86 · arabia .85 · import .85 · coffee .84
`profit`	loss .79 · oper .78 · pre-tax .77 · profits .75 · comalco .75	pre-tax .88 · loss .86 · profits .85 · pretax .83 · attributable .82
`acquisition`	transaction .77 · merger .76 · buyout .72 · acquisitions .71 · comdata .70	buyout .92 · lbo .87 · merger .87 · borg-warner .86 · leveraged .86
`grain`	corn .77 · wheat .77 · cotton .72 · feed .71 · soybeans .71	soybeans .93 · winter .93 · corn .92 · feed .92 · grains .92
`cereal` (n=24)	grants .92 · bread .89 · spanish .89 · non-ec .89 · levies .88	availability .95 · ghana .95 · fixing .95 · featured .95 · artificially .94
`trade`	yeutter .64 · gatt .62 · surpluses .61 · tariffs .60 · bilateral .60	tariffs .71 · taiwan .67 · bilateral .67 · korea .67 · yeutter .66
`deficit`	surplus .86 · deficits .78 · widened .74 · narrowed .74 · invisibles .73	surplus .96 · balance .84 · account .83 · invisibles .82 · narrowed .82

- **合理的語意／用法關係：**oil–crude–gas、grain–corn–wheat、acquisition–merger–buyout、deficit–surplus；詞形變化 profit / profits、deficit / deficits 也靠近（stemming 用規則做的事）。
- **情境共現（同一類新聞的固定班底）：**opec–lukman–nazer–ceiling（同篇 6–42、PMI 3.8–4.7）、trade–yeutter–gatt–korea、acquisition–borg-warner。**反義詞 profit / loss .79、rise / fall .87、buy / sell .77**：同句位互換，向量只知「用法相同」不知「意思相反」→ 相近 ≠ 同義。
- **不符預期：**petroleum 的鄰居是公司名／礦業詞——語料裡它多半是 British / Pacific / Esso *Petroleum* 的一部分，含它的 test 文件只 44% 是 crude、29% 是 acq；cereal、tariff（訓練 24 / 38 次）鄰居隨機且 cosine 虛高（.88–.96），兩模型 Top-5 零重疊；CBOW 向量較平滑，cosine 普遍偏高、無關鄰居較多（opec–coffee 同篇 0）。

3 Document-level：20 個主題查詢的檢索評估

run（test 3,299 篇）	P@10	MRR	nDCG@10	MAP	主題詞	慣用詞	同義改寫	情境描述
A_0 TF-IDF stems	.745	.824	.623	.369	.90	.88	.64	.56
A TF-IDF	.730	.824	.605	.341	**.92**	.92	.64	.44
C 平均 · CBOW	.755	.762	.630	.610	.90	.86	.56	.70
C 平均 · skip-gram	.830	.912	.714	.638	.92	.88	.76	.76
B 加權 · CBOW	.790	.870	.670	.605	.90	.86	.66	.74
B 加權 · skip-gram	**.865**	**.942**	**.735**	**.644**	.92	**.94**	**.80**	**.80**
D 融合 α=.5 · skip-gram	.815	.942	.705	.640	.96	.90	.74	.66
D 融合 α=.2 · skip-gram	.885	.963	.757	.649	1.00	.92	.80	.82

右四欄 = P@10 依查詢用字分類。MAP 的大差距反映 TF-IDF 的召回上限（只對含查詢詞的文件給分，c03 只檢回 284 篇），不是前十名品質；主要指標是 P@10 / MRR / nDCG@10。逐題 P@10：B 勝 9、A 勝 5（c01 g01 g03 g04 t03）、平手 6。



P@10 依查詢用字：用字離新聞詞彙越遠（往右），TF-IDF 掉得越多；B（橙）維持 0.80。

4 研究問題的結論

- **RQ1 詞層級。**接近有三種來源——同語意場／同句型、同一類新聞的共現、稀有詞雜訊——要用同篇數、PMI 與主題分布才分得開；反義詞 cosine 高達 .77–.92，向量相近不代表同義。
- **RQ2 詞彙 vs 語意匹配。**主題詞與慣用詞查詢 TF-IDF 與 B 同為 .92；同義改寫 .64 → .80、情境描述 .44 → .80。stemming（A_0）是 TF-IDF 自己的有限語意匹配（.44 → .56）。語意匹配的代價：情境相近但主題不同的誤配（鋅、鋁產量）、稀有查詢詞的不穩定向量（t03 .9 → .7）。
- **RQ3 核心 A vs B。**skip-gram：P@10 +18%、MRR +14%、nDCG@10 +21%，收益全在用字不同的查詢；CBOW 收益減半。這不是「詞向量一定較好」：C · CBOW 的 MRR（.762）低於 TF-IDF（.824）。
- **RQ4 CBOW vs skip-gram。**5 epochs 下 skip-gram 較好（逐題 7 : 2 : 11）；但 CBOW 10 epochs 反而退步（loss 1.95 → 1.65，P@10 .790 → .770）、skip-gram 視窗 2 退到 .800、維度 50 / 100 幾乎無差（sg-d50 .885）。763K 詞元的小語料上差距受參數與 seed 左右，不應預設 skip-gram 必勝；詞層級 Top-5 只重疊 1–3 個，但文件層級差距小得多——文件向量把個別鄰居的差異平均掉了。
- **RQ5 加權與融合。**不加權平均 C 讓 said、mln、dlrs 把所有文件拉向同一方向（MRR .912 vs B .942；CBOW .762 vs .870）；融合在 α = .2 最佳（nDCG@10 .757），預設 α = .5 比純 B 差。限制：加權平均不保留詞序與否定；相關性只來自 TOPICS；每主題 4 題、共 20 題，差距 < .05 不應視為顯著；結論限於小型新聞語料。

A 附錄：20 個查詢與逐題 P@10（A TF-IDF vs B 加權 · skip-gram d100）

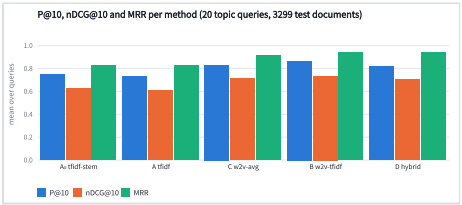
id	topic	kind	query	relevant	grade 2	A P@10	B P@10	A nDCG@10	B nDCG@10
e01	earn	topic	quarterly net profit results	1,087	1,083	1.00	1.00	1.00	1.00
e02	earn	domain	company reports earnings per share	1,087	1,083	1.00	1.00	1.00	1.00
e03	earn	synonym	corporate financial performance for the year	1,087	1,083	0.40	**0.80**	0.40	**0.84**
e04	earn	semantic	income statement with revenue and sales figures	1,087	1,083	0.70	**0.90**	0.75	**0.94**
a01	acq	topic	acquisition of a company	719	696	1.00	1.00	1.00	1.00
a02	acq	domain	takeover bid for shares	719	696	0.90	**1.00**	0.89	**1.00**
a03	acq	synonym	merger agreement between two firms	719	696	0.90	**1.00**	0.94	**1.00**
a04	acq	semantic	buying a controlling stake in a business	719	696	0.50	**1.00**	0.43	**1.00**
c01	crude	topic	crude oil prices	189	121	**1.00**	0.90	**1.00**	0.86
c02	crude	domain	OPEC barrel output quota	189	121	1.00	1.00	1.00	1.00
c03	crude	synonym	petroleum production and output	189	121	0.20	**0.80**	0.14	**0.48**
c04	crude	semantic	energy exploration and drilling	189	121	0.30	**0.90**	0.23	**0.45**
g01	grain	topic	grain exports	149	10	**1.00**	0.80	**0.56**	0.47
g02	grain	domain	wheat and corn harvest	149	10	1.00	1.00	0.33	**0.38**
g03	grain	synonym	cereal crop production forecast	149	10	**0.80**	0.70	**0.26**	0.26
g04	grain	semantic	agriculture department crop report	149	10	**0.50**	0.40	0.14	**0.17**
t01	trade	topic	international trade dispute	117	75	0.60	**0.90**	0.52	**0.93**
t02	trade	domain	trade deficit and surplus	117	75	0.70	0.70	**0.59**	0.54
t03	trade	synonym	import tariffs and export restrictions	117	75	**0.90**	0.70	**0.70**	0.53
t04	trade	semantic	protectionism and talks between countries	117	75	0.20	**0.80**	0.21	**0.86**

kind：topic = 主題詞、domain = 路透慣用詞、synonym = 同義／改寫、semantic = 情境描述。相關 = test 文件帶該主題；grade 2 = 該主題是文件唯一主題。

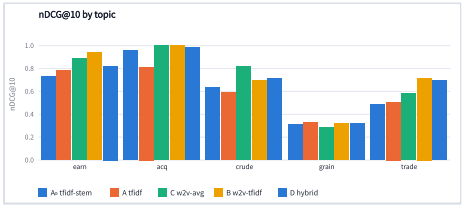
c03「petroleum production and output」：A 的前 10 名是 3 篇工業產出（ipi）、2 篇併購（British Petroleum 股權）、穀物、jet fuel、汽車產量，只有 2 篇 crude（P@10 .20、RR .14）；B 的前 10 名 8 篇 crude（Malaysia / Saudi / Norway oil output、API 庫存週報——其中 2 篇不含任何查詢詞，靠 petroleum→oil .77、output→bpd .75 配到），誤配是鋅、鋁產量（P@10 .80、RR 1.0）。

B 附錄：所有模型的評估（B 加權詞向量方法；P@10 / MRR / nDCG@10 / MAP）

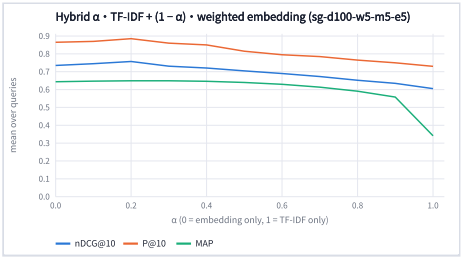
模型	架構	dim	window	epochs	loss	訓練時間	P@10	MRR	nDCG@10	MAP	C 平均 P@10	D α=.5 P@10
sg-d100-w5-m5-e5	skip-gram	100	5	5	2.117	21.3 min	**.865**	**.942**	**.735**	.644	.830	.815
sg-d50-w5-m5-e5	skip-gram	50	5	5	2.141	11.5 min	.885	.942	.725	.642	.835	.830
sg-d100-w2-m5-e5	skip-gram	100	2	5	2.054	13.3 min	.800	.840	.656	.610	.770	.795
cbow-d100-w5-m5-e5	CBOW	100	5	5	1.951	6.7 min	.790	.870	.670	.605	.755	.810
cbow-d50-w5-m5-e5	CBOW	50	5	5	1.947	3.5 min	.800	.873	.680	.611	.740	.810
cbow-d100-w5-m5-e10	CBOW	100	5	10	1.647	13.5 min	.770	.860	.664	.634	.750	.835
A TF-IDF（無模型）					surface words, ltc		.730	.824	.605	.341	–	–
A₀ TF-IDF stems					Porter, ltc		.745	.824	.623	.369	–	–



P@10、nDCG@10、MRR per method（active model = skip-gram d100）。



nDCG@10 依主題：grain 是唯一 TF-IDF 較好的主題（詞彙固定，且 grade 2 只有 10 篇使理想 DCG 偏高）。



D 的 α 掃描（skip-gram）：少量 TF-IDF（α = 0.2）最佳；α ≥ 0.5 逐漸退回 TF-IDF。CBOW 的最佳 α = 0.7，僅 +0.006。

C 附錄：詞對的 cosine（skip-gram d100）與方法的計算方式

a	b	cosine	同篇（train）	PMI	
oil	crude	.743	216	2.4	同義／同場
oil	petroleum	.637	194	2.1	同義（但 petroleum 多為公司名）
grain	wheat	.765	82	2.7	上下位
grain	cereal	.549	3	1.9	同義，但 cereal 稀有
acquisition	merger	.756	61	1.4	近義
trade	tariff	.452	17	2.0	相關；tariff 稀有
profit	loss	**.793**	569	1.8	**反義**，同句位
rise	fall	**.866**	147	1.6	**反義**
buy	sell	**.771**	99	1.2	**反義**

前處理（所有方法相同）：`WORD_RE` 取字母開頭、可含連字號的詞 → 小寫 → 移除停用詞與單字母 → 純數字丟棄；不做 stemming（A₀ 除外）。

A $w(t,d) = (1 + \ln tf) \cdot \ln(N/df)$，查詢同；兩側 L2 正規化 → 內積 = cosine。**C** $d = \Sigma\, tf \cdot v_t / \Sigma\, tf$。**B** $d = \Sigma\, (1+\ln tf) \cdot idf \cdot v_t / \Sigma\, w$；查詢 q 同式；再 L2 正規化；score = q · d。**D** $score = \alpha \cdot \cos_A + (1-\alpha) \cdot \cos_B$，兩側皆無正分的文件不檢回（α = 1 即 A）。

OOV：不在 9,996 詞彙中的詞跳過（test 詞型 54%、詞元 7%）；查詢全 OOV → 空排名。**解釋**：每筆結果列出查詢詞是否在文件中，以及每個查詢詞在該文件中 cosine 最高的 3 個詞（語意／情境匹配的證據）。

評估：P@k、R@k、RR、AP、nDCG@k（gain 2^g-1、$\log_2$ 折扣）由 `ir/evaluation.py`（Project #3）計算；未檢回文件視為不相關。