Reuters-21578：從 TF-IDF 到 Word Embedding 的新聞檢索實驗

胡元楨（P77141105）· 繳交 2026-11-10 · 全部以純 Python 標準函式庫自行實作：`ir/reuters.py`（SGML 解析、ModApte、TOPICS 相關性）、`ir/embedding.py`（文件向量、融合、共現）、`ir/word2vec.py`（CBOW / skip-gram）、`ir/tfidf.py`、`ir/evaluation.py`；網頁 `/#emb`、CLI `cli.py reuters …`、單元測試 `tests/test_project4.py`（19）；詳文 `REPORT_embedding.md`，數字皆可由頁尾指令重現。

9,603 / 3,299
ModApte train（訓練詞向量）/ test（檢索集合）；相關性 = TOPICS 標籤，與方法無關

9,996 詞
word2vec 詞彙（min_count 5）；覆蓋 test 詞元 93%、詞型 46%；6 個模型 sg / CBOW × d50 / d100

A · B · C · D
TF-IDF · TF-IDF 加權詞向量 · 詞向量平均 · 融合；同一組詞、同一 cosine

20 查詢
5 主題 × 4 種用字：主題詞／路透慣用詞／同義改寫／情境描述

.730 → .865
P@10 A → B（skip-gram d100）；MRR .824 → .942；nDCG@10 .605 → .735

.92 = .92
主題詞查詢 A 與 B 打平；收益全在用字不同的查詢（同義改寫 .64 → .80、情境 .44 → .80）

任務一 資料集、相關性判斷、TF / DF / IDF / TF-IDF 與 cosine

spec 1–3

資料。自行解析 22 個 SGML 檔（21,578 則 1987 年新聞）。**ModApte** = `TOPICS="YES"` 且 LEWISSPLIT TRAIN / TEST → train 9,603 篇（68K 句、763K 詞元）只用來訓練 word2vec；test 3,299 篇（平均 74.5 詞、詞彙 17,295）是檢索集合。**相關性**：每個查詢針對一個主題，test 文件帶該主題即相關（唯一主題 = grade 2，否則 grade 1）；TOPICS 由路透編目員指派，與查詢字和方法無關。

TF-IDF。沿用 Project #3 的向量空間模型：tf(t,d)、df(t)、idf = ln(N/df)，`ltc` 權重 (1+ln tf)·idf 後 L2 正規化，分數 = 內積 = cosine。TF-IDF 與詞向量使用**完全相同的詞**（小寫、去停用詞、不 stemming）；Porter-stemmed 的 Project #3 管線另列為 A_0 對照。df 越大 idf 越小：said df 2,026 → idf 0.49、mln 1,609 → 0.72、dlrs 1,451 → 0.82；petroleum df 90 → 3.60、output 92 → 3.58、production 180 → 2.91。TF-IDF 只對含查詢詞的文件打分（c03 只有 284 / 3,299 篇有分數），這也是後面 MAP 偏低的原因。

topic	train	test	唯一主題	查詢例（主題詞 · 同義改寫／情境描述）
earn 獲利	2,877	1,087	1,083	quarterly net profit results · corporate financial performance for the year
acq 併購	1,650	719	696	acquisition of a company · merger agreement between two firms
crude 原油	389	189	121	crude oil prices · **petroleum** production and output
grain 穀物	433	149	10	grain exports · **cereal** crop production forecast
trade 貿易	369	117	75	trade deficit figures · import tariffs and export restrictions

每主題 4 題（主題詞 / 路透慣用詞 / 同義改寫 / 情境描述），共 20 題：「查詢用字離新聞詞彙多遠」成為可控變因。

任務二 Word2Vec：CBOW 與 skip-gram 在 train 切分上訓練

spec 4

`ir/word2vec.py`（Project #2 自行實作：negative sampling 5、dynamic window、sub-sampling 1e-3）。**skip-gram** 以中心詞預測每個上下文詞（每個中心詞產生 2b 個樣本，訓練慢、稀有詞更新多）；**CBOW** 以上下文平均預測中心詞（快、向量較平滑）。六個模型同一份 train → 詞彙都是 9,996；loss 隨 epoch 下降（CBOW 5 → 10 epochs：1.95 → 1.65），skip-gram 時間約為 CBOW 的 3 倍；loss 不能跨架構比較。覆蓋率：test 詞型 46%、詞元 93%（OOV 多是公司名、人名、hapax）；沒有任何 test 文件完全沒有向量。

模型	架構	dim	win	ep	loss	分鐘
sg-d100-w5-m5-e5	skip-gram	100	5	5	2.117	21.3
cbow-d100-w5-m5-e5	CBOW	100	5	5	1.951	6.7
sg-d50-w5-m5-e5	skip-gram	50	5	5	2.141	11.5
cbow-d50-w5-m5-e5	CBOW	50	5	5	1.947	3.5
sg-d100-w2-m5-e5	skip-gram	100	2	5	2.054	13.3
cbow-d100-w5-m5-e10	CBOW	100	5	10	1.647	13.5

任務三 Word-level：每個詞的 Top-5 最近鄰與三個問題

spec 5 · skip-gram d100 ／ CBOW d100

詞	skip-gram（cosine）	CBOW（cosine）
`oil`	crude .74 · gas .69 · petroleum .64 · pipeline .62 · natural .61	crude .80 · natural .80 · fuel .76 · pipeline .76 · postings .76
`petroleum`	king .70 · xon .69 · esso .69 · gas .68 · inland .68	mines .92 · columbia .86 · mining .84 · pty .84 · pacific .83
`opec`	bpd .78 · lukman .77 · nazer .77 · arabia .77 · ceiling .76	producer .90 · colombia .86 · arabia .85 · import .85 · coffee .84
`profit`	loss .79 · oper .78 · pre-tax .77 · profits .75 · comalco .75	pre-tax .88 · loss .86 · profits .85 · pretax .83 · attributable .82
`acquisition`	transaction .77 · merger .76 · buyout .72 · acquisitions .71 · comdata .70	buyout .92 · lbo .87 · merger .87 · borg-warner .86 · leveraged .86
`grain`	corn .77 · wheat .77 · cotton .72 · feed .71 · soybeans .71	soybeans .93 · winter .93 · corn .92 · feed .92 · grains .92
`cereal` n=24	grants .92 · bread .89 · spanish .89 · non-ec .89 · levies .88	availability .95 · ghana .95 · fixing .95 · featured .95 · artificially .94

- **合理的語意／使用情境關係：**oil–crude–gas–petroleum、grain–corn–wheat–soybeans、acquisition–merger–buyout、deficit–surplus；詞形變化 profit / profits、deficit / deficits 也靠近（stemming 用規則做的事，詞向量從分布學到）。
- **因相似新聞情境而共現：**opec–lukman–nazer–ceiling（OPEC 報導的固定班底：同篇 6–42 次、PMI 3.8–4.7）、trade–yeutter–gatt、acquisition–borg-warner。這些是「同一類新聞」而非同義。
- **不符預期，原因：**(1) 語料用法偏移——petroleum 在語料裡多是 British / Esso / Pacific *Petroleum* 公司名，鄰居變成公司與礦業詞（含 petroleum 的 test 文件只 44% 是 crude）；(2) 稀有詞——cereal、tariff 只訓練 24 / 38 次，鄰居隨機、cosine 虛高（.88–.96），兩模型 Top-5 零重疊；(3) CBOW 向量較平滑，cosine 普遍偏高、無關鄰居較多（opec–coffee 同篇 0）。
- **向量相近 ≠ 同義：**反義詞 profit / loss .79、rise / fall .87、buy / sell .77、deficit / surplus .86（CBOW 更高：.86 / .92 / .87）——它們在同一句位互換出現，向量只知「用法相同」不知「意思相反」。

任務四 用詞向量表示文件：四種表示法

spec 6

A TF-IDF ltc：w = (1+ln tf)·ln(N/df)，L2 正規化 → cos
A_0 同上但 Porter stems（Project #3 管線，對照）

只有含查詢詞的文件有分數；前 10 名詞彙重疊必 > 0。

C 詞向量平均：$d = \Sigma_t$ tf·v(t) / Σ tf
B TF-IDF 加權平均：$d = \Sigma_t$ (1+ln tf)·idf·v(t)，L2 正規化

每篇文件都有向量（3,299 / 3,299 篇有分數）；B 讓 said、mln 等高 df 詞幾乎不拉動文件向量；OOV 詞跳過並回報覆蓋率。

D 融合：score = $\alpha \cdot \cos_A + (1-\alpha) \cdot \cos_B$（預設 α = 0.5，掃描 0–1）

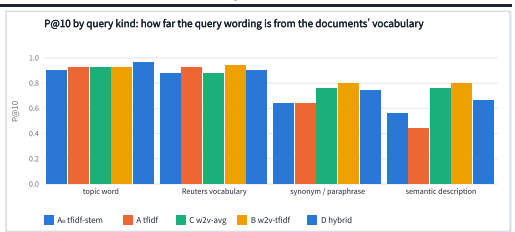
查詢向量用同一公式；B 的查詢詞權重與 idf 成正比。檢索系統：查詢 → 前處理 → 建向量 → 與每篇 test 新聞算 cosine → 排序 → 前 k 名；每筆列出 TOPICS、rel 等級、查詢詞是否命中、查詢詞在文件中最相近的詞（可解釋為何配到）。

任務五 Document-level：新聞檢索系統與 20 個查詢的評估

spec 7–11 · k = 10 · test 3,299 篇

run（B 其他模型見結論）	P@10	MRR	nDCG@10	MAP	主題詞	慣用詞	同義	情境
A_0 TF-IDF stems	.745	.824	.623	.369	.90	.88	.64	.56
A TF-IDF	.730	.824	.605	.341	.92	.92	.64	.44
C 平均 · CBOW	.755	.762	.630	.610	.90	.86	.56	.70
C 平均 · skip-gram	.830	.912	.714	.638	.92	.88	.76	.76
B 加權 · CBOW	.790	.870	.670	.605	.90	.86	.66	.74
B 加權 · skip-gram	**.865**	**.942**	**.735**	.644	.92	**.94**	**.80**	**.80**
D 融合 α=.5 · skip-gram	.815	.942	.705	.640	.96	.90	.74	.66
D 融合 α=.2 · skip-gram	.885	.963	.757	**.649**	1.00	.92	.80	.82

右四欄 = P@10 依查詢用字（每類 5 題）。R@10 全在 .03 左右（earn 有 1,087 篇相關）；MAP 的大差距反映 TF-IDF 的召回上限（沒檢回的相關文件算 0），不是前十名品質，因此主要指標是 P@10 / MRR / nDCG@10。逐題 P@10：**B 勝 9**、**A 勝 5**（c01 g01 g03 g04 t03）、平手 6。



P@10 依查詢用字：用字離新聞詞彙越遠（往右），TF-IDF（A）掉得越多；B 加權詞向量維持 .80；主題詞查詢兩者相同。

結論 差異分析：詞彙匹配、語意相似度、文件排序

spec 9–11 · RQ1–RQ5

- **核心比較 A vs B（spec 9）。**保留 TF-IDF 對重要詞的辨識力、再引入上下文表示**有**改善：skip-gram P@10 +18%、MRR +14%、nDCG@10 +21%；但收益**全部來自用字與新聞不同的查詢**（同義改寫 .64 → .80、情境描述 .44 → .80），主題詞與慣用詞查詢持平（.92）。c03 *petroleum production and output*：A .20 → B .80（前十重疊只 2 篇）。反例：g03 *cereal*（.8 → .7）、t03 *tariff*（.9 → .7）——稀有查詢詞的向量不穩定時，字面比對反而較好。
- **CBOW vs skip-gram（spec 10）。**同參數下 skip-gram 較好（B 方法 .865 vs .790；逐題 7 : 2 : 11），但不是架構決定一切：CBOW 10 epochs 反而退步（loss 1.95 → 1.65，P@10 .790 → .770）、skip-gram 視窗 2 掉到 .800、d50 不輸 d100（.885）；詞層級 Top-5 兩架構只重疊 1–3 個，文件層級差距卻小得多（文件向量把鄰居差異平均掉）。小語料上差距受資料量、詞頻與參數左右，結論只能是「在此語料與參數下 skip-gram 較好」。
- **詞彙匹配 vs 語意相似度 vs 排序（spec 11）。**詞彙匹配：A 的「無查詢詞」結果永遠 0；語意匹配：B 可排進不含任何查詢詞的文件（c03 有 2 篇，如 API 庫存週報），相關就是收益、不相關就是誤配（鋅、鋁產量）；排序：A 與 B 前十重疊常不到一半。加權的因果：不加權的 C 讓 said、mln、dlrs 把所有文件拉向同一方向（MRR .912 vs B .942；CBOW .762 vs .870）。融合 D 在 α = .2 最佳（nDCG@10 .757），預設 α = .5 反而比純 B 差——融合權重不能假設。
- **限制。**加權平均不保留詞序與否定；相關性只來自 TOPICS；20 題，差距 < .05 不顯著；詞向量只用 train 訓練（test 詞型 OOV 54%）；結論限於小型新聞語料——Word Embedding 不保證優於 TF-IDF，必須以 document-level 的檢索評估驗證。