Reuters-21578：從 TF-IDF 到 Word Embedding 的新聞檢索實驗

胡元楨（P77141105）

結論。在 TF-IDF 的權重上加入詞向量（方法 B）使 P@10 由 .730 升到 .865，但進步**只發生在查詢用字與新聞不同時**；用字一致時兩者相同；B 還會帶進鄰近主題的新聞，遇到反義詞與沒有向量的詞時失準。Word Embedding 不保證優於 TF-IDF。

資料
21,578 → ModApte 12,902
train **9,603**：只訓練詞向量
test **3,299**：檢索集合

相關性
新聞的 TOPICS 人工標記
earn acq crude grain trade
與檢索方法無關

方法
規格：**A** TF-IDF
規格：**B** TF-IDF 加權詞向量
自行加入：C 直接平均、D 融合

詞向量
7 個 word2vec 模型
詞彙 9,996（min_count 5）
主模型 skip-gram d100

評估
20 個查詢
= 5 主題 × 4 種用字
P@10、MRR、nDCG@10

1 Word-level：哪些詞在向量空間中接近？為什麼？

規格：Word-level analysis · skip-gram d100 的前 4 名鄰居

接近的原因	詞（訓練次數）	最近鄰（cosine）	兩模型共同鄰居	判讀
語意相同	oil（2,397）	crude .74 · gas .69 · petroleum .64 · pipeline .61	3 / 5	可互相替換；兩個模型一致
同類新聞的常客	opec（371）	bpd .77 · lukman .77 · nazer .77 · arabia .77	1 / 5	人名、國名，不能替換 opec，只是常同篇（PMI 3.8–4.7）
語料的特殊用法	petroleum（404）	king .70 · xon .69 · esso .69 · gas .68	0 / 5	在路透語料中多是公司名的一部分，不是 oil 的同義詞
訓練不足	cereal（24）	grants .92 · bread .89 · spanish .89 · non-ec .89	0 / 5	鄰居無關而 cosine 最高：高分是假象
用法相同但反義	profit / loss .79 · rise / fall .87 · buy / sell .77	＞ 同義的 oil / petroleum .64		佔同一個句位；向量相近 ≠ 同義

答：cosine 只反映「出現的語境相似」。語境相似有五種來源，其中只有第一種是意義相近；所以詞向量好不好，必須到文件層級才能判斷。

2 詞彙匹配與語意相似度的差異

學習目標 7

P@10 依查詢用字（每類 5 題）	主題詞	慣用詞	同義改寫	情境描述
A TF-IDF	.92	.92	.64	.44
B 加權詞向量	.92	.94	**.80**	**.80**

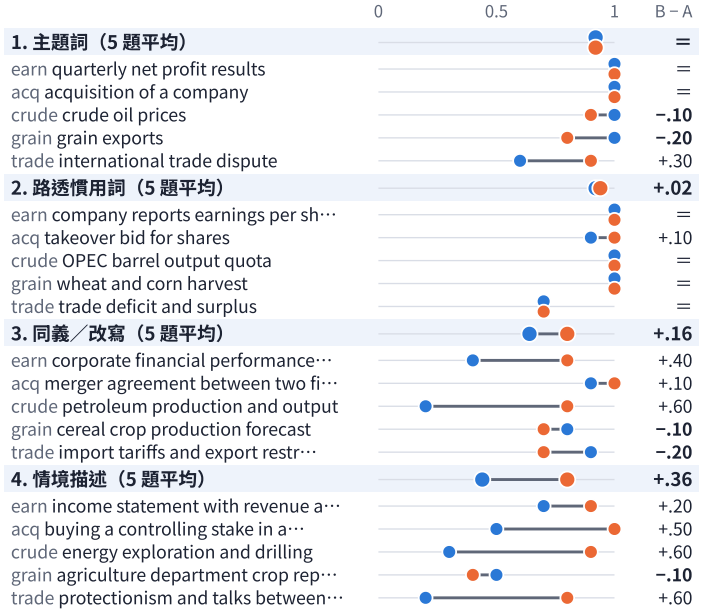
答：用字與新聞一致時兩者打平；用字離新聞越遠，A 掉得越多，B 維持 .80。例：*petroleum production and output*，A .20 → B .80。A 只能命中 output、production，前 6 名是工業產出與併購新聞；B 的前 10 名有 2 篇**不含任何查詢詞**。代價：B 也排進鋅、鋁的「產量」新聞。

3 加入詞向量是否改善文件檢索？

核心比較 A vs B

20 題平均	P@10	MRR	nDCG@10
A TF-IDF	.730	.824	.605
B 加權詞向量	.865	.942	.735

答：有改善（P@10 +18%、MRR +14%、nDCG@10 +22%），但不是每題都好：逐題 **B 勝 9、A 勝 5、平手 6**，平均是少數幾題大贏拉出來的。A 勝的 5 題中 3 題屬於 grain（唯一 A 較好的主題：.82 對 .72）。原因是 B 會帶進**鄰近主題**：查穀物時排進油籽、糖的作物新聞；*import tariffs*…（.90 → .70）排進柳橙汁、油籽的貿易爭端。情境相同，TOPICS 標的卻是別的主題。



A TF-IDF　B 加權詞向量（skip-gram d100）。逐題 P@10，依查詢用字分四類；越往下用字離新聞越遠，B 的優勢越明顯。例外集中在 grain：B 會帶進鄰近的商品主題。

4 Skip-Gram 一定優於 CBOW 嗎？

方法 B 的 P@10



答：在這份語料上 skip-gram 較好（同設定 .865 對 .790；逐題 7 勝 2 負 11 平）。但 CBOW 訓練更久並未變好、維度 50 不輸 100。除了刻意訓練不足的模型，其餘六個都贏過 A，進步幅度由 +.040 到 +.155：方向不靠挑模型，幅度會。★ = 主模型（常見預設值）。

5 延伸與限制：加權、融合與做不到的事

C、D 自行加入

skip-gram d100	P@10	MRR	nDCG@10
C 直接平均（不加權）	.830	.912	.714
B TF-IDF 加權	.865	.942	.735
D 融合 α = 0.5	.815	.942	.705
D 融合 α = 0.2（最佳）	.885	.963	.757

答：加權有小幅幫助（C → B；CBOW 上是 .755 → .790）。**融合 D** = $\alpha \cdot \cos_A + (1-\alpha) \cdot \cos_B$：α 由 0 到 1 每 0.1 試一次，取 nDCG@10 最高者（α = 0.2）。它是四種方法中最好的：主題詞查詢 P@10 1.00、情境描述 .82，也補回 B 找不到的 OOV 詞。但 α = 0.5 反而比 B 差，且 α 是在同一批 20 題上挑的，數字偏樂觀。

- **反義詞：**用 B 查 profit，前 10 名有 5 篇標題寫 LOSS（A 1 篇）；P@10 卻都是 1.00，**指標看不出來**。
- **否定與詞序：***will acquire* 與 *did not acquire* 前處理後是同一組詞，兩種方法的排名完全相同。
- **沒有向量的詞：**test 有 54% 的詞型不在詞彙內；查 *Cajamarquilla* 時 B 回傳空排名，A 找到 1 篇。
- **評估本身：**相關性只到主題層級；僅 20 題，.05 以內的差距不具意義。