

PMC 全文字檢索工具

後端 • 資料收錄與建索引(indexing time)

1 取得與解析

PMID / PMCID →
NCBI → JATS XML

2 前處理

斷詞、小寫化、停
用詞、Porter 詞幹

3 索引

位置倒排索引,記錄
欄位區間

前端 • 使用者查詢與互動(query time)

4 查詢

布林、片語、萬用
字元、欄位限定

5 排序

BM25 / TF-IDF,整
篇或分欄評分

6 呈現

高亮片段、比對位
置圖、規則式斷句

前處理 pipeline:原文 → 索引詞

- 1 斷詞 Tokenization** 連續字母或數字為一個 token,連字號切開
COVID-19 → covid, 19 T-cell → t, cell
- 2 小寫化 Case folding** Cancer / cancer / CANCER 視為同一個詞
SARS-CoV-2 → sars, cov, 2
- 3 停用詞移除 Stop-word removal** Snowball 174 詞 + 生醫補充 17 詞(et al.、however、may...)
Smith et al. reported → smith, report
"role of the gut" → role _ _ gut (位置保留,相距 3)
- 4 Porter 詞幹化 Stemming** 依 1980 論文五步驟自行實作,以論文範例驗證
immunotherapies → immunotherapi probiotics → probiot

導入的演算法與模型

位置倒排索引 Positional inverted index

term → {doc → [positions]},支援片語、欄位區間

布林檢索模型 + 遞迴下降查詢解析

AND / OR / NOT 集合運算,優先序 NOT > AND > OR

Okapi BM25 與 TF-IDF 排序

$k1=1.5$ 、 $b=0.75$;TF-IDF 為 $(1+\log tf) \cdot \log(N/df)/\sqrt{dl}$

分欄評分 Field-level scoring

title / abstract / body 各自長度正規化,可只依摘要排序

規則式句子邊界偵測 EOS detection

縮寫表、首字母、屬名 E. coli、小數點;對照天真法

NCBI E-utilities 整合

PMID → PMCID、efetch 全文,無全文時改索引 PubMed 摘要